探索数据上的离线强化学习：IQL 的 expectile、CQL 的保守性与数据来源

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文完成 CS224R 2025 Homework 3：在 PointMass 迷宫上实现 Implicit Q-Learning（IQL）与离散动作 Conservative Q-Learning（CQL），比较 Random Network Distillation（RND）与均匀随机两种无监督探索得到的数据。IQL 在 Easy 上 $\zeta = 0.9$ 的回报为 -18.8 ± 0.5，优于 $\zeta = 0.2$ 的 -20.4 ± 0.8（各 6 个种子）；Medium 上 RND 数据比随机数据高约 30–40。CQL 在 Medium 上 $\alpha = 0$ 的全部种子停在 episode 上限 -150，$\alpha = 0.1$ 为 -68.5 ± 11.5。核对 starter 后我们发现，CQL 的数据采集在两种探索设定下都调用同一个最短路贪心控制器，因此作业里 CQL 的 “RND 对 random” 对比实际上比较的是同一份专家数据。我们补充了该控制器的回报（-67.2）、α 的七点扫描与分布外间隙，并新增 `--behavior explore` 让 CQL 真正使用探索数据：在均匀随机数据上 $\alpha = 0.1$ 达到 -34.3 ± 6.1，明显超过专家控制器本身。

关键词： Offline RL；IQL；CQL；Expectile；RND；Exploration Data；Coverage

1 问题与设定

PointMass 是带墙的二维迷宫，5 个离散动作（四个方向与不动），动作带高斯噪声；到达目标得 0，其余每步 -1，episode 上限 Easy 50、Medium 150、Hard 100 步。因此 -150 表示在 Medium 上始终没有到达目标。

一次运行共 5×10^4 个环境步，分为探索与利用两段 [Yarats et al., 2022]。探索阶段只优化内在奖励。RND 固定随机目标网络 f^*，训练预测网络 $\hat{f}$，用 $\|\hat{f}(s') - f^*(s')\|$ 作奖励 [Burda et al., 2019]；随机探索在 `learning_starts` 之前全部均匀采样动作。利用阶段用环境奖励训练离线 critic：

- IQL 按作业命令运行，探索 2×10^4 步。命令没有 `--offline_exploitation`，所以利用阶段仍以 $\varepsilon = 0.2$ 继续写入缓冲区，严格说是 offline-to-online。
- CQL 带 `--offline_exploitation`，探索 10^4 步（starter 默认值）后缓冲区冻结，是严格的离线设定。

2 方法

2.1 IQL

IQL 只在数据动作上做备份 [Kostrikov et al., 2022]：

$$L_V = \mathbb{E}_{\mathcal{D}}\big[L_2^\zeta(\bar{Q}(s,a) - V(s))\big], \quad L_2^\zeta(u) = |\zeta - \mathbb{1}(u < 0)|u^2, \tag{1}$$

$$L_Q = \mathbb{E}_{\mathcal{D}}\big[(r + \gamma(1-d)V(s') - Q(s,a))^2\big]. \tag{2}$$

$\bar{Q}$ 来自目标网络并 detach。策略用 AWAC 的优势加权对数似然抽取，$A = Q(s,a) - V(s)$ 在无梯度下计算并压成形状 $(N,)$[Nair et al., 2020, Peng et al., 2019]。$\zeta = 0.5$ 时 V 是行为策略价值；$\zeta \to 1$ 时逼近数据支撑内的 $\max_a Q$ [Newey and Powell, 1987]。

2.2 CQL

离散动作下 CQL 正则可以精确计算 [Kumar et al., 2020]：

$$\mathcal{L} = \mathcal{L}_{\text{DQN}} + \alpha\, \mathbb{E}_{s,a\sim\mathcal{D}}\Big[\log \textstyle\sum_{a'} e^{Q(s,a')} - Q(s,a)\Big]. \tag{3}$$

实现用 `torch.logsumexp`，同时记录 $\log\sum e^Q$ 与 $Q(s, a_{\mathcal{D}})$，二者之差称为分布外间隙（OOD gap）。官方单元测试输出 `PASSED!!`，我们另写了 5 个 pytest 用例核对 IQL 的 expectile、V/Q 目标与 CQL 正则。

2.3 数据采集器的发现与修正

starter 的 `ExplorationOrExploitationAgent.step_env` 把探索策略的代码注释掉，每一步都执行 `env.get_optimal_action(env.state)`：在一步仿真后选择最短路距离（全源最短路）最小的动作。因此 CQL 的 `--use_rnd` 只改变 `learning_starts`（2000 或 10^4），不改变数据。图 7 中三组 CQL 的状态密度图完全相同，也印证了这一点。我们在 solutions 副本中增加 `--behavior {oracle,explore}`：默认 `oracle` 与 starter 完全一致；`explore` 恢复与 IQL agent 相同的采集逻辑（ε-greedy 地执行探索 critic 的 argmax，`learning_starts` 之前均匀随机）。另写 `analysis/oracle_baseline.py` 评估该控制器本身：

Easy -18.4、Medium -67.2、Hard -55.9（各 20 条 episode，成功率 1.0/1.0/0.95）。

2.4 实验

所有配置至少 3 个种子，作业要求的配置 6 个种子。最终回报取每个种子最后 3 次评估的均值，再报告跨种子均值 ± 标准差（总体标准差）。运行在 CPU 上并行完成，曲线由 TensorBoard 事件导出。

3 IQL

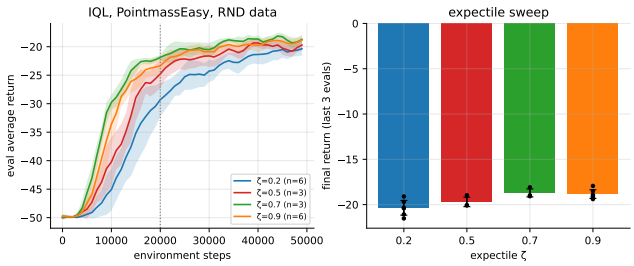


图 1: PointmassEasy 上的 expectile 扫描。左：评估回报曲线，虚线为探索结束。右：最终回报，黑点为单个种子。

Q1.1：$\zeta = 0.2$ 与 0.9。 Easy 上 $\zeta = 0.9$ 的最终回报为 -18.84 ± 0.48，$\zeta = 0.2$ 为 -20.36 ± 0.81（各 6 个种子），中间的 0.5 与 0.7 分别为 -19.71 与 -18.71（图 1）。较大的 ζ 更好：$V(s)$ 拟合数据中 Q 的上分位，近似“数据支撑内最好的动作”的价值，优势 $Q - V$ 只对优于大多数数据动作的动作为正，AWR 的权重因此集中在更好的动作上。$\zeta = 0.2$ 则让 V 低于平均，几乎所有动作的优势为正，策略抽取接近行为克隆。Easy 迷宫很小，RND 数据已覆盖目标，所以差距只有约 1.5；对照专家控制器的 -18.4，$\zeta \geq 0.7$ 已接近最优。

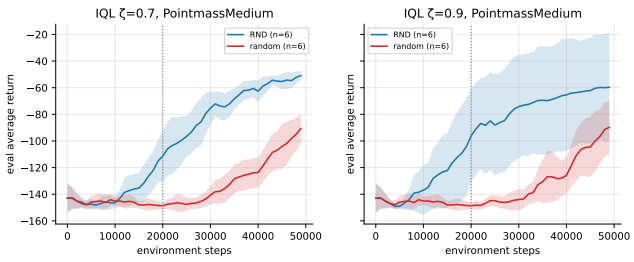


图 2: PointmassMedium 上 RND 与随机探索数据（各 6 个种子）。

表 1: IQL 在 PointmassMedium 上的最终回报（6 个种子）。

	RND	random
$\zeta = 0.7$	-50.9 ± 2.4	-90.7 ± 6.7
$\zeta = 0.9$	-59.7 ± 36.9	-89.8 ± 15.8

Q1.2：RND 与 random。 表 1 与图 2 中，两种 ζ 下 RND 都比随机探索高 30 以上。$\zeta = 0.9$ 的 RND 有一个种子停在 -141.6，其余五个在 -38 到 -50 之间，均值因此被拉低、方差很大；$\zeta = 0.7$ 的六个种子都在 -48 到 -55，更稳定。曲线显示随机数据上的 IQL 在探索结束（2×10^4 步）时仍为 -150，之后靠利用阶段的在线数据才慢慢上升；RND 数据上回报在探索阶段就开始上升。这说明在 offline RL 中，数据决定了可学的上限：均匀随机游走的扩散半径随 $\sqrt{t}$ 增长，状态密度集中在起点附近（图 7 第二行），远端走廊和目标附近几乎没有转移；RND 主动访问预测误差大的状态，覆盖了通往目标的路径。IQL 只在数据动作上备份，没有数据的区域无法通过外推补上 [Schweighofer et al., 2022, Jin et al., 2021]。

补充扫描。 Medium 上 RND 数据的 $\zeta = 0.5, 0.7, 0.9, 0.95$ 分别为 -98.1 ± 32.1、-50.9 ± 2.4、-59.7 ± 36.9、-47.8 ± 11.2（图 5 右）。$\zeta = 0.5$ 即 SARSA 式的行为价值，明显最差；0.7 以上差别在种子噪声内，高 ζ 的方差更大，因为 V 依赖少数高价值样本。Hard 上 $\zeta = 0.9$ 只有 -93.3 ± 3.8，低于专家控制器的 -55.9。

4 CQL

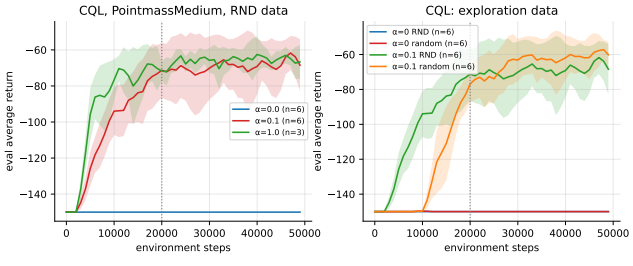


图 3: CQL 在 PointmassMedium 上的评估回报。左：α；右：两种探索标志。

Q2.1：$\alpha = 0$ 与 0.1。 $\alpha = 0$ 时正则消失，算法退化为在固定缓冲区上训练的 double DQN。六个种子的最终回报全部为 -150；$\alpha = 0.1$ 为 -68.5 ± 11.5（逐种子 $-63.5, -83.9, -49.8, -74.7, -77.6, -61.3$）。图 4 给出

原因：$\alpha = 0$ 时数据动作的 Q 值约为 -1.0，$\log \sum e^{Q}$ 为 0.91，间隙 1.91。每步奖励为 -1、到达目标需要几十步，真实价值远低于 -1，这是典型的过估计。数据由专家控制器采集，每个状态几乎只出现一个动作；$\max_{a'} Q(s', a')$ 总会挑到没有被数据约束的动作，误差经备份传回 [Fujimoto et al., 2019, Kumar et al., 2019]。贪心策略于是执行这些虚高的动作，在迷宫里卡住。$\alpha = 0.1$ 时数据 Q 降到 -12.7，间隙降到 0.48，策略回到专家动作附近。

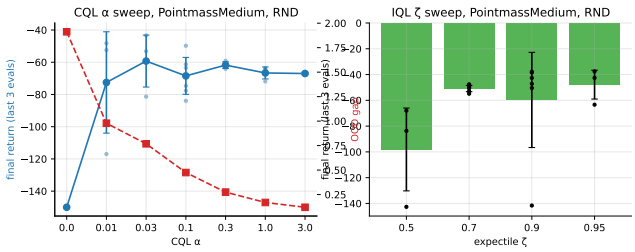


图 5: 左：CQL α 七点扫描的最终回报（蓝）与分布外间隙（红，右轴）。右：IQL ζ 扫描。

α 扫描。 图 5 左：$\alpha = 0.01, 0.03, 0.1, 0.3, 1, 3$ 的回报分别为 $-72.5, -59.3, -68.5, -61.8, -66.6, -67.0$，间隙从 0.98 单调降到 0.12。只要 $\alpha > 0$，策略就不再崩溃；$\alpha \geq 0.3$ 后方差很小，回报稳定在专家控制器的 -67.2 附近。这符合 CQL 的理论：α 越大，学到的 Q 越接近行为策略的价值下界，策略越接近行为策略 [Kumar et al., 2020]。小 α（0.01）有一个种子跌到 -117，保守性不足时外推仍会偶发。Hard 上同样，$\alpha = 0$ 停在上限 -100，$\alpha = 0.1$ 为 -41.1 ± 2.0，高于专家控制器的 -55.9：控制器的一步前瞻没有考虑动作噪声，在窄通道附近并非最优，CQL 在其数据附近做了小幅的策略改进。

Q2.2: RND 与 random 标志。 按作业命令，$\alpha = 0.1$ 时 RND 标志为 -68.5 ± 11.5，random 标志为 -60.2 ± 5.8（各 6 个种子），差别在种子噪声内。原因是上节的发现：两个标志下数据完全相同，只是 random 标志把 critic 的训练起点推迟到第 10^4 步。图 7 中 CQL 三行的状态密度一致，轨迹集中在专家路径上。

5 CQL 真正使用探索数据时

表 2: CQL 在 PointmassMedium 上按数据来源的最终回报。

数据	$\alpha = 0$	$\alpha = 0.1$	$\alpha = 1$
专家（starter）	-150.0 ± 0.0	-68.5 ± 11.5	-66.6 ± 3.7
RND 探索	-62.1 ± 35.3	-67.6 ± 26.9	-150.0 ± 0.0
均匀随机	-51.6 ± 42.0	-34.3 ± 6.1	-42.7 ± 12.1

表 2 与图 6 给出三点结论。

第一，数据的动作覆盖决定了是否需要保守。专家数据上 $\alpha = 0$ 必然崩溃；探索数据在每个状态上覆盖多个动作，$\max_{a'}$ 查询的动作大多有数据约束，即使 $\alpha = 0$ 的离线 DQN 也能学到 -50 到 -60 的策略，只是方差很大（随机数据有一个种子为 -145）。这与 ExORL 的观察一致：在探索性数据上，普通的 off-policy 算法已经可以工作 [Yarats et al., 2022]。

第二，覆盖面广的数据让 CQL 超过专家。均匀随机数据上 $\alpha = 0.1$ 达到 -34.3 ± 6.1，六个种子都优于专家控制器的 -67.2。专家数据只沿一条路径，CQL 只能在其附近改进；随机数据虽然质量低，但包含大量不同动作的转移，动态规划可以把片段拼成更短的路径 [Kumar et al., 2022]。

第三，保守性会把策略拉向行为策略，行为策略的偏差因此变得重要。RND 数据上 $\alpha = 1$ 的六个种子全部为 -150。RND 的探索策略在后期主要执行探索 critic 的 argmax，动作分布偏向“去新奇的地方”而不是“去目标”；α 很大时 CQL 近似对行为策略做加权模仿，学到的是探索行为。均匀随机数据的动作分布对称，同样的 $\alpha = 1$ 只把 Q 整体下压，不偏向任何动作，所以仍有 -42.7。这一对比说明 α 的合适取值依赖数据的行为策略：数据越接近专家，越需要保守；数据越偏离任务，越不能过度保守。

这一组结果也与 IQL 的 Q1.2 方向不同：IQL 在 RND 数据上更好，CQL 在随机数据上更好。两者的设定不同。IQL 探索 2×10^4 步且之后继续在线收集，CQL 只用 10^4 步的冻结数据；10^4 步内随机探索在 Medium 上已能偶尔到达目标附近，而 RND 的 argmax 探索策略的动作多样性低于均匀随机。数据的“好坏”不能脱离算法与预算单独讨论。

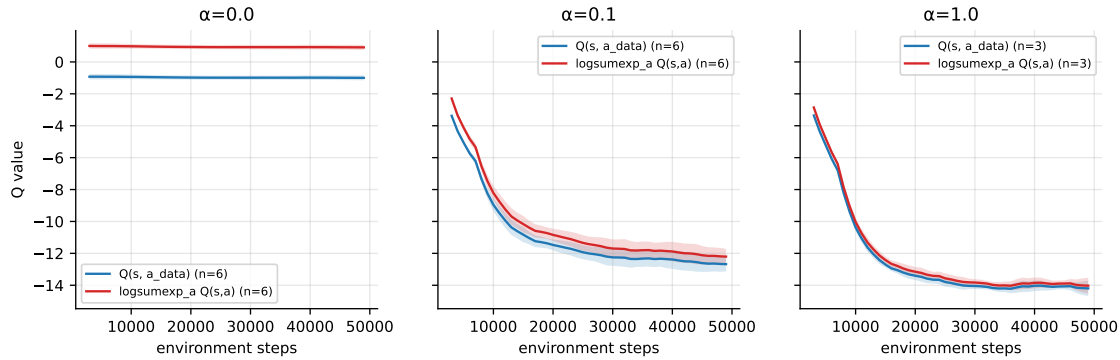


图 4: CQL 的 $Q(s, a_{\mathcal{D}})$ 与 $\log \sum_a e^{Q(s,a)}$。$\alpha = 0$ 时分布外动作的软最大值高于数据动作，Q 值接近 -1，远高于真实回报。

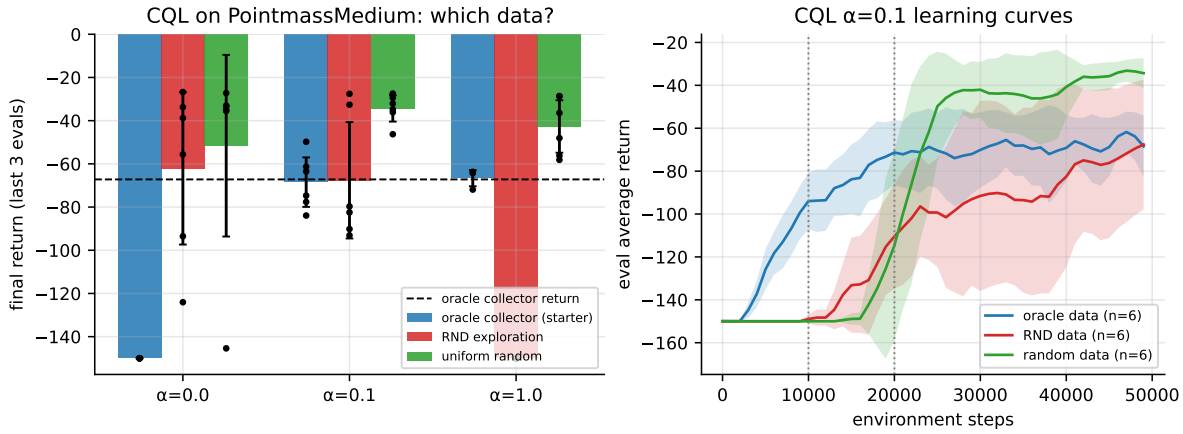
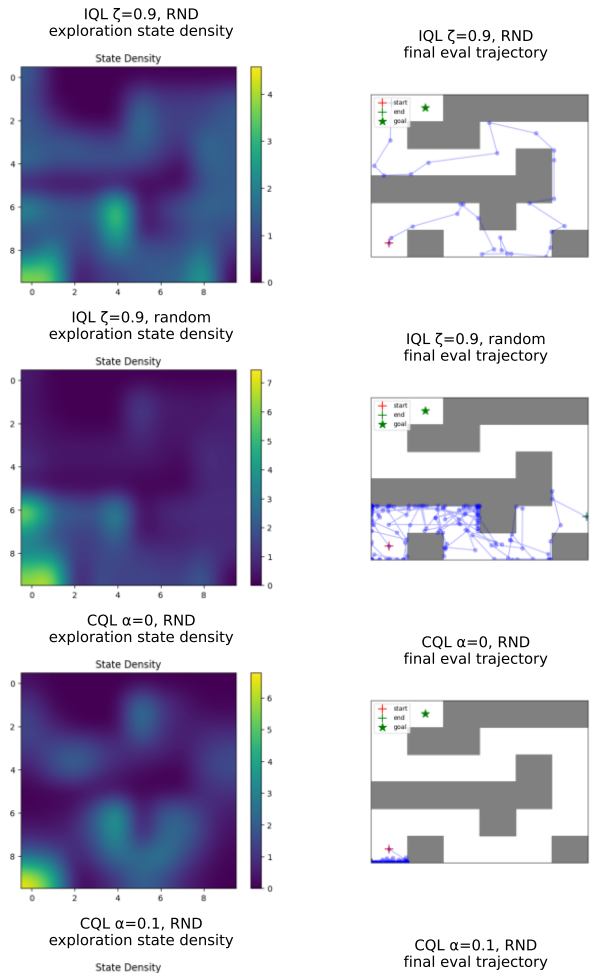


图 6: PointmassMedium 上三种数据来源的 CQL（`--behavior explore` 各 6 个种子）。虚线为专家控制器的回报 -67.2。右：$\alpha = 0.1$ 的学习曲线，两条竖线分别为 CQL 的探索结束（10^4）与 IQL 的探索结束（2×10^4）。



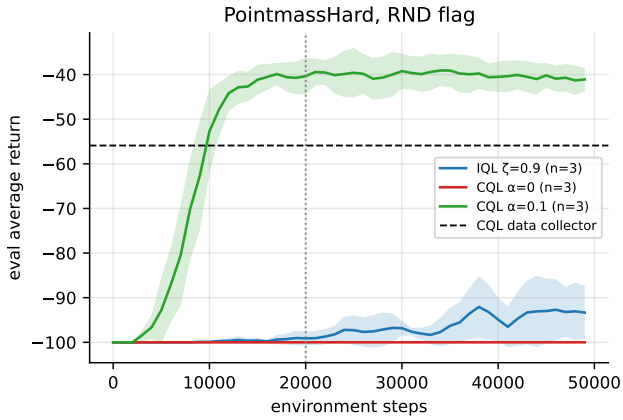


图 8: PointmassHard：IQL 与 CQL（starter 采集器），虚线为采集器自身回报。

6 结论

IQL 的 expectile 越高，策略抽取越接近数据支撑内的贪心改进，Easy 上 $\zeta = 0.9$ 优于 0.2；Medium 上 RND 数据比随机数据高 30 以上，差距来自数据覆盖。

CQL 的 $\alpha = 0$ 在专家数据上因分布外动作过估计而完全失败，任意 $\alpha > 0$ 都能恢复到专家水平。作业中 CQL 的 RND/random 对比被 starter 的固定采集器消解；修正后，均匀随机数据上的 CQL 显著超过专家，而 RND 数据配合大 α 会模仿探索行为而失败。离线 RL 的结果是算法、保守系数与数据行为策略三者的乘积，不能只讨论其中一项。

参考文献

Yuri Burda, Harrison Edwards, Amos Storkey, and Oleg Klimov. Exploration by random network distillation. In *International Conference on Learning Representations (ICLR)*, 2019.

Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, 2019.

Ying Jin, Zhuoran Yang, and Zhaoran Wang. Is pessimism provably efficient for offline RL? In *International Conference on Machine Learning (ICML)*, 2021.

Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.

Aviral Kumar, Justin Fu, Matthew Soh, George Tucker, and Sergey Levine. Stabilizing off-policy Q-learning via bootstrapping error reduction. In *Advances in Neural Information Processing Systems*, 2019.

Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Aviral Kumar, Joey Hong, Anikait Singh, and Sergey Levine. When should we prefer offline reinforcement learning over behavioral cloning? In *International Conference on Learning Representations (ICLR)*, 2022.

Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. AWAC: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.

Whitney K. Newey and James L. Powell. Asymmetric least squares estimation and testing. volume 55, pages 819–847, 1987.

Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. In *arXiv preprint arXiv:1910.00177*, 2019.

Kajetan Schweighofer, Marius-Constantin Dinu, Andreas Radler, Markus Hofmarcher, Vihang Prakash Patil, Angela Bitto-Nemling, Hamid Eghbal-zadeh, and Sepp Hochreiter. A dataset perspective on offline reinforcement learning. In *Conference on Lifelong Learning Agents (CoLLAs)*, 2022.

Denis Yarats, David Brandfonbrener, Hao Liu, Michael Laskin, Pieter Abbeel, Alessandro Lazaric, and Lerrel Pinto. Don't change the algorithm, change the data: Exploratory data for offline reinforcement learning. *arXiv preprint arXiv:2201.13425*, 2022.