数据决定上限：探索数据、CQL 与 IQL 的面试指南

ShaneLiu04

https://github.com/ShaneLiu04

摘要

Offline RL 的面试通常从算法开始：CQL 的正则为什么能压低外推，IQL 的 expectile 为什么不查询分布外动作。工程上更常见的追问是数据：同一个算法换一份数据集，回报可以从“永远到不了目标”变成接近最优。本文以 CS224R 2025 Homework 3 的 PointMass 实验为线索，把三件事放在一起讲：无监督探索（RND 与随机策略）决定了数据覆盖；离散动作 CQL 的 logsumexp 正则在 $\alpha = 0$ 时退化为离线 DQN 并发生过估计；IQL 的 expectile 在数据只覆盖部分路径时如何选择上分位。每一节都给出可检查的日志量与追问。

关键词： Offline RL；Exploration Data；RND；CQL；IQL；Coverage；Pessimism

1 两阶段设定

作业把一次运行拆成两段。前一段是无监督探索：智能体只最大化内在奖励，环境奖励不进入探索 critic。随机探索在 `learning_starts` 之前每步都均匀采样动作；RND 探索在 $\varepsilon = 0.2$ 之外执行探索 critic 的 argmax。IQL 探索 2×10^4 步，命令不带 `--offline_exploitation`，利用阶段仍以 $\varepsilon = 0.2$ 的策略继续写入缓冲区，实际上是 offline-to-online 的设定 [Lee et al., 2022]。CQL 探索 10^4 步后缓冲区冻结，属于严格的 offline RL。

一个值得在面试里讲的细节：2025 starter 的 CQL agent 把探索策略的采集代码注释掉了，每一步都调用 `env.get_optimal_action`，即按全源最短路距离贪心的专家控制器。所以 CQL 的 `--use_rnd` 只改变 critic 的训练起点，不改变数据。发现方式很朴素：三组 CQL 的状态密度图逐像素相同。先画数据、再调算法，是 offline RL 工程的第一条纪律。

这种设定是 ExORL 的缩小版：先用与任务无关的探索算法采数据，再在同一份数据上用不同奖励做离线学习 [Yarats et al., 2022, Laskin et al., 2021]。ExORL 的主要结论是 *改数据比改算法更有效*：在探索性数据上，连普通的 TD3 都能接近 offline 专用算法。

2 RND：用预测误差近似计数

RND 固定一个随机初始化的目标网络 $f^*(s)$，训练预测网络 $\hat{f}_\phi$ 在缓冲区状态上拟合它，奖励为 $\|\hat{f}_\phi(s') - f^*(s')\|$[Burda et al., 2019]。见过越多次的状态预测误差越小，所以它是伪计数的一种平滑近似 [Bellemare et al., 2016, Tang et al., 2017]。与 ICM 相比，RND 的预测目标是确定性的，不受环境随机性（noisy TV）影响 [Pathak et al., 2017]。实现细节：

- 奖励要做归一化（作业用滑动标准差），否则不同阶段的量级差几个数量级；
- 目标网络与预测网络使用不同的初始化，避免一开始误差就接近 0；
- RND 奖励是非平稳的：预测网络在学，奖励在衰减，探索 critic 必须持续更新。

最大熵探索给出另一种理论视角：理想的无监督探索最大化状态访问分布的熵 [Hazan et al., 2019]。均匀随机策略在迷宫里的状态分布高度集中在起点附近，因为扩散的半径只随 $\sqrt{t}$ 增长；RND 主动走向低访问区域，覆盖面更大。

3 数据覆盖与可学性

理论上，悲观的 offline RL 只需要数据覆盖最优策略的状态动作分布，而不需要覆盖全部 [Jin et al., 2021, Rashidinejad et al., 2021]。这给出一个可操作的判断：如果数据里没有任何一条轨迹到达目标附近，任何离线算法都无法学出到达目标的策略；覆盖足够时，算法的差别才显现。Schweighofer 等人用“轨迹质量”和“状态覆盖”两个指标刻画 D4RL 式数据集，并发现覆盖度高的数据上 offline RL 优于行为克隆，质量高、覆盖低的数据上行为克隆更稳 [Schweighofer et al., 2022, Kumar et al., 2022]。

在 PointMass Medium 上，可以直接用作业输出的 `curr_state_density.png` 检查覆盖。IQL 的随机探索密度集中在起点附近，RND 扩展到迷宫远端，IQL 的回报相应高出 30 以上。我们让 CQL 真正使用探索数据后得到一组更有意思的对照（Medium，各 6 个种子）：专家数据上 $\alpha = 0$ 全部失败（-150），$\alpha = 0.1$ 约 -68，与专家控制器自身的 -67 持平；均匀随机数据上 $\alpha = 0$ 的离线 DQN 也能学到约 -52，$\alpha = 0.1$ 达到 -34，明

显超过专家；RND 数据上 $\alpha = 1$ 全部失败，因为强保守把策略拉向偏向“新奇”的探索行为。结论：保守系数要与数据的行为策略一起选。

4 离散动作 CQL

离散动作下，CQL 的正则可以精确计算 [Kumar et al., 2020]：

$$\mathcal{L} = \mathcal{L}_{\mathrm{TD}} + \alpha\, \mathbb{E}_{s\sim\mathcal{D}}\Big[\log \textstyle\sum_a e^{Q(s,a)} - \mathbb{E}_{a\sim\mathcal{D}} Q(s,a)\Big]. \quad (1)$$

第一项是软最大值，压低所有动作；第二项抬高数据动作。最优点上，分布外动作的 Q 值被压到数据动作以下，策略改进就不会选到它们。实现要点：

- logsumexp 用 `torch.logsumexp`，不要手写 `log(sum(exp))`；
- 第二项取的是 $Q(s, a_{\text{data}})$，不是 $\max_a Q$；
- 日志里同时记录 $\log \sum e^{Q}$ 与 $Q(s, a_{\text{data}})$，两者之差就是“分布外间隙”，是判断正则是否生效的最直接指标。

$\alpha = 0$ 意味着什么。 正则消失，剩下的是在固定缓冲区上训练的 double DQN。数据只覆盖部分动作时，$\max_a Q(s', a)$ 会挑中没有被数据约束的动作，误差经备份传回 [Fujimoto et al., 2019, Kumar et al., 2019]。作业的专家数据上，$\alpha = 0$ 的六个种子回报全部是 -150，即 episode 长度上限。数据动作的 Q 值约 -1.0，而每步奖励 -1、到达需要几十步，显然是过估计；分布外间隙为 1.91，$\alpha = 0.1$ 时降到 0.48，$\alpha = 3$ 时为 0.12。

α 的取值。 α 过大时 Q 被压向行为策略的价值，CQL 退化为加权的行为克隆，回报趋于数据质量；过小时外推重新出现。原论文还给出 Lagrangian 版本，让 α 自适应地把间隙维持在阈值 τ[Kumar et al., 2020]。后续工作指出 CQL 在数据覆盖好的区域过于保守，MCQ 只对分布外动作施加温和的伪目标 [Lyu et al., 2022]，EDAC 用 Q 集成的不确定性代替显式正则 [An et al., 2021]，Cal-QL 校准保守价值以便在线微调 [Nakamoto et al., 2023]。

5 IQL 与 expectile

IQL 用 expectile 回归拟合 $V(s)$[Kostrikov et al., 2022, Newey and Powell, 1987]：

$$L_V = \mathbb{E}_{(s,a)\sim\mathcal{D}}\big[|\zeta - \mathbb{1}(u<0)|\, u^2\big], \quad u = Q(s,a) - V(s), \quad (2)$$

Q 的目标为 $r + \gamma(1-d)V(s')$，策略用 AWR 抽取 [Peng et al., 2019, Nair et al., 2020]：$\exp(A/\lambda)$ 加权的对数似然。$\zeta = 0.5$ 时 V 是行为策略的期望价值，等价于 SARSA；$\zeta \to 1$ 时 V 逼近数据支撑内的最大 Q，接近 in-sample 的 Q-learning。所有更新只用数据中出现过的动作，因此不会外推到分布外动作。SQL/EQL 把这一思路推广为隐式价值正则 [Xu et al., 2023]，XQL 用 Gumbel 回归达到类似效果 [Garg et al., 2023]。

为什么 ζ 不是越大越好。 ζ 越大，V 越依赖少数高价值样本，方差越大；在随机环境中还会对“运气好”的转移过度乐观。作业中 Easy 环境的 ζ 差别不大，因为数据已经覆盖到目标；Medium 环境中 ζ 的影响更明显。

6 工程清单

- 先看数据：状态密度图、到达目标的轨迹数、平均回报。覆盖不够时不要调算法。
- CQL：监控分布外间隙与数据 Q 值。间隙趋于 0 且回报差，说明 α 太小；数据 Q 值远低于真实回报，说明 α 太大。
- IQL：V 损失与 Q 损失应同时下降；优势的尺度决定 AWR 权重，必要时截断 $\exp(A/\lambda)$。
- 多种子：PointMass 的回报是“到达/未到达”的混合，三个种子的方差很大，要报告逐种子结果 [Agarwal et al., 2021]。
- 区分 offline 与 offline-to-online：缓冲区是否在利用阶段继续增长。

7 追问清单

1. 为什么同样的 CQL 在 RND 数据上更好？如果给随机探索 10 倍步数呢？
2. 离散动作 CQL 的正则与 softmax 交叉熵有什么关系？（$\log \sum e^{Q} - Q(s,a)$ 正是以 Q 为 logits 的交叉熵。）
3. $\alpha = 0$ 的 CQL 与行为克隆谁更好？在什么数据上？
4. IQL 的 ζ 与 CQL 的 α 分别控制哪一类误差？
5. 如果允许在线微调，CQL 的保守价值会带来什么问题？[Nakamoto et al., 2023]
6. 为什么 RND 对 noisy TV 鲁棒？在什么环境里它仍然会失效？

参考文献

Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems*, 2021.

Gaon An, Seungyong Moon, Jang-Hyun Kim, and Hyun Oh Song. Uncertainty-based offline reinforcement learning with diversified Q-ensemble. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

Marc G. Bellemare, Sriram Srinivasan, Georg Ostrovski, Tom Schaul, David Saxton, and Remi Munos. Unifying count-based exploration and intrinsic motivation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2016.

Yuri Burda, Harrison Edwards, Amos Storkey, and Oleg Klimov. Exploration by random network distillation. In *International Conference on Learning Representations (ICLR)*, 2019.

Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, 2019.

Divyansh Garg, Joey Hejna, Matthieu Geist, and Stefano Ermon. Extreme Q-learning: Maxent RL without entropy. In *International Conference on Learning Representations*, 2023.

Elad Hazan, Sham M. Kakade, Karan Singh, and Abby Van Soest. Provably efficient maximum entropy exploration. In *International Conference on Machine Learning (ICML)*, 2019.

Ying Jin, Zhuoran Yang, and Zhaoran Wang. Is pessimism provably efficient for offline RL? In *International Conference on Machine Learning (ICML)*, 2021.

Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.

Aviral Kumar, Justin Fu, Matthew Soh, George Tucker, and Sergey Levine. Stabilizing off-policy Q-learning via bootstrapping error reduction. In *Advances in Neural Information Processing Systems*, 2019.

Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Aviral Kumar, Joey Hong, Anikait Singh, and Sergey Levine. When should we prefer offline reinforcement learning over behavioral cloning? In *International Conference on Learning Representations (ICLR)*, 2022.

Michael Laskin, Denis Yarats, Hao Liu, Kimin Lee, Albert Zhan, Kevin Lu, Catherine Cang, Lerrel Pinto, and Pieter Abbeel. URLB: Unsupervised reinforcement learning benchmark. In *NeurIPS Datasets and Benchmarks Track*, 2021.

Seunghyun Lee, Younggyo Seo, Kimin Lee, Pieter Abbeel, and Jinwoo Shin. Offline-to-online reinforcement learning via balanced replay and pessimistic Q-ensemble. In *Conference on Robot Learning (CoRL)*, 2022.

Jiafei Lyu, Xiaoteng Ma, Xiu Li, and Zongqing Lu. Mildly conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. AWAC: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.

Mitsuhiko Nakamoto, Simon Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-QL: Calibrated offline RL pre-training for efficient online fine-tuning. In *Advances in Neural Information Processing Systems*, 2023.

Whitney K. Newey and James L. Powell. Asymmetric least squares estimation and testing. volume 55, pages 819–847, 1987.

Deepak Pathak, Pulkit Agrawal, Alexei A. Efros, and Trevor Darrell. Curiosity-driven exploration by self-supervised prediction. In *International Conference on Machine Learning (ICML)*, 2017.

Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. In *arXiv preprint arXiv:1910.00177*, 2019.

Paria Rashidinejad, Banghua Zhu, Cong Ma, Jiantao Jiao, and Stuart Russell. Bridging offline reinforcement learning and imitation learning: A tale of pes-

simism. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

Kajetan Schweighofer, Marius-Constantin Dinu, Andreas Radler, Markus Hofmarcher, Vihang Prakash Patil, Angela Bitto-Nemling, Hamid Eghbal-zadeh, and Sepp Hochreiter. A dataset perspective on offline reinforcement learning. In *Conference on Lifelong Learning Agents (CoLLAs)*, 2022.

Haoran Tang, Rein Houthooft, Davis Foote, Adam Stooke, Xi Chen, Yan Duan, John Schulman, Filip De Turck, and Pieter Abbeel. #exploration: A study of count-based exploration for deep reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

Haoran Xu, Li Jiang, Jianxiong Li, Zhuoran Yang, Zhaoran Wang, Victor Wai Kin Chan, and Xianyuan Zhan. Offline RL with no OOD actions: In-sample learning via implicit value regularization. In *International Conference on Learning Representations (ICLR)*, 2023.

Denis Yarats, David Brandfonbrener, Hao Liu, Michael Laskin, Pieter Abbeel, Alessandro Lazaric, and Lerrel Pinto. Don't change the algorithm, change the data: Exploratory data for offline reinforcement learning. *arXiv preprint arXiv:2201.13425*, 2022.