稀疏奖励下的目标重标注与解耦元探索：HER、RL^2 与 DREAM

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文完成 CS224R 2025 Homework 4 的两部分。第一部分在 goal-conditioned DQN 上实现 Hindsight Experience Replay（HER）的 `final`、`future`、`random` 三种重标注，并在 bit flipping（$n = 6, 15, 25$）与 MuJoCo Sawyer Reach 上与无重标注的基线比较。15 位与 25 位任务上，无 HER 的成功率在全部 5 个种子上都是 0，三种 HER 都是 1.0；Sawyer 的稠密奖励让基线也能达到 0.55 ± 0.11，HER 提到 0.95–0.99。第二部分实现 DREAM 的解码器损失与信息增益奖励。网格公交任务上，DREAM 的元测试回报为 0.696 ± 0.007（5 个种子），等于我们推导的最优值 0.7；RL^2 为 0.143 ± 0.073，接近直接步行的 0.1。额外实验包括重标注比例 k 的扫描、Sawyer 上的 `future`/`random`，以及去掉每步探索惩罚 c 的 DREAM 消融。

关键词： Goal-Conditioned RL；HER；Sparse Reward；Meta-RL；RL^2；DREAM

1 问题

Goal-conditioned RL 在每个 episode 采样目标 g，奖励 $r(s, a, g)$ 只在到达 g 时不同于失败 [Kaelbling, 1993, Schaul et al., 2015]。bit flipping 的状态与目标都是 n 位二进制串，动作翻转一位，奖励在 $s = g$ 时为 0、否则为 -1，episode 长度为 n。随机初始化的 Q 网络几乎不会碰到 $r = 0$，DQN 的所有 TD 目标都是常数，学不到动作偏好 [Andrychowicz et al., 2017]。Sawyer Reach 是机械臂末端在平面内到达目标点，动作离散为四个方向，奖励为 $-\|x - g\|$[Nair et al., 2018, Todorov et al., 2012]。

Meta-RL 部分是 5×5 网格：智能体从中心出发，目标是四个角之一；中心四周有四个公交站，乘车会被传送到某个角，24 个任务只在公交目的地的排列上不同；右侧中间的地图格子会显示当前任务 ID[Liu et al., 2021]。每次元测试有一个探索 episode 和一个利用 episode，只计利用 episode 的回报。

2 方法

2.1 Goal-conditioned DQN 与 HER

Q 网络输入 $[s; g]$，输出各动作的 Q 值；采样时取 greedy 动作。DQN 每个 epoch 采集 16 条轨迹，做 40 次批大小 128 的更新，$\gamma = 0.98$，目标网络每个 epoch 同步一次，TD 目标截断到 $[-1/(1-\gamma), 0]$[Mnih et al., 2015]。

`update_replay_buffer` 先写入原转移 $(s_t, a_t, r_t, s_{t+1}, g)$，再为每个时间步生成 $k = 4$ 条重标注转移（`final` 只生成一条）：

- `final`：$g' = s_T$，即最后一个 `next_state`；
- `future`：$g' = s_{j+1}$，$j \sim \mathcal{U}\{t, \dots, T-1\}$；
- `random`：$g' = s_{j+1}$，$j \sim \mathcal{U}\{0, \dots, T-1\}$。

奖励由环境的奖励函数 $r(s_{t+1}, g')$ 重算，数组全部 `copy()`。我们为 `main.py` 增加了 `--num_relabeled`，用于扫描 k。

2.2 DREAM

解码器 $q_\omega(z \mid \tau) = \mathcal{N}(g_\omega(\tau), I)$，最大化 $\mathbb{E}[\log q_\omega(z \mid \tau^{\text{exp}})]$ 等价于最小化

$$\mathcal{L}_{\text{dec}} = \mathbb{E}\big\| g_\omega(\tau^{\text{exp}}) - \text{sg}(z) \big\|_2^2. \tag{1}$$

实现上对 `all_decoder_embeddings` 的每个前缀计算与 `stop_gradient`(z) 的平方距离，沿嵌入维求和、沿时间与 batch 取平均。探索奖励是相邻前缀的信息增益

$$r_t^{\text{exp}} = \|g(\tau_{:t}) - z\|^2 - \|g(\tau_{:t+1}) - z\|^2, \tag{2}$$

即距离序列的差分 `distances[:, :-1] - distances[:, 1:]`。starter 再从每步奖励中减去常数 $c = 0.1$（论文式 (5)），使探索策略在不再获得信息时倾向于结束 episode [Liu et al., 2021]。编码器 $F_\psi(z \mid \mu)$ 另有信息瓶颈项 $\max(\|z\|^2, 10)$，配合编码噪声限制 z 携带的信息量 [Alemi et al., 2017]。

2.3 实验设置

bit flipping 按作业的 epoch 数（250/500/1000）运行，6 位 3 个种子，15、25 位 5 个种子；Sawyer 运行

1000 个 epoch、5 个种子，四种重标注都跑。k 扫描在 15 位 `future` 上取 $k \in \{1, 2, 8\}$，各 3 个种子，$k = 4$ 复用主实验。DREAM 与 RL^2 各 5 个种子，$c = 0$ 的 DREAM 3 个种子。最终成功率取每个种子最后 10（bit flipping）或 20（Sawyer）个记录点的均值，再报告跨种子的均值与标准差。全部运行在 CPU 上并行完成，曲线由 TensorBoard 事件文件导出为 CSV 后统一绘制。

3 Problem 0：网格任务的最优回报

中心 $(2, 2)$ 到任一角的曼哈顿距离为 4。

(a) 直接步行：前三步各得 -0.3，第四步到达得 $+1$，回报 $1 - 0.9 = 0.1$。

(b) 已知公交目的地时，走一步到通往目标角的公交站（四个站都与中心相邻），再乘车直达目标：$-0.3 + 1 = 0.7$，这是单个利用 episode 的最优回报。

(c) 地图在 $(4, 2)$，距中心两步。最快的探索是直接走到地图格子读出任务 ID，共 2 步；之后的动作不再提供信息。

(d) 探索 episode 的回报不计入目标，因此元 RL 智能体的最优利用回报就是 0.7。

4 HER on bit flipping

表 1: bit flipping 的最终成功率与首次达到 0.9 的 epoch（滑动平均）。

	$n = 6$	$n = 15$	$n = 25$
no hindsight	0.90 ± 0.14 / 245	0.00 / –	0.00 / –
final	1.00 / 40	1.00 / 100	1.00 / 320
random	1.00 / 35	1.00 / 100	1.00 / 290
future	1.00 / 35	1.00 / 90	1.00 / 300

图 1 与表 1 对应作业的 (a)–(d)。$n = 6$ 时状态空间只有 64 个目标，随机初始化的 greedy 策略偶尔能在 6 步内命中，无 HER 的 DQN 能学，但三个种子里有一个只到 0.69，达到 0.9 要到第 245 个 epoch；HER 在 35–40 个 epoch 内就达到 0.9。$n = 15$ 与 $n = 25$ 时，随机命中的概率约为 2^{-n} 量级，回放缓冲区里没有任何 $r = 0$ 的转移，Q 函数没有可区分动作的信号，无 HER 的成功率在全部种子上都是 0。HER 把每条失败轨迹变成若干条到达“它自己经过的状态”的成功示范，正样本比例与 n 无关，因此 25 位任务也能学会，只是收敛所需的 epoch 随 n 增长（90–100 到 290–320）：目标空间更大，Q 网络需要更多样本才能泛化到任务目标。

三种重标注最终都达到 1.0。`future` 在 15 位上略快（90 对 100），`random` 在 25 位上略快（290 对 300、320），差距都在一个记录间隔左右。bit flipping 是可逆的：任何经过的状态，无论在 t 之前还是之后，都能从 s_t 翻回去，所以 `random` 不会产生不可达目标；而 `final` 虽然每条轨迹只给一个新目标，在短 episode（长度为 n）上已经足够。在不可逆或长 horizon 的环境里，`future` 的可达性保证才会显出优势 [Andrychowicz et al., 2017, Plappert et al., 2018]。

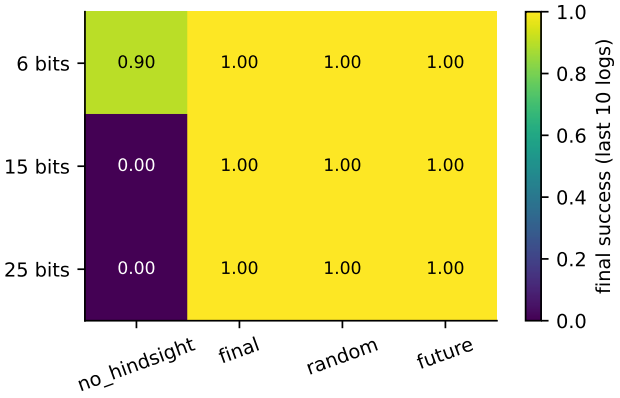


图 2: 最终成功率热图：行为位数，列为重标注策略。

重标注比例 k。 图 3 在 15 位 `future` 上比较 $k = 1, 2, 4, 8$。四条曲线几乎重合，首次达到 0.9 的 epoch 为 90–95。在这个任务上，只要有重标注，正样本就已不再稀缺；瓶颈转为 Q 网络对新目标的泛化与每个 epoch 固定的 40 次更新，增加 k 并不能加快学习。

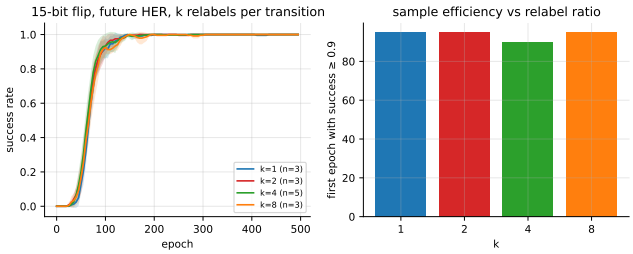


图 3: 15 位 `future` HER 中每条转移的重标注数 k。

5 HER on Sawyer Reach

图 4 中，无 HER 的成功率在 1000 个 epoch 后为 0.55 ± 0.11，仍在缓慢上升；`final` 为 0.95 ± 0.05，`future` 为 0.99 ± 0.01，`random` 为 0.99 ± 0.01。滑动成功率首次达到 0.8 的 epoch 分别为 `random` 335、`final` 495、`future` 550，无 HER 未达到。

与 bit flipping 的差别在奖励结构。Sawyer 的奖励 $-\|x - g\|$ 是稠密的：即使从未到达目标，每一步也告诉智能体离目标多远，DQN 能学到“朝目标移动”，所以

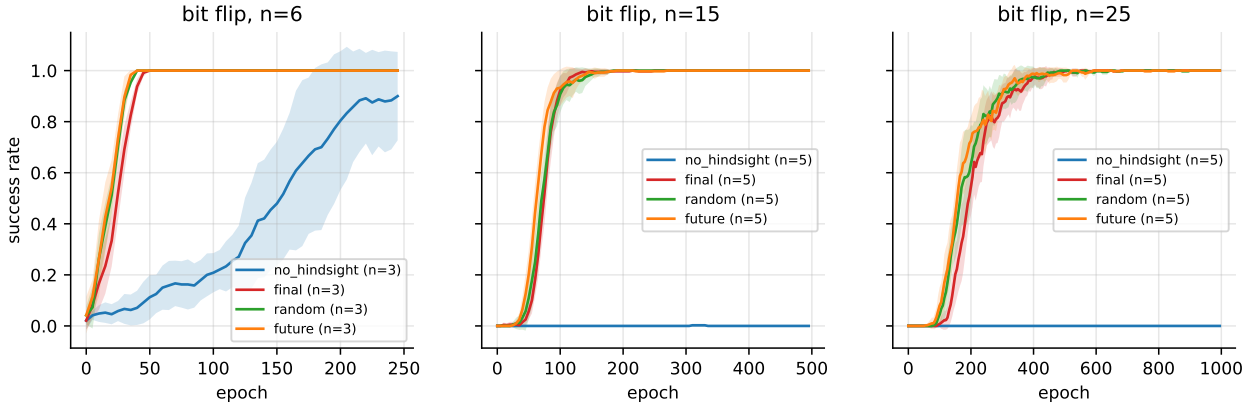


图 1: bit flipping 的评估成功率（均值 ± 标准差，阴影）。$n = 6$ 时无 HER 也能学会；$n = 15, 25$ 时无 HER 始终为 0，三种 HER 都收敛到 1。

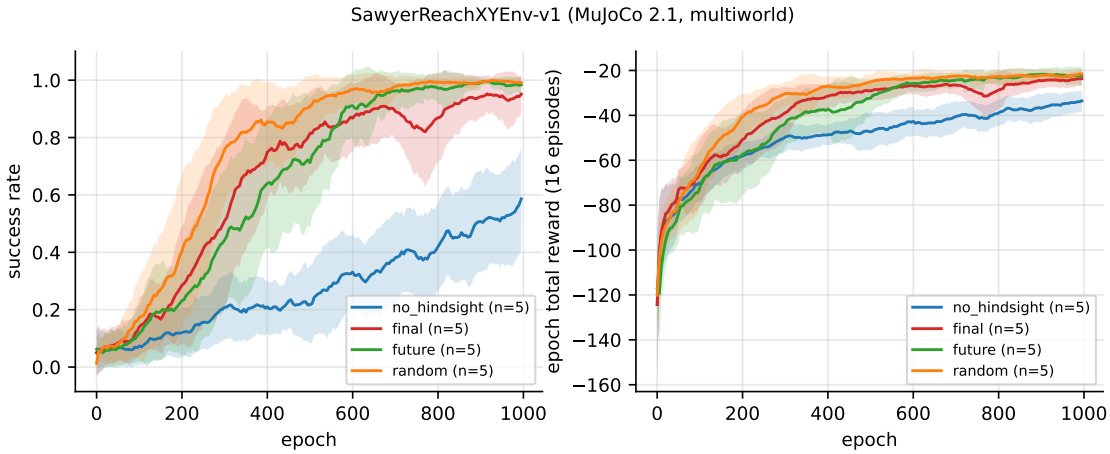


图 4: Sawyer Reach 的成功率与每个 epoch 的总奖励（5 个种子）。

基线不是 0。HER 在这里的作用是让每条轨迹在更多目标上提供监督，提高样本效率与末端精度，而不是像 bit flipping 那样从 0 到 1。总奖励曲线也反映这一点：四种方法的回报差距远小于成功率差距，因为成功只看最后是否落入阈值，而奖励在接近目标时已经很高。`final` 在第 700–800 个 epoch 有一次明显下滑，标准差也最大；只用末状态作目标，新目标集中在策略常去的区域，覆盖不如另外两种均匀。

6 Meta-RL

6.1 RL^2

RL^2 训练约 5×10^4 个元训练 trial 后，最后三次评估的元测试回报为 0.143 ± 0.073（5 个种子：$0.07, 0.16, 0.10, 0.28, 0.12$），保留一位小数约为 0.1，与直接步行的回报一致，远低于最优的 0.7。图 6 最下一行是一个种子在 52 000 个 trial 时的轨迹：智能体有时会走到地图附近，但利用阶段并没有稳定地选择通往目标的公交，大多数情况下仍在步行。RL^2 的测试 episode 长度维持在 13 步左右，说明探索段被用来游走，而不是用最短的 2 步读取地图。原因在于端到端优化的耦合：只有当利用策略已经会使用地图信息时，走到地图才有回报；而利用策略只有在探索收集到信息时才能学会使用它。训练早期两者都差，探索得不到梯度信号，策略停在“忽略任务信息、直接步行”的局部最优 [Duan et al., 2016, Liu et al., 2021]。少数种子在训练后期回报开始上升（0.28），说明这一局部最优可以逃离，但需要远多于 DREAM 的样本。

6.2 DREAM

DREAM 的回报在约 1.5×10^4 个 trial 后开始与 RL^2 分离，约 3×10^4 个 trial 后稳定在 0.7，最后三次评估为 0.696 ± 0.007，5 个种子里有 4 个恰为 0.70。这达到了 Problem 0 推导的最优值，符合预期：DREAM 用问题 ID 训练的编码器为探索提供了稠密的信息增益奖励，打破了探索与利用的鸡生蛋循环。解码误差从约 23 迅速降到 4 左右，不再归零，因为 z 带有编码器的噪声，且解码器在第一步之前无法知道任务。

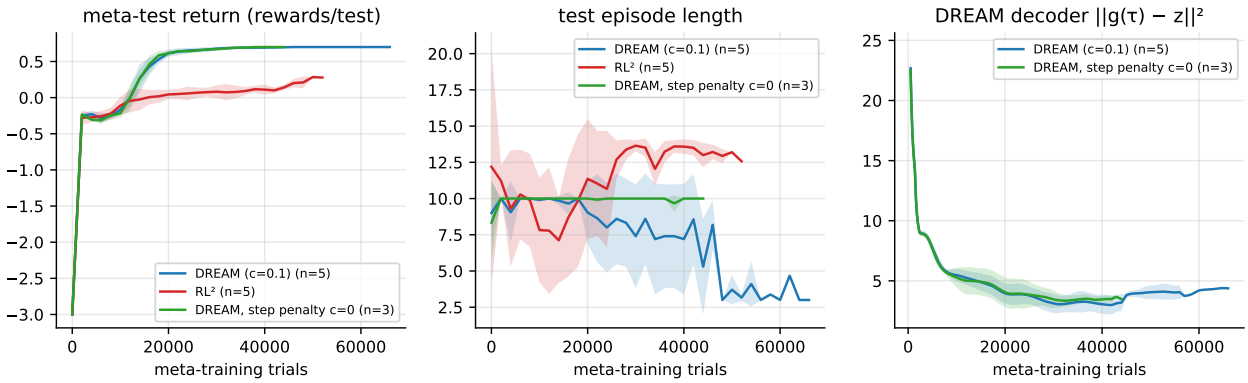


图 5: 左：元测试利用回报。中：DREAM 为探索 episode 长度，RL^2 为测试 episode 长度（RL^2 的探索与利用在同一条轨迹中）。右：DREAM 的解码误差。

图 6 第一行是 DREAM 在 56 000 个 trial 时的行为。探索 episode 中，智能体从中心向右走两格到达地图（黑色格子）后停止，episode 长度为 3 步，正是 Problem 0(c) 的最短探索。利用 episode 中，智能体走一步到通往目标角的公交站并乘车，两步到达目标，回报 0.7。

6.3 每步探索惩罚的消融

把探索奖励中的常数 c 设为 0 后，三个种子的元测试回报同样是 0.70，收敛速度与默认 DREAM 几乎相同（图 5 左）。差别出现在探索行为上：$c = 0$ 的探索 episode 长度始终在 10 步左右（9.9 ± 0.2），即用满上限；默认 $c = 0.1$ 的五个种子最终为 $8.4, 10, 3.6, 10, 3.0$，其中两个种子学会了“读完地图就结束”的 3 步探索。图 6 第二行显示，$c = 0$ 时智能体同样先到地图，但之后继续游走。走到地图那一步之后，解码器已经能恢复 z，后续每步的信息增益约为 0；$c = 0$ 时这些步没有代价，探索策略没有理由结束 episode，$c > 0$ 时它们的回报为 $-c$，最优行为是立即结束。由于本设定只计利用回报，探索长度不影响最终分数，c 的作用只体现在探索效率上；在探索步数本身有成本，或者需要多次探索 episode 的设定里，这一项才会改变回报 [Liu et al., 2021]。另有三个默认种子的探索仍接近 10 步，说明 $c = 0.1$ 带来的信号较弱，“提前结束”需要额外的训练才能被发现。

7 结论

HER 的收益随奖励稀疏程度增长：bit flipping 中它是能否学会的决定因素，Sawyer 的稠密奖励下它把成功率从 0.55 提到 0.95 以上。在可逆的 bit flipping 上，三种重标注策略与 $k \in \{1, 2, 4, 8\}$ 的差别都很小。Meta-RL 中，端到端的 RL^2 停在步行回报 0.1 附近，DREAM 借助问题 ID 解耦探索与利用，达到最优的 0.7；每步探索惩罚 c 在本任务中不改变最终回报，但让部分种子学到最短的探索轨迹。

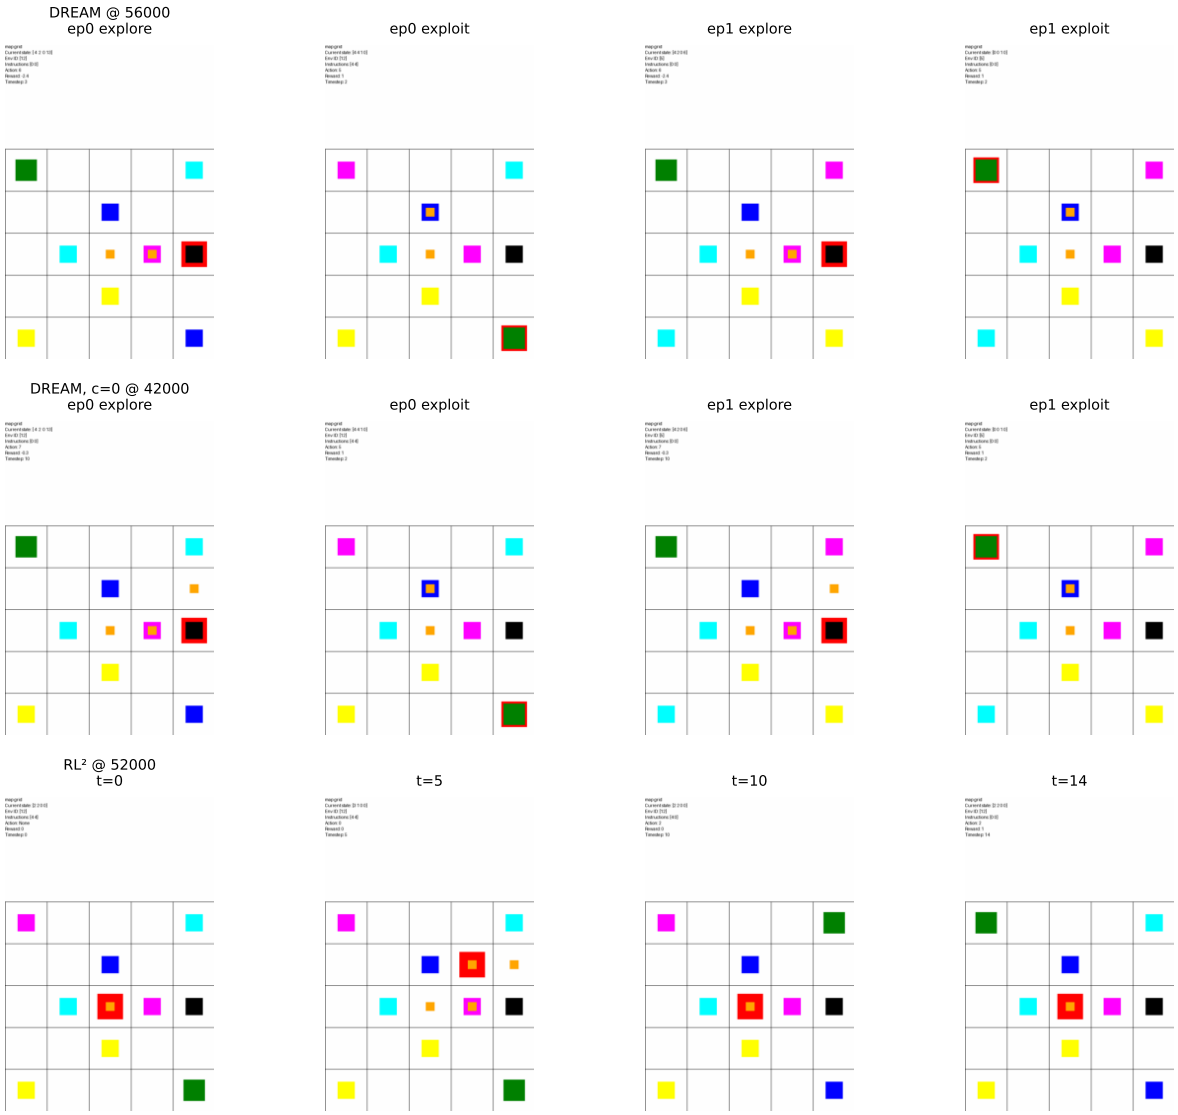


图 6: 元测试 rollout 的最后一帧。橙色小方块为本 episode 访问过的格子，黑色为地图，绿色为目标，红色为智能体。前两行为 DREAM 及其 $c = 0$ 消融的两个元测试 episode，最后一行为 RL^2 同一条轨迹的四个时刻。

参考文献

Alexander A. Alemi, Ian Fischer, Joshua V. Dillon, and Kevin Murphy. Deep variational information bottleneck. In *International Conference on Learning Representations (ICLR)*, 2017.

Marcin Andrychowicz, Filip Wolski, Alex Ray, Jonas Schneider, Rachel Fong, Peter Welinder, Bob McGrew, Josh Tobin, Pieter Abbeel, and Wojciech Zaremba. Hindsight experience replay. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

Yan Duan, John Schulman, Xi Chen, Peter L. Bartlett, Ilya Sutskever, and Pieter Abbeel. RL^2: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016.

Leslie Pack Kaelbling. Learning to achieve goals. In *International Joint Conference on Artificial Intelligence (IJCAI)*, 1993.

Evan Zheran Liu, Aditi Raghunathan, Percy Liang, and Chelsea Finn. Decoupling exploration and exploitation for meta-reinforcement learning without sacrifices. In *International Conference on Machine Learning (ICML)*, 2021.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.

Ashvin Nair, Vitchyr Pong, Murtaza Dalal, Shikhar Bahl, Steven Lin, and Sergey Levine. Visual reinforcement learning with imagined goals. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.

Matthias Plappert, Marcin Andrychowicz, Alex Ray, Bob McGrew, Bowen Baker, Glenn Powell, Jonas Schneider, Josh Tobin, Maciek Chociej, Peter Welinder, Vikash Kumar, and Wojciech Zaremba. Multi-goal reinforcement learning: Challenging robotics environments and request for research. *arXiv preprint arXiv:1802.09464*, 2018.

Tom Schaul, Daniel Horgan, Karol Gregor, and David Silver. Universal value function approximators. In *International Conference on Machine Learning (ICML)*, 2015.

Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2012.