Goal-Conditioned RL 与 Meta-RL 面试指南：从 HER 的重标注到 DREAM 的信息瓶颈

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文整理两类“条件化”强化学习在面试中的核心问题。Goal-conditioned RL 把目标 g 放进价值函数的输入，稀疏奖励下的关键是 hindsight relabeling：失败的轨迹对另一个目标是成功的示范。Meta-RL 把任务 μ 隐藏起来，策略必须先探索再利用；关键是探索怎样获得训练信号。我们以 CS224R 2025 Homework 4 的实测为线索：bit flipping 上 HER 把 15 与 25 位任务的成功率从 0 提到 1；Sawyer Reach 的稠密奖励让无 HER 的基线也能部分成功；网格公交任务上 RL^2 停在直接步行的回报 0.1 附近，DREAM 达到最优的 0.7。文中给出每个机制的损失、可检查的日志量和常见失败模式，并附一份追问清单。

关键词： UVFA；Hindsight Experience Replay；Relabeling；RL^2；DREAM；Information Bottleneck；Exploration

1 Goal-conditioned RL 的形式化

在 goal-conditioned MDP 中，奖励 $r(s,a,g)$ 依赖一个在每个 episode 开始时采样的目标 $g \sim p(g)$[Kaelbling, 1993]。策略与价值写成 $\pi(a \mid s,g)$、$Q(s,a,g)$，即 universal value function approximator（UVFA）[Schaul et al., 2015]。实现上最简单的做法是把 $[s;g]$ 拼成一个向量送进 Q 网络，本作业的 DQN 正是这样：bit flipping 的输入维度是 $2n$，输出 n 个翻转动作的 Q 值 [Mnih et al., 2015]。

为什么稀疏奖励难。 bit flipping 的奖励只有 0（到达）和 -1（未到达），episode 长度为 n。从均匀随机的起点出发，随机策略恰好命中目标的概率约为 2^{-n} 量级。$n=15$ 时，每个 epoch 16 条轨迹几乎从不出现 $r=0$，所有 TD 目标都是 $-1+\gamma \max Q$，Q 函数对动作完全没有偏好，greedy 策略不会改进。这不是函数近似能力的问题，而是数据里没有任何成功信号。追问常见的答案“加 ε-greedy”不能解决：探索的覆盖率仍是指数级稀疏。

2 Hindsight Experience Replay

HER 的观察是：一条没有到达 g 的轨迹，到达了它自己经过的状态 [Andrychowicz et al., 2017]。把转移 (s_t, a_t, s_{t+1}, g) 复制一份并把目标换成 $g' = \phi(\tau)$，奖励重算为 $r(s_{t+1}, g')$，就得到了成功的示范。由于 DQN 是 off-policy 的，重标注后的转移与原转移同样合法：Bellman 方程对每一个目标都成立，重标注只是改变了“在哪个目标上做备份”。

目标选择策略。 作业实现了三种：

- `final`：$g' = s_T$，每条轨迹只产生一个新目标；
- `future`：$g' = s_j$，$j \sim \mathcal{U}\{t+1, \dots, T\}$，保证 g' 从 s_t 出发可达；
- `random`：$g' = s_j$，j 在整条轨迹上均匀采样，包括过去的状态。

三者的差别在新目标的分布：`future` 的 g' 与 s_t 的距离较近且可达，产生大量短视距的正样本，原论文因此推荐它，并用 $k=4$ 的重标注比例 [Andrychowicz et al., 2017, Plappert et al., 2018]。`random` 会选到过去的状态，在 bit flipping 里过去状态依然可达（翻回去即可），所以不会产生不可达目标；在不可逆环境里它会产生虚假的不可达目标。`final` 每条轨迹只有一个目标，正样本较少，但在本任务上已经足够。我们的实测中三种 HER 在 6/15/25 位上最终成功率都接近 1，差别主要体现在收敛速度。

偏差。 HER 改变了训练目标的分布：$p(g')$ 由行为策略经过的状态决定，而不是任务的 $p(g)$。在确定性环境中 Bellman 方程对任意 g' 都正确，因此偏差只体现在“哪些目标学得更好”；在随机环境中，按结果重标注会让价值偏乐观，因为只保留了恰好到达 g' 的那次随机结果 [Eysenbach et al., 2020, Li et al., 2020]。面试中可以把它与 GCSL 对照：GCSL 直接对重标注轨迹做监督学习，不需要价值函数，但在随机环境里同样会学到偏乐观的策略 [Ghosh et al., 2021]。

重标注比例 k。 每条原始转移附带 k 条重标注转移，正样本比例随 k 增大。k 过大时，回放缓冲区几乎全是“自己经过的目标”，任务目标的样本占比过低；k

过小时，稀疏任务收敛慢。我们在 15 位任务上扫描了 $k \in \{1, 2, 4, 8\}$，见作业报告。

3 稠密奖励与 Sawyer Reach

Sawyer Reach 用 MuJoCo 2.1 仿真机械臂末端在平面内移动，作业把连续动作离散成 4 个方向 [Todorov et al., 2012, Nair et al., 2018]。奖励是 $-\|x - g\|$，成功阈值由环境给出。这是稠密奖励：每一步都告诉智能体离目标有多远，所以无 HER 的 DQN 也能学到“朝目标移动”。HER 在这里提供的是更多目标上的训练样本，提升的是样本效率和末端精度，而不是从零到一。这一对比是面试中的经典追问：*HER 的收益与奖励稀疏程度成正比*。稠密奖励的代价是需要设计距离度量；在图像观测上，RIG 用 VAE 的隐空间距离代替 [Nair et al., 2018]，TDM 则把“到目标的时间”当作价值 [Pong et al., 2018]。

4 Meta-RL：把任务当隐变量

Meta-RL 在任务分布 $p(\mu)$ 上训练，测试时面对未见过的 μ，需要在少量交互内适应 [Beck et al., 2023]。本作业是“一个探索 episode + 一个利用 episode”的设定：只计利用 episode 的回报，探索 episode 的回报无关紧要。最优解是先用探索 episode 获取识别任务所需的信息，再利用这些信息。

Black-box：RL^2。 RL^2 用一个 RNN 跨 episode 地接收 $(s_t, a_{t-1}, r_{t-1}, d_{t-1})$，隐状态在探索与利用 episode 之间不重置，目标是两段回报的总和 [Duan et al., 2016, Wang et al., 2016]。它的表达能力足以表示 Bayes 最优策略 [Zintgraf et al., 2020, Humplik et al., 2019]，但优化上有一个鸡生蛋问题：探索行为只有在利用策略已经会使用这些信息时才有回报；利用策略只有在探索收集到信息时才能学会使用。训练早期两者都很差，探索得不到任何梯度信号，于是收敛到“忽略任务信息、直接步行到目标”的局部最优。我们在网格任务上观察到的 RL^2 测试回报正好停在步行回报 0.1 附近。

Decoupled：DREAM。 DREAM 利用训练时可见的问题 ID μ 打破这个循环 [Liu et al., 2021]。

1. 利用策略 $\pi^{\text{task}}(a \mid s, z)$ 以编码 $z \sim F_\psi(z \mid \mu)$ 为条件训练。编码器上加信息瓶颈惩罚，使 z 只保留解决任务所需的信息（这里是公交目的地），而不是 μ 的全部比特 [Alemi et al., 2017]。
2. 探索策略最大化 $I(z; \tau^{\text{exp}})$ 的变分下界 $\mathbb{E}[\log q_\omega(z \mid \tau^{\text{exp}})]$[Barber and Agakov, 2003]。解码器取单位方差高斯时，$\log q$ 等于 $-\|g_\omega(\tau) - \text{sg}(z)\|^2$ 加常数。
3. 把下界按时间展开成望远镜和，每一步的内在奖励是信息增益 $r_t = \|g(\tau_{:t}) - z\|^2 - \|g(\tau_{:t+1}) - z\|^2$。

这样探索策略在训练一开始就有稠密的训练信号：走到地图格子的那一步，解码误差骤降，内在奖励为正。实现上要注意两点：解码器损失里的 z 必须 stop-gradient，否则编码器会把 z 推向解码器容易预测的平凡解；奖励的符号是“前一步误差减后一步误差”，写反会让探索策略主动回避信息。

信息瓶颈与每步惩罚。 去掉瓶颈后，z 可以把 24 个任务 ID 的全部信息编码进去，包括与当前目标无关的公交。探索策略被要求恢复这些冗余比特，目标变难；利用策略也可能依赖 ID 中的无关细节。作业的 starter 用 $\max(\|z\|^2, 10)$ 加编码噪声实现瓶颈。另一个容易混淆的超参是探索奖励中的每步惩罚 c（论文式 (5)，默认 0.1）：它不改变信息量，只让“不再获得信息的步”带负回报。我们把 c 设为 0 后，元测试回报仍为最优的 0.7，但探索 episode 总是用满 10 步；$c = 0.1$ 时有种子学会读完地图就结束（3 步）。面试时要能区分这两个旋钮各自控制什么。

5 与其他 meta-RL 方法的关系

MAML 在梯度空间做适应，探索依靠内循环的策略梯度噪声 [Finn et al., 2017]；E-MAML 与 MAESN 尝试把探索放进元目标 [Stadie et al., 2018, Gupta et al., 2018]。PEARL 用概率上下文变量做后验采样，探索相当于 Thompson sampling，在需要“先付出代价获取信息”的任务上不是最优的 [Rakelly et al., 2019]。VariBAD 学习任务后验的变分近似并在 belief 上做规划，与 DREAM 一样把任务推断显式化 [Zintgraf et al., 2020]。大规模的 black-box 路线（AdA）说明，只要任务分布与算力足够，RNN/Transformer 仍能学出人类时间尺度的适应 [Adaptive Agent Team et al., 2023]。

6 工程清单

- HER：重标注时 `copy()` 所有 numpy 数组；新目标取 `next_state`；奖励用环境的奖励函数重算，而不是复制原奖励。
- 记录正样本比例（$r = 0$ 的转移占比）与成功率；前者为 0 时任何超参都无效。
- DQN 的目标网络、$\gamma = 0.98$ 与有限 horizon：bit flipping 没有终止掩码，价值下界约为 $-1/(1-\gamma)$。
- DREAM：同时看解码损失与测试回报。解码损失下降而回报不升，说明利用策略没学会使用 z；回报上升而解码损失不降，说明利用策略在绕过 z。

- RL^2：检查测试 episode 长度。若与“直接步行”的步数一致，说明探索段被浪费。

7 追问清单

1. HER 为什么要求 off-policy 算法?能否用于 PPO?(需要重要性采样修正，或改用 GCSL 式的监督目标 [Ghosh et al., 2021]。)
2. `future` 与 `random` 在不可逆环境里有何差别?
3. 稠密奖励下 HER 还有用吗？收益来自哪里?
4. RL^2 为什么能表示 Bayes 最优策略，却学不到?
5. DREAM 的内在奖励为什么是信息增益而不是“解码误差的负值”？两者的累计和有何不同?
6. 训练时没有问题 ID 时，DREAM 还能用吗？(可以用任务的奖励/动力学特征代替，或退化为 VariBAD 式的后验推断。)
7. 信息瓶颈的系数过大或过小分别会怎样? 它和每步惩罚 c 有什么区别?

参考文献

Adaptive Agent Team, Jakob Bauer, et al. Human-timescale adaptation in an open-ended task space. In *International Conference on Machine Learning (ICML)*, 2023.

Alexander A. Alemi, Ian Fischer, Joshua V. Dillon, and Kevin Murphy. Deep variational information bottleneck. In *International Conference on Learning Representations (ICLR)*, 2017.

Marcin Andrychowicz, Filip Wolski, Alex Ray, Jonas Schneider, Rachel Fong, Peter Welinder, Bob McGrew, Josh Tobin, Pieter Abbeel, and Wojciech Zaremba. Hindsight experience replay. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

David Barber and Felix Agakov. The IM algorithm: A variational approach to information maximization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2003.

Jacob Beck, Risto Vuorio, Evan Zheran Liu, Zheng Xiong, Luisa Zintgraf, Chelsea Finn, and Shimon Whiteson. A survey of meta-reinforcement learning. *arXiv preprint arXiv:2301.08028*, 2023.

Yan Duan, John Schulman, Xi Chen, Peter L. Bartlett, Ilya Sutskever, and Pieter Abbeel. RL^2: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016.

Benjamin Eysenbach, Xinyang Geng, Sergey Levine, and Ruslan Salakhutdinov. Rewriting history with inverse RL: Hindsight inference for policy improvement. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning (ICML)*, 2017.

Dibya Ghosh, Abhishek Gupta, Ashwin Reddy, Justin Fu, Coline Devin, Benjamin Eysenbach, and Sergey Levine. Learning to reach goals via iterated supervised learning. In *International Conference on Learning Representations (ICLR)*, 2021.

Abhishek Gupta, Russell Mendonca, YuXuan Liu, Pieter Abbeel, and Sergey Levine. Meta-reinforcement learning of structured exploration strategies. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.

Jan Humplik, Alexandre Galashov, Leonard Hasenclever, Pedro A. Ortega, Yee Whye Teh, and Nicolas Heess. Meta reinforcement learning as task inference. In *arXiv preprint arXiv:1905.06424*, 2019.

Leslie Pack Kaelbling. Learning to achieve goals. In *International Joint Conference on Artificial Intelligence (IJCAI)*, 1993.

Alexander C. Li, Lerrel Pinto, and Pieter Abbeel. Generalized hindsight for reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

Evan Zheran Liu, Aditi Raghunathan, Percy Liang, and Chelsea Finn. Decoupling exploration and exploitation for meta-reinforcement learning without sacrifices. In *International Conference on Machine Learning (ICML)*, 2021.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.

Ashvin Nair, Vitchyr Pong, Murtaza Dalal, Shikhar Bahl, Steven Lin, and Sergey Levine. Visual reinforcement learning with imagined goals. In *Advances*

in Neural Information Processing Systems (NeurIPS), 2018.

Matthias Plappert, Marcin Andrychowicz, Alex Ray, Bob McGrew, Bowen Baker, Glenn Powell, Jonas Schneider, Josh Tobin, Maciek Chociej, Peter Welinder, Vikash Kumar, and Wojciech Zaremba. Multi-goal reinforcement learning: Challenging robotics environments and request for research. *arXiv preprint arXiv:1802.09464*, 2018.

Vitchyr Pong, Shixiang Gu, Murtaza Dalal, and Sergey Levine. Temporal difference models: Model-free deep RL for model-based control. In *International Conference on Learning Representations (ICLR)*, 2018.

Kate Rakelly, Aurick Zhou, Deirdre Quillen, Chelsea Finn, and Sergey Levine. Efficient off-policy meta-reinforcement learning via probabilistic context variables. In *International Conference on Machine Learning (ICML)*, 2019.

Tom Schaul, Daniel Horgan, Karol Gregor, and David Silver. Universal value function approximators. In *International Conference on Machine Learning (ICML)*, 2015.

Bradly C. Stadie, Ge Yang, Rein Houthooft, Xi Chen, Yan Duan, Yuhuai Wu, Pieter Abbeel, and Ilya Sutskever. Some considerations on learning to explore via meta-reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.

Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2012.

Jane X. Wang, Zeb Kurth-Nelson, Dhruva Tirumala, Hubert Soyer, Joel Z. Leibo, Remi Munos, Charles Blundell, Dharshan Kumaran, and Matt Botvinick. Learning to reinforcement learn. *arXiv preprint arXiv:1611.05763*, 2016.

Luisa Zintgraf, Kyriacos Shiarlis, Maximilian Igl, Sebastian Schulze, Yarin Gal, Katja Hofmann, and Shimon Whiteson. VariBAD: A very good method for Bayes-adaptive deep RL via meta-learning. In *International Conference on Learning Representations (ICLR)*, 2020.