推理模型后训练面试指南：从可验证奖励到 SFT、DPO/IPO 与 RLOO

ShaneLiu04

https://github.com/ShaneLiu04

摘要

推理岗位的面试把一条后训练管线拆成可以当场写下来的几段：奖励从哪来，监督微调改的是哪一部分 token，偏好损失在参考策略处等于什么，策略梯度的基线为什么必须在组内计算，以及 pass@k 和准确率差在哪里。本文按这个顺序整理 InstructGPT 式的 RLHF、DPO、IPO、REINFORCE、RLOO、GRPO 和过程奖励，并用 Countdown 上 Qwen2.5-0.5B 的实测说明每个机制在日志里长什么样。基座 pass@1 为 0.000，SFT 之后为 0.188。IPO 在参考策略处的损失是 25.0，与 $(1/(2\beta))^2$ 一致。短程 RLOO 的在线精确率均值是 0.156，两个种子的测试 pass@8 分别是 0.480 和 0.360。这些数字用来约束回答：没有稳定增益时，不把算法说成已经超过 SFT。

关 键 词： RLHF；DPO；IPO；RLOO；GRPO；pass@k；Verifier；Process Reward

1 面试要回答的对象

研究岗位和工程岗位问的是同一条链路的两端。研究侧关心目标函数是否在优化想要的量：偏好模型会不会把概率质量推到人类没比较过的回答上，组内基线是不是无偏，pass@k 上升时 pass@1 是否下降。工程侧关心同一条链路能不能跑完：回答掩码有没有把提示算进损失，参考模型是不是冻结的，梯度裁剪阈值 0 会不会把更新清掉，停止符的 token 编号和模型实际生成的编号是否相同。

Countdown 把这条链路收成一个可以手算的环境。数字和目标值是给定的，奖励由程序计算。因此可以把“奖励模型不准”和“策略梯度没有信号”分开。下面的每一节都先给定义和文献中的形式，再给本实验里对应的日志。

2 可验证奖励

人类偏好把回答映射到一个标量，再用来训练奖励模型 [Christiano et al., 2017, Ziegler et al., 2019, Stiennon et al., 2020, Ouyang et al., 2022]。奖励模型是一个有误差的函数。它在比较过的回答对上拟合，在分布外的长回答上可以给出人类不会给的高分。这是 RLHF 被反复讨论的失效方式 [Casper et al., 2023, Zheng et al., 2023]。

数学和代码题可以绕开这个拟合。一个 verifier 执行模型给出的最终答案，或者执行中间步骤，返回对或错 [Cobbe et al., 2021, Uesato et al., 2022, Lightman et al., 2023]。结果奖励只看最后的答案。过程奖励给正确的中间步骤更高的分。Lightman 等人在 MATH 上比较二者，过程监督在搜索时更省样本。Uesato 等人指出，结果监督已经能抬高最终正确率，过程监督的优势更集中在需要定位错误步骤的时候。

Countdown 的奖励是三档结果分，不是逐步分。没有 `<answer>` 为 0，提取到等式但数字用错或结果不对为 0.1，用恰好给定的数字得到目标值为 1。0.1 这一档很重要。它把“会写标签”和“等式算对”拆开。SFT 之后几乎所有样本都落到 0.1 或 1，组内优势就来自这两档之差。若奖励只有 0/1，而模型还不会写标签，一组样本全是 0，优势也是 0。

面试里可以把奖励设计说成三句话。第一，奖励必须在策略当前会访问的字符串上有方差。第二，格式分和正确分要分开记录，否则损失下降可能只是学会了标签。第三，verifier 的抽取规则要和训练时的停止符一致。答案标签后面的垃圾 token 如果还留在损失里，序列级优势会记到它们头上。

3 SFT 与冷启动

SFT 是回答 token 上的因果语言模型负对数似然。位置 t 的目标由 logits 的第 $t-1$ 位预测。提示用左填充，回答用右填充，掩码是“回答且非 padding”再右移一位。把提示算进损失会让模型复读题目，回答分布几乎不动。

InstructGPT 把 SFT 放在奖励模型和 PPO 之前，演示数据决定了策略的初始支撑 [Ouyang et al., 2022]。Gandhi 等人把推理的冷启动说成几种可迁移的行为：验证、回溯、子目标、逆向。没有这些行为的 SFT 轨迹，后面的强化学习缺少可强化的模式 [Gandhi et al., 2025]。DeepSeek-R1 的实验也把这件事写清楚：从基座直接做

可验证奖励的强化学习可以长出长链推理，但那是在大模型和长训练上观察到的，小模型的短跑不能默认有同样的现象 [DeepSeek-AI, 2025]。

本实验的 SFT 目标是搜索器找到的一行等式，外面包上 `<think>` 和 `<answer>`。19 000 条训练样本上，损失从 1.480 降到 0.078，留出负对数似然 0.067。基座 pass@1 为 0.000，SFT 为 0.188，pass@8 为 0.475。这个提升来自格式和“用全数字写一条等式”，不是来自长的搜索痕迹。面试时要主动说出目标分布是什么。短等式的 SFT 不能被描述成已经学会了 Cognitive Behaviors 里的回溯。

另一个工程细节是模板套几次。Countdown 的提示已经含有 `<|im_start|>`。再套一次 chat 模板会把特殊符号嵌进文本。偏好数据的 `query` 还没有模板，那里又必须套。同一套数据加载不能用一个布尔值打完全部阶段。

4 从 RLHF 到 DPO

经典 RLHF 先在偏好对上训练奖励模型 $r_\phi(x, y)$，再用 PPO 优化 $\mathbb{E}[r_\phi] - \beta\,\mathrm{KL}(\pi\|\pi_{\text{ref}})$ [Ouyang et al., 2022, Schulman et al., 2017, Zheng et al., 2023]。KL 项把策略留在参考模型附近，参考模型通常是 SFT。PPO 需要价值网络或广义优势估计 [Schulman et al., 2015]，对语言模型来说还要处理变长序列、裁剪和奖励归一化。工程上这是一整条分布式系统 [Zheng et al., 2023]。

DPO 从同一个 KL 约束的最优策略出发，把奖励写成策略与参考策略的对数比，再代入 Bradley–Terry 模型，得到只含 π_θ 和 π_{ref} 的分类损失 [Rafailov et al., 2023]：

$$L_{\text{DPO}} = -\log \sigma\big(\beta(\Delta_w - \Delta_l)\big), \tag{1}$$

$\Delta(y) = \log \pi_\theta(y \mid x) - \log \pi_{\text{ref}}(y \mid x)$。没有单独的奖励模型和在线采样。代价是：策略只能在离线对里已经出现的回答之间重新分配质量。对里没有的正确等式，DPO 不会去搜索。

在 $\Delta = 0$ 时 $L_{\text{DPO}} = \log 2$。本实验第一步损失是 0.693，与 $\log 2 \approx 0.693$ 一致。验证偏好准确率是 0.566。准确率接近一半，说明 chosen 的对数比并没有稳定地高于 rejected。这时不要把 pass@1 的小幅变化解释成偏好优化已经对齐了 verifier。

DPO 的已知问题包括：损失可以在降低分类误差的同时把 chosen 和 rejected 的绝对概率一起压低。面试里用 Δ_w 和 Δ_l 两条曲线分开看，而不是只看 loss。若两者一起变负，分类间隔可能仍在变大，但模型对两条回答都更不确定。

5 IPO 的平方间隔

Azar 等人把一类偏好目标写成 Ψ-preference optimization，并指出 Bradley–Terry 假设下的一些目标会过度移动概率 [Azar et al., 2024]。IPO 用平方损失把间隔固定住：

$$L_{\text{IPO}} = \big(\Delta_w - \Delta_l - 1/(2\beta)\big)^2. \tag{2}$$

β 越小，目标间隔 $1/(2\beta)$ 越大，策略被要求把 chosen 与 rejected 拉得更开，也更容易不稳定。$\pi = \pi_{\text{ref}}$ 时损失是 $(1/(2\beta))^2$。$\beta = 0.1$ 时这个数是 25。本实验的第一步就是 25.0。这是实现测试，不是训练效果。

求和的 Δ 随回答长度增长。一两百个 token 的对数概率之和，移动几个 nat 就会让平方损失从 25 跳到验证集上的 31.07，准确率 0.500。长度平均把同一目标间隔放在 token 均值上，验证损失回到 25.01，贴着恒等线。稳定不等于学到了偏好。它只说明优化没有炸。

面试时可以这样区分 DPO 和 IPO。DPO 的梯度在间隔已经很大时饱和，因为 logistic 的尾部平坦。IPO 的梯度随间隔误差线性增长，没有饱和，所以对 Δ 的尺度更敏感，也更需要决定“和”还是“平均”。两者都依赖一个冻结的参考模型。参考模型若被错误地更新，或和策略不是同一套模板下的对数概率，Δ 没有意义。

6 REINFORCE、RLOO 与 GRPO

REINFORCE 的梯度是 $\mathbb{E}[\nabla \log \pi(a)\,(r - b)]$，$b$ 不依赖当前这条样本的动作时，它不改变梯度的期望，只改变方差 [Williams, 1992]。b 若用到了本条样本的奖励，估计就有偏，除非像 leave-one-out 那样把本条从基线里拿掉。

Kool 等人对 K 条独立样本使用 [Kool et al., 2019]

$$\hat{A}_i = r_i - \frac{1}{K-1}\sum_{j \neq i} r_j. \tag{3}$$

$K = 2$ 时基线就是另一条样本的奖励，方差大。K 增大时基线更接近组内均值，但每步要生成更多条。Ahmadian 等人把这个估计用回语言模型的 RLHF，发现在他们的设置里 RLOO 可以匹配更复杂的 PPO，而实现只保留策略网络 [Ahmadian et al., 2024]。

GRPO 是同一想法的另一个归一化 [Shao et al., 2024, DeepSeek-AI, 2025]。组内奖励减去均值再除以标准差，然后沿 token 做裁剪的策略梯度，并带 KL。RLOO 不除以标准差，也不把本条奖励放进基线。组内奖励全相等时，两者的优势都是 0。这是健康的行为，不是 bug。日志里这一步的策略损失应为 0。

在线 RLOO 让行为策略等于当前策略，temperature 和 top-p 都是 1，重要性权重为 1。若评估用 temperature 0.6，那是另一个分布，不能把评估 pass@k 当成训练奖励的无偏估计。本实验的在线精确率均值是 0.156，奖励均值是 0.241。测试 pass@1 在两个种子上是 0.253 和 0.223，pass@8 是 0.480 和 0.360。$K = 2$ 的 pass@8 是 0.380。无 KL 的 pass@8 是 0.520。修正停止符后的四十步 pass@1 是 0.217，一百二十步是 0.245，pass@8 是 0.340。短预算下种子之间的 pass@8 差距已经大于多数算法之间的差距。回答 “RLOO 是否优于 SFT” 时，要把预算和种子说出来。

PPO 的裁剪是在重要性权重上 [Schulman et al., 2017]。on-policy 且权重为 1 时，裁剪区间不改变这一步的比值。它会在后面变成 off-policy、或者复用旧样本时才起作用。把裁剪系数设成 0 却调用 `clip_grad_norm_(parameters, 0)`，会把全部梯度变成 0。梯度范数阈值和 PPO 的 ratio clip 是两个开关。

7 pass@k

准确率是每个提示一条贪心或低温回答对不对。pass@k 是从 n 条采样里不放回地抽 k 条、至少一条正确的概率。无偏估计是 $1 - \binom{n-c}{k} / \binom{n}{k}$，要求 $n \geq k$，c 是正确条数 [Chen et al., 2021]。$n = k$ 时，这个估计退化成 “n 条里有没有一条正确”，方差是伯努利方差。n 比 k 大很多时方差更小。本实验的 SFT 用 $n = 16$，其他检查点用 $n = 8$，所以 pass@8 可以比较期望，不能比较单个检查点的噪声水平。

pass@1 上升而 pass@8 不上升，表示单样本更常命中，多次采样的覆盖没有变好。推理模型的产品指标经常是 pass@1，因为用户只看一条。研究指标经常是 pass@k，因为搜索或自洽可以再用这 k 条 [Lightman et al., 2023, DeepSeek-AI, 2025]。面试里先问清楚部署时看几条，再决定优化哪一个。

Rejection sampling fine-tuning 和 RAFT 走另一条路：多采样，只把奖励高的回答拿去做 SFT[Dong et al., 2023]。它没有优势基线，也不会给低奖励样本负梯度。在格式已经学会、正确样本仍稀少时，它和 RLOO 的差别是：RLOO 会压低组内较差的样本，RAFT 只强化较好的样本。两者都需要 verifier 在采样时就能打分。

8 KL、熵与长度

$\mathrm{KL}(\pi \| \pi_{\mathrm{ref}})$ 惩罚离开 SFT 或初始策略的 token 分布。系数过大时，在线奖励上不去。系数为零时，策略可以走到参考模型没有覆盖的字符串，其中包括答案标签之后的特殊符号循环。熵奖励鼓励词表上不要过早塌缩。系数 0.001 相对序列对数概率是一个小项。本实验里去掉这两项之后，pass@8 并没有变差，见无 KL 的 0.520。四十步还看不出正则项的长期作用。

长度是另一个隐蔽的奖励。若优势加在整个序列的对数概率上，更长的错误回答会收到更多 token 的梯度。格式奖励 0.1 又让 “写很长但算错” 和 “写短但算错” 得到相同的序列奖励。停止在 `</answer>` 上，是在定义回合的边界。本实验里 `</answer>` 有两种 BPE：不带空格是 `</+answer+>`，带前导空格是另一个起始 token。只登记第一种时，生成不会停。面试里可以把这件事说成：停止条件必须在 token 编号上核对，不能只在解码后的字符串上核对。

9 工程清单

训练日志里至少留这些量。SFT 留回答 token 数、训练负对数似然、留出负对数似然、学习率和梯度范数。偏好优化留 Δ_w、Δ_l、间隔、准确率、β 和损失类型。第一步损失应等于恒等式，否则参考模型没有接上，或者 Δ 的求和方式与公式不一致。RLOO 留组内奖励均值、精确率、格式率、优势绝对值、策略损失、熵、KL 和重要性权重。权重在 on-policy 时应为 1。优势绝对值为 0 的步不提供策略信息。

实现上有几处容易错。因果掩码要右移。参考模型单独加载并冻结，`deepcopy` 在 `device_map` 上会失败。词表上的 log-sum-exp 放在 float32 里按时间分块，否则 $[B, T, V]$ 的 float32 张量会占满显存。注意力用 scaled dot-product，避免训练态把 $[B, H, T, T]$ 存下来。0.5B 模型的解码利用率可以不高，显存却会在错误的注意力实现里被打满。把利用率打满不是目标，把损失和停止符核对正确才是。

数据侧要核对列名和模板。`query` 与已经渲染好的 `prompt` 不能混用。测试集 50 条只用于 pass@k。搜索器生成 SFT 数据时，只用训练集的下标，并且记录无解的条数。本实验 20 000 条里无解数为 0。

10 怎么读这份实验

图 1 回答 “冷启动有没有发生”。损失贴住留出值，同时 pass@1 离开 0，两件事一起才说明模型开始产生可评分的等式。只看损失会把 “记住搜索器的句式” 说成 “学会了解题”。

图 2 回答 “偏好损失有没有接上公式”。第一步打中 25 和 $\log 2$，实现是对的。之后求和 IPO 上升，是尺度问题，不是数据没有加载。长度平均把损失按住，准确率仍在一半附近，所以这一阶段没有可报告的偏好增益。pass@8 上 IPO 是 0.560，要和 SFT 的 0.475 一起看 n 的差别。

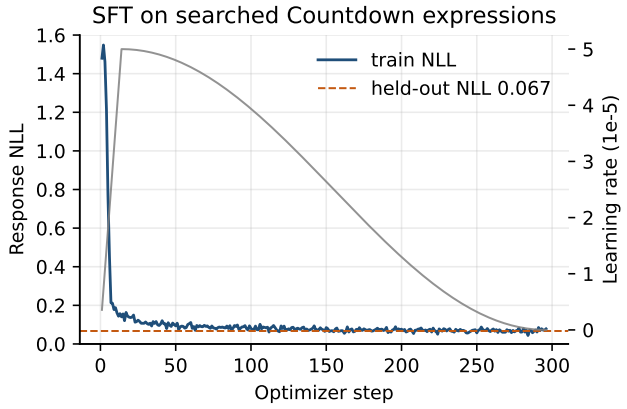


图 1: SFT 把回答负对数似然压到留出值附近。这是格式学习的曲线，不是 pass@k。

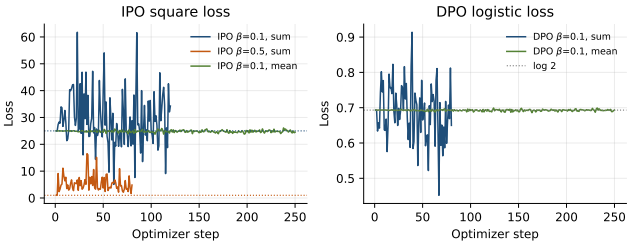


图 2: 左图的点线是 IPO 在参考策略处的恒等式。求和版本离开这条线，长度平均版本贴着它。

图 3 回答“在线更新有没有超过 SFT”。在短等式、每步四个提示、最多一百二十步这个预算下，没有一个检查点在 pass@8 上稳定高于其他检查点。写进面试答案时要带上预算：SFT 负责把奖励从全零变成有方差，随后的短程 IPO 与 RLOO 没有给出可重复的 pass@8 提升。

换成长 `<think>`、每步 32 个提示、100 步、vLLM 采样之后，结论换成另一句。留出集 500 题、每题 16 条：长 think SFT 的 pass@1 是 0.272，pass@16 是 0.662。RLOO、GRPO 和 Dr. GRPO 把 pass@1 抬到 0.525 ± 0.004、0.512 ± 0.016 和 0.534 ± 0.008，pass@16 仍是 0.676 ± 0.029、0.648 ± 0.016 和 0.675 ± 0.019。面试里把这说成分布变尖：小 k 上升，大 k 没有拉开。短等式上的 RLOO 则把 pass@16 打到 0.314。同一套损失，初始化格式不同，覆盖可以变好也可以变坏。GRPO 除以组内标准差，Dr. GRPO 只减均值。本实现两边都用序列对数概率之和，没有再做长度平均，所以不能把差距说成长度归一化的效果。测试时用题目自带的检查器在 16 条里重排，收回的是 pass@16 已经覆盖的解。最大平均对数概率低于均匀抽一条。

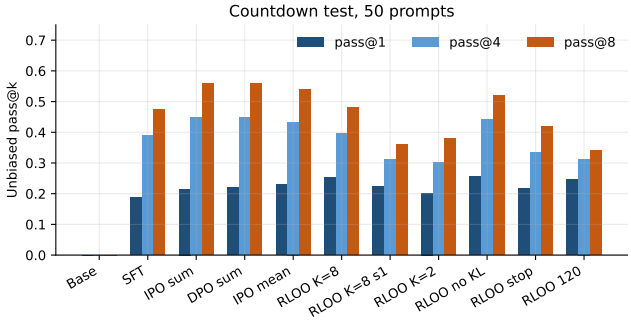


图 3: 同一套 50 题上的 pass@k。Base 为零。SFT 打开格式。短程偏好优化和 RLOO 的差别小于种子噪声。

11 岗位上的回答方式

奖励模型还要不要。有 verifier 的任务优先用 verifier。人类偏好留在没有自动检查的开放生成上，例如摘要和对话的风格 [Stiennon et al., 2020, Ouyang et al., 2022]。Constitutional AI 用模型自己的原则产生偏好，仍然是一个会错的奖励 [Bai et al., 2022]。数学题上再套一个奖励模型，通常是在 verifier 已经够用之后才考虑过程分 [Lightman et al., 2023]。

DPO 和 PPO 怎么选。离线对的质量高、不需要探索新回答时，DPO 或 IPO 更省系统 [Rafailov et al., 2023, Azar et al., 2024]。需要在采样里发现对里没有的解时，用 RLOO 或 GRPO 这一类在线目标 [Ahmadian et al., 2024, Shao et al., 2024]。PPO 的价值网络在奖励稠密、信用分配很长时仍有用 [Schulman et al., 2017, Zheng et al., 2023]。Countdown 的奖励在序列末尾才知道对错，四十步的组内基线已经能给出非零优势，价值网络不是第一优先级。

pass@1 掉了但 pass@8 升了。这是多样性换覆盖。产品若只展示一条，要同时看多数投票或重排序能不能把 pass@8 的覆盖收成 pass@1。只报其中一个指标会让两个岗位听到相反的结论。

损失是恒等式但准确率是一半。实现通过了检查，优化还没有离开参考策略，或者离开的方向不是 chosen。下一步看 Δ_w 与 Δ_l 的符号，而不是把学习率加大到损失爆炸。本实验里求和 IPO 的验证损失升到 31.07，就是后一种情况。

小模型实验能说明什么。它能说明掩码、恒等式、优势为零的条件和停止符。它不能说明 0.5B 上失败的方法在更大模型和官方 batch 上也会失败，也不能把四十步的波动说成算法排序。DeepSeek-R1 和 DeepSeek-Math 的结果对应的是另一种规模 [Shao et al., 2024, DeepSeek-AI, 2025, Qwen Team, 2025]。面试里把“我核对过的不变量”和“我还没有跑的规模”分成两句。

参考文献

Arash Ahmadian, Chris Cremer, Matthias Gallé, Marzieh Fadaee, Julia Kreutzer, Olivier Pietquin, Ahmet Üstün, and Sara Hooker. Back to basics: Revisiting REINFORCE-style optimization for learning from human feedback in LLMs. *arXiv preprint arXiv:2402.14740*, 2024.

Mohammad Gheshlaghi Azar, Zhaohan Daniel Guo, Bilal Piot, Rémi Munos, Mark Rowland, Michal Valko, and Daniele Calandriello. A general theoretical paradigm to understand learning from human preferences. In *International Conference on Artificial Intelligence and Statistics*, 2024.

Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, et al. Constitutional AI: Harmlessness from AI feedback. In *arXiv preprint arXiv:2212.08073*, 2022.

Stephen Casper, Xander Davies, Claudia Shi, Thomas Krendl Gilbert, Jérémy Scheurer, Javier Rando, Rachel Freedman, Tomasz Korbak, David Lindner, Pedro Freire, et al. Open problems and fundamental limitations of reinforcement learning from human feedback. *Transactions on Machine Learning Research*, 2023.

Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.

Paul F. Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In *Advances in Neural Information Processing Systems*, 2017.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.

DeepSeek-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.

Hanze Dong, Wei Xiong, Deepanshu Goyal, Yihan Zhang, Winnie Chow, Rui Pan, Shizhe Diao, Jipeng Zhang, Kashun Shum, and Tong Zhang. RAFT: Reward ranked finetuning for generative foundation model alignment. *Transactions on Machine Learning Research*, 2023.

Kanishk Gandhi, Ayush Chakravarthy, Anikait Singh, Nathan Lile, and Noah D. Goodman. Cognitive behaviors that enable self-improving reasoners, or, four habits of highly effective STaRs. *arXiv preprint arXiv:2503.01307*, 2025.

Wouter Kool, Herke van Hoof, and Max Welling. Buy 4 REINFORCE samples, get a baseline for free! In *ICLR Workshop on Deep Reinforcement Learning Meets Structured Prediction*, 2019.

Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step. *arXiv preprint arXiv:2305.20050*, 2023.

Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, 2022.

Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.

Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D. Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Advances in Neural Information Processing Systems*, 2023.

John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. *arXiv preprint arXiv:1506.02438*, 2015.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.

Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F. Christiano. Learning to summarize from human feedback. In *Advances in Neural Information Processing Systems*, 2020.

Jonathan Uesato, Nate Kushman, Ramana Kumar, Francis Song, Noah Siegel, Lisa Wang, Antonia Creswell, Geoffrey Irving, and Irina Higgins. Solving math word problems with process- and outcome-based feedback. In *arXiv preprint arXiv:2211.14275*, 2022.

Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8:229–256, 1992.

Rui Zheng, Shihan Dou, Songyang Gao, Yuan Hua, Wei Shen, Binghai Wang, Yan Liu, Senjie Jin, Qin Liu, Yuhao Zhou, et al. Secrets of RLHF in large language models part I: PPO. *arXiv preprint arXiv:2307.04964*, 2023.

Daniel M. Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B. Brown, Alec Radford, Dario Amodei, Paul Christiano, and Geoffrey Irving. Fine-tuning language models from human preferences. *arXiv preprint arXiv:1909.08593*, 2019.