Countdown 上的推理后训练

长 think SFT 提供覆盖，在线 RL 把分布变尖，验证器收回已经采样到的解

ShaneLiu04　CS224R Default Project　Qwen2.5-0.5B　https://github.com/ShaneLiu04

问题

Countdown 给出几个整数和一个目标。模型必须每个数字恰好用一次，写出等于目标的等式。没有 `<answer>` 时奖励是 0，格式对但算错是 0.1，等式正确是 1。基座 Qwen2.5-0.5B 在留出集 500 题上的 pass@1 是 0.000，pass@16 是 0.002。奖励几乎全是 0，组内优势也是 0，策略梯度没有方向。

这件事值得单独做，是因为推理 RL 的论文常常只报 pass@1。pass@1 上升可以是“更常一次命中”，也可以是“八次里至少一次”变多。这两句话对产品的含义相反：前者是把质量收进单次采样，后者才是能力变宽。

方法

冷启动用长 `<think>` 的监督微调。在线阶段每步 32 个提示、组大小 8、100 步，学习率 10^{-5}，熵和 KL 系数都是 0.001。vLLM 以温度 1 采样，每步把当前权重复制回去。三种优势共用序列对数概率之和：

$$A_i^{\mathrm{RLOO}} = r_i - \frac{1}{K-1}\sum_{j\neq i} r_j,$$

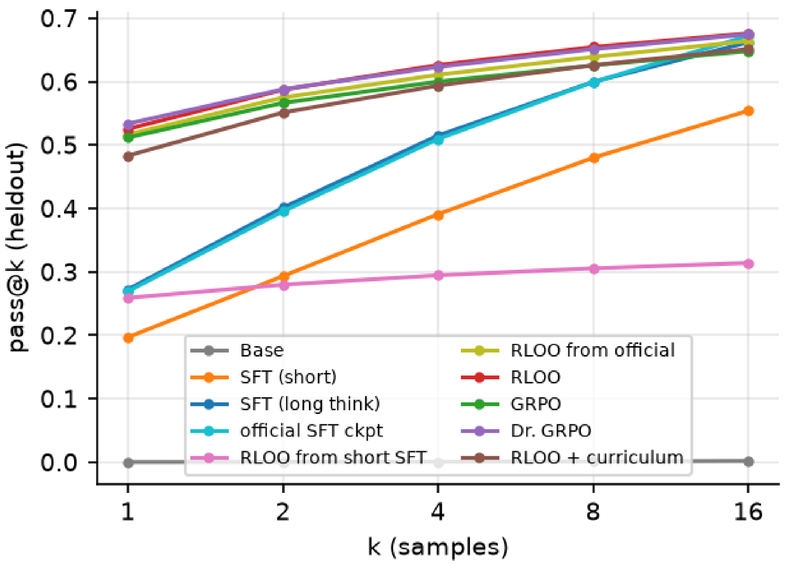
$$A_i^{\mathrm{GRPO}} = (r_i - \bar{r})/(\sigma + \epsilon),$$

$$A_i^{\mathrm{Dr}} = r_i - \bar{r}.$$

Dr. GRPO 去掉的是标准差。损失没有再除以回答长度。课程学习前一半只出三数字题，后一半只出四数字题。短等式 SFT 是对照：格式对了，但没有长搜索。

测试时在 k 条样本里重排。全验证器就是训练用的等式检查，题目里已经有目标和数字。对照是均匀抽一条、多数投票、最大平均对数概率，以及只检查数字是否用全。评估温度 0.6、top-p 0.95，每题 16 条。留出 500 题不进入训练。

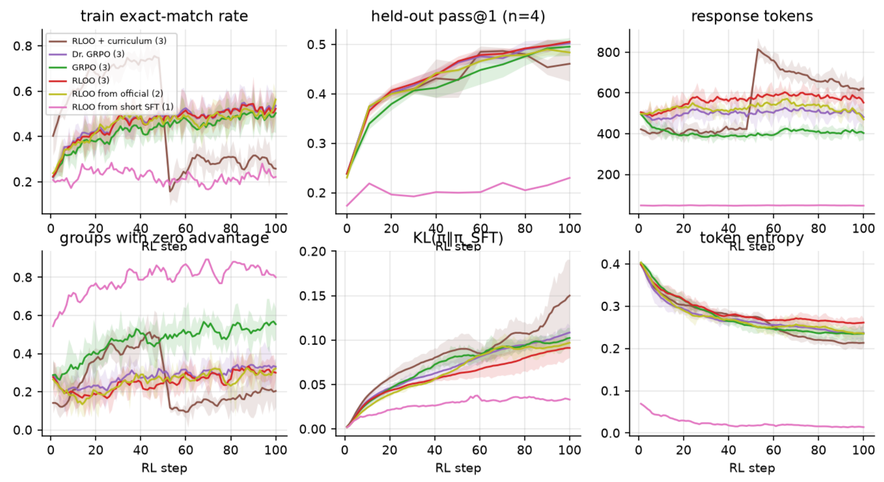
结果



留出集 500 题。在线方法的曲线更陡，右端几乎重合。± 是种子间标准差。

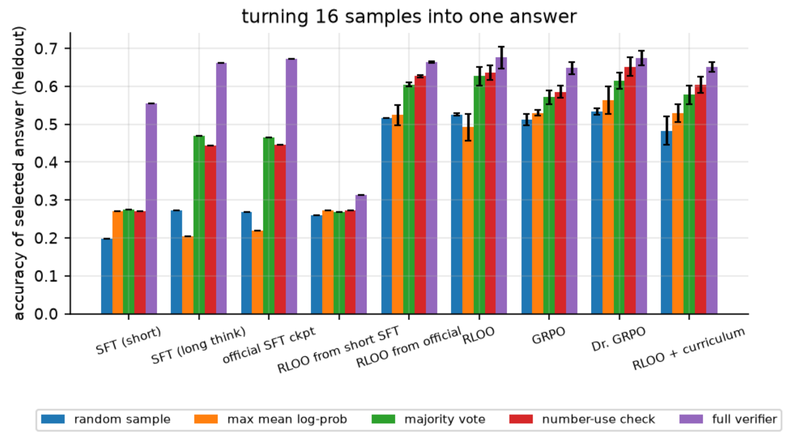
	pass@1	pass@16
长 think SFT	0.272	0.662
短等式 SFT	0.197	0.554
RLOO	0.525 ± 0.004	0.676 ± 0.029
GRPO	0.512 ± 0.016	0.648 ± 0.016
Dr. GRPO	0.534 ± 0.008	0.675 ± 0.019
课程学习	0.483 ± 0.037	0.651 ± 0.013
官方 SFT + RLOO	0.517 ± 0.001	0.664 ± 0.002
短等式 + RLOO	0.259	0.314

pass@1 从 0.27 附近升到 0.52–0.54，pass@16 仍在 0.64–0.68。在线 RL 把概率质量推向已经会的题，没有把 16 次采样的覆盖再拉开。短等式初始化上的 RLOO 把 pass@16 打到 0.314，低于它的 SFT。同样的优势，坏的冷启动会把覆盖训掉。课程学习没有超过同一预算的普通 RLOO。GRPO 和 Dr. GRPO 的差距还没有大过种子之间的起伏，不能把“去掉标准差”写成稳定排序。



在线精确率。曲线在上升，但终点的 pass@16 没有离开 SFT。

重排与边界



$k = 16$ 的选择器。全验证器等于 pass@16。最大对数概率低于随机一条。

全验证器能把小预算上的命中率拉向 pass@k，因为它丢掉算错的等式。最大平均对数概率偏向短而流利的错答案，留出集上低于均匀抽取。重排收回的是采样里已经出现的解。训练没覆盖到的题，检查器也挑不出来。

可以带走的四句话

1. 先看奖励是否有方差。基座 pass@1 是 0 时，RLOO 的优势也是 0。
2. 同时报 pass@1 和 pass@16。只报前者会把“分布变尖”说成“学会了解题”。
3. 冷启动的格式要和奖励对齐。长 think 上 RL 抬高 pass@1；短等式上 RL 压低 pass@16。
4. 有便宜检查器时，测试时多采样再验证，比再训一个打分模型直接。对数概率不是这个检查器的替代品。

边界。模型是 0.5B，不是论文里的大模型。在线预算是 100 步、每步 32 个提示，不是官方 batch 128 再累积 128。种子间的标准差以 `extension_macros.tex` 为准。评估温度和训练温度不同。Dr. GRPO 在这里只比较了标准差缩放，没有比较长度归一化。

数字由 `analysis/plot_extension.py` 从留出集 JSON 生成。海报对应课程要求的四个问题：任务是什么、为什么值得做、实验看到了什么、听众能带走什么以及哪里不能外推。