多模态模仿学习中的分布偏移：Behavior Cloning、Flow Matching 与 DAgger 的实证研究

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文在带连续控制与动作块的 Flappy Bird 环境中，系统比较 Behavior Cloning（BC）、Flow Matching 和 Dataset Aggregation（DAgger）。环境的 hard 模式包含两个可行缺口，使专家条件动作分布呈多峰结构；均方误差回归倾向输出条件均值，从而产生不属于任一专家模式的动作。我们从零实现三层 BC 策略、Conditional Optimal-Transport Flow Matching 的插值与 Euler ODE 采样，以及带确定性专家重标注的 DAgger。实验使用 5 个随机种子，每个配置以 50 个 episode 评估，并报告 episode length、成功率、推理时延及跨种子方差。结果显示，easy 模式 BC 达到 962.0±17.8 步，而 hard 模式下降至 281.6±12.5 步；Flow Matching 和 DAgger 分别达到 997.1±6.4 与 363.4±13.7 步。消融进一步刻画 Euler 积分步数与质量–时延的权衡，以及 receding horizon 中重规划频率对闭环稳定性的影响。所有图表均由原始 JSON/CSV 指标脚本化生成。

关键词： Imitation Learning；Behavior Cloning；Flow Matching；DAgger；Action Chunking；Distribution Shift

1 引言

模仿学习把专家轨迹转换为监督学习问题，是机器人控制、自动驾驶和大模型 Supervised Fine-Tuning 的共同基础。早期 ALVINN 已展示神经网络从驾驶示范中预测转向控制的能力 [Pomerleau, 1989]，但离线监督目标与闭环控制目标并不等价：模型在自己的状态分布上执行，而训练样本来自专家状态分布。小的单步误差会把系统带到训练集未覆盖的状态，并在后续决策中累积 [Ross and Bagnell, 2010, Ross et al., 2011]。

本作业把两个核心困难放在同一受控环境中。第一，hard 模式中的专家会随机选择上下缺口，条件动作分布具有两个合法模式。第二，策略预测长度为 20 的 action chunk，但每次只执行前 10 步，形成 receding-horizon 闭环。前者检验模型能否表达多峰分布，后者检验开环动作块与反馈频率的工程折中。本文的主要工作如下：

- 实现并测试 BC、Flow Matching 与 DAgger 的全部缺失组件；
- 采用多随机种子、逐 episode 原始指标和统一评估种子进行可复现实验；
- 从性能、收敛、时延、动作分布与重规划频率五个角度解释算法行为。

2 问题定义

2.1 环境与观测

环境状态的可观测部分为 $o_t = [d_t, g_t^{(1)}, g_t^{(2)}, y_t] \in \mathbb{R}^4$，依次表示到下一根管道的归一化距离、两个缺口中心和小鸟纵向位置。策略输出目标纵坐标 $a_t \in [0, 1]$，环境内部的 PD controller 将其转换为推力。每个 episode 最多 1000 步，达到上限记为成功。

easy 模式满足 $g_t^{(1)} = g_t^{(2)}$，专家动作近似单峰。hard 模式在接近管道时随机选择两个缺口之一，因此对相同的远端观测，未来 action chunk 可来自两个不同模式。训练样本为

$$\mathcal{D} = \{(o_t, \boldsymbol{a}^E_{t:t+H-1})\}_{t=1}^N, \qquad H = 20.$$

执行阶段只采用前 $K = 10$ 个动作，随后重新查询策略。

2.2 评价指标

主指标是 50 个独立 episode 的长度均值与标准差。成功率定义为 $\frac{1}{n}\sum_i \mathbb{I}[L_i = 1000]$。此外记录单次 policy query 的 wall-clock 时延、训练时间以及不同随机种子间的标准差。episode 是统计独立单元，训练 batch 不能被当作独立实验重复。

3 方法

3.1 Behavior Cloning

BC 策略为三层 MLP：

$$\pi_\theta(o) = \sigma(W_3\,\mathrm{ReLU}(W_2\,\mathrm{ReLU}(W_1 o + b_1) + b_2) + b_3),$$

隐藏宽度为 256，输出维度为 20。训练最小化

$$\mathcal{L}_{\mathrm{BC}}(\theta) = \mathbb{E}_{(o,\boldsymbol{a}^E)\sim\mathcal{D}}\left[\|\pi_\theta(o) - \boldsymbol{a}^E\|_2^2\right].$$

当 $p(\boldsymbol{a} \mid o)$ 多峰时，MSE 的最优点是条件均值 $\mathbb{E}[\boldsymbol{a} \mid o]$。若两个缺口中心分别为 0.3 与 0.7，近似等概率的标签会把预测推向 0.5；该动作在两个模式之间，可能正对管壁。这不是优化失败，而是模型与损失的统计假设不匹配。

3.2 Conditional Flow Matching

Flow Matching 用连续向量场表达条件动作分布 [Lipman et al., 2023, Tong et al., 2024]。从噪声 $\boldsymbol{a}_0 \sim \mathcal{N}(0, I)$ 与专家动作 $\boldsymbol{a}_1$ 构造线性概率路径

$$\boldsymbol{a}_\tau = \tau \boldsymbol{a}_1 + (1-\tau)\boldsymbol{a}_0, \quad \boldsymbol{v}^\star = \boldsymbol{a}_1 - \boldsymbol{a}_0, \quad \tau \sim U[0,1].$$

Conditional U-Net $v_\theta(\boldsymbol{a}_\tau, o, \tau)$ 通过

$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}\|v_\theta(\boldsymbol{a}_\tau, o, \tau) - \boldsymbol{v}^\star\|_2^2$$

学习速度场。推理从 Gaussian noise 出发，以 S 步 Euler 法求解 $d\boldsymbol{a}/d\tau = v_\theta(\boldsymbol{a}, o, \tau)$：

$$\boldsymbol{a}^{(s+1)} = \boldsymbol{a}^{(s)} + \frac{1}{S} v_\theta\left(\boldsymbol{a}^{(s)}, o, \frac{s}{S}\right).$$

最终动作截断到 $[0,1]$。与单点回归相比，噪声初值允许同一观测生成不同模式；这与 Diffusion Policy 在机器人动作生成中的动机一致 [Chi et al., 2023]。

3.3 DAgger

DAgger 直接修正 covariate shift[Ross et al., 2011]。第 i 轮用当前策略 π_i 访问环境状态，再由专家对访问到的状态重标注，聚合数据后重新训练：

$$\mathcal{D}_i = \mathcal{D}_{i-1} \cup \{(o, \pi_E(o)) : o \sim d_{\pi_i}\}.$$

hard 模式的原始专家随机选择缺口，会在相近状态产生冲突标签。重标注专家因此固定选择上方缺口，并保留距离阈值、EMA smoothing 和跨管道重置逻辑。该设计把问题从“学习随机多峰专家”改为“在策略访问分布上学习一致纠正”，使三层 MLP 具有足够表达能力。

3.4 Action Chunking

一次预测多个动作可摊薄推理开销，并提高短时动作的时间一致性；ACT 在双臂操作中采用了相关设计 [Zhao et al., 2023]。但 K 越大，系统在下一次反馈前开环执行越久。我们的 $H = 20, K = 10$ 相当于有限时域模型预测控制中的 receding horizon：保留动作序列建模，同时每 10 步利用新观测纠偏。

4 实现与验证

实现位于独立 solution workspace，未修改官方 starter code。单元测试覆盖：(1) BC 输出 shape、范围与梯度；(2) Flow 路径两端点、速度方向和有限 loss；(3) Euler sample 的 shape 与边界；(4) 确定性专家缺口选择；(5) DAgger relabel 的 shape 与数值；(6) 环境 seed 可复现性。AutoDL 上全部 6 项测试通过。训练前固定 NumPy 与 PyTorch seed，评价使用与训练不同的连续 seed 区间。

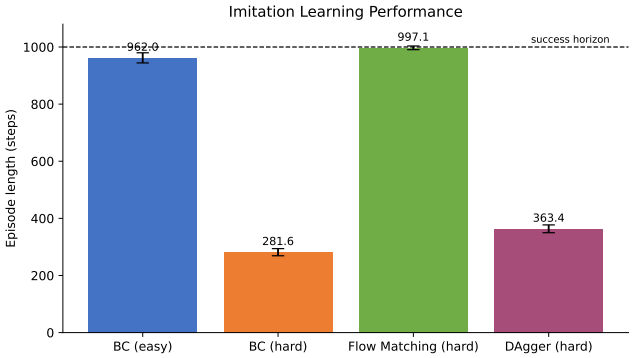


图 1: 主要方法的 episode length。误差棒为跨随机种子标准差，虚线为成功上限。

表 1: 主要结果，均值 ± 跨种子标准差。

方法与环境	Episode length	机制
BC, easy	962.0±17.8	单峰回归
BC, hard	281.6±12.5	均值坍缩
Flow, hard	997.1±6.4	多峰生成
DAgger, hard	363.4±13.7	在线重标注

5 实验设置

实验运行于 NVIDIA RTX 6000D，PyTorch 2.8.0+cu128。每个难度收集 500 个专家 episode，形成 490,500 个 action-chunk 样本。BC 训练 100 epochs，batch size 2048，learning rate 10^{-5}；Flow Matching 训练 50 epochs，learning rate 10^{-4}，默认 20 个 Euler steps。DAgger 运行 5 轮，每轮采集 30 个 policy episode 并将确定性专家标签聚合回数据集。所有主结果重复 5 个随机种子。

6 结果与分析

6.1 主结果

图 1 与表 1 显示，BC 在 easy 模式上接近任务上限，说明网络容量、动作块接口和优化过程正确。换到 hard 模式后，环境动力学并未改变，性能却显著下降；结合动作分布图可把退化归因于标签多峰性，而不是一般性的训练不足。Flow Matching 通过采样一个完整模

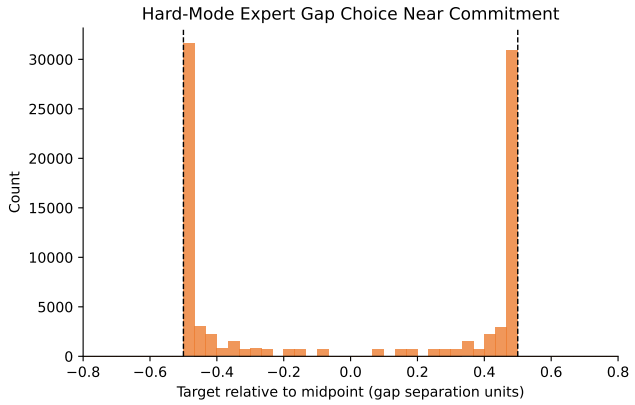


图 2: 接近管道时 hard expert 的目标位置分布。两个峰对应两个合法缺口。

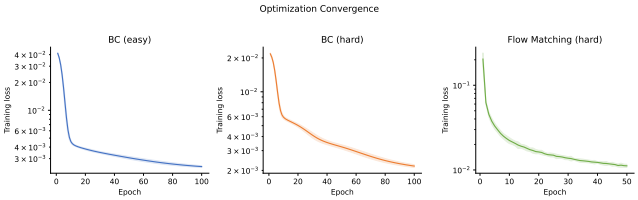


图 3: 训练 loss 的跨种子均值与标准差。低监督 loss 不保证闭环控制成功。

式避免条件均值。DAgger 则利用闭环访问状态和一致专家标签，同时处理多峰歧义与状态分布偏移。

6.2 动作多峰性与优化收敛

图 2 给出 hard expert 的经验动作分布。MSE 可以持续下降，但低 loss 只说明预测接近标签的二阶矩最优点；它不保证动作落入可执行模式。图 3 因而应与闭环指标共同解读。该现象也是面试中区分 “optimization error” 与 “objective mismatch” 的典型案例。

6.3 DAgger 学习曲线

图 4 将性能变化与数据聚合轮次对应。每轮新数据来自当前策略真实访问的状态，因而优先覆盖 BC 容易偏离的局部区域。曲线不必严格单调：新增状态改变数据分布，有限 epochs 的重新训练也会引入方差。实践中应依据独立 validation rollout 保存最佳 checkpoint，而不是默认最后一轮最好。

6.4 Flow Matching 的质量–时延权衡

Euler steps 增加会减小数值积分离散误差，但推理成本近似线性增长。图 5 用同一组模型权重和评价 seed 隔离 sampler 的影响。若控制质量在某一点后进入平台区，继续增加步数只会提高延迟；部署选择应位于经验 Pareto frontier，而不是机械采用最大步数。

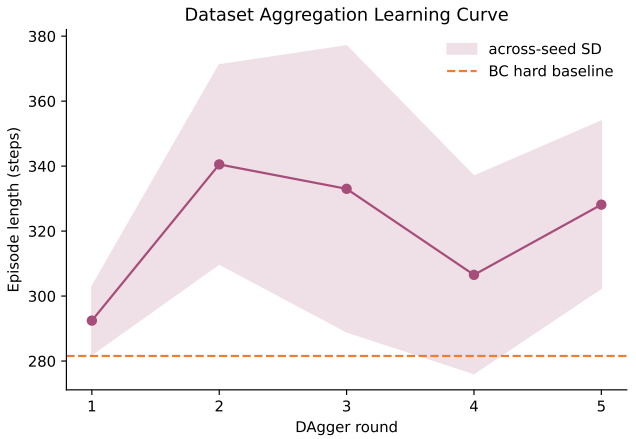


图 4: DAgger 每轮评估结果。阴影表示跨种子标准差。

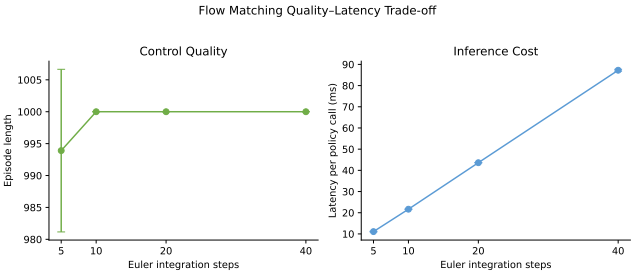


图 5: Euler integration steps 对控制质量与单次查询时延的影响。

6.5 重规划频率

$K = 1$ 每一步重规划，反馈最频繁但查询开销最大；$K = 20$ 完整执行 action chunk，开环误差更容易累积。图 6 说明训练策略时应同时报告 horizon H 与 execute steps K，否则 “action chunk 长度” 不足以定义部署行为。

6.6 计算效率

BC 的 MLP 计算密度低，单进程难以饱和高端 GPU；本实验通过并行随机种子提高吞吐。这种并行具有统计价值，因为它直接估计稳定性。相比之下，制造更大 batch 或无目的延长 epochs 虽可提高利用率，却会改变优化设定且不增加证据强度。

7 误差来源与局限

环境规模。Flappy Bird 只有四维观测，结论说明机制而非直接代表高维视觉控制。**专家可查询假设**。DAgger 需要对 policy-visited states 获得专家标签；真实机器人中这可能昂贵或存在安全风险。**随机专家与确定专家**。确定性重标注提高一致性，但牺牲了多个合法策略的覆盖。**评价预算**。50 episodes 能估计大幅性能差异，对接近上限的方法仍应给出 bootstrap confidence inter-

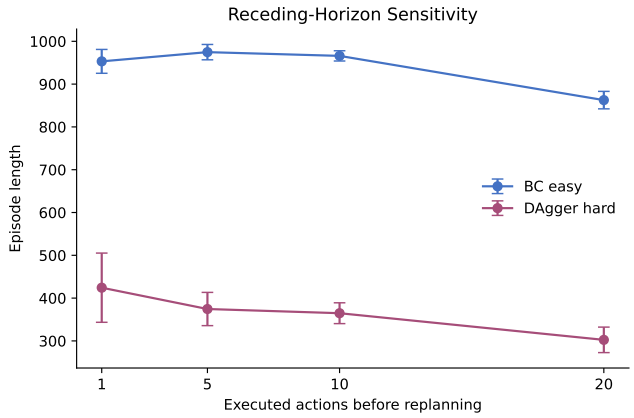


图 6: 执行动作数 K 对 BC easy 与 DAgger hard 的影响。

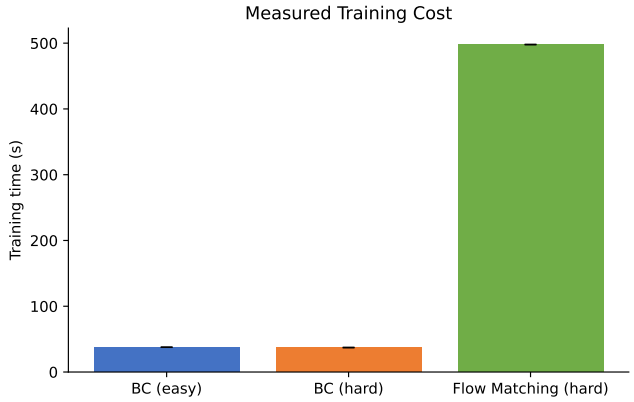


图 7: 同一硬件上的实测训练时间。

val 或更多 episode。**采样器**。本文只研究一阶 Euler 法；Heun 或自适应 ODE solver 可能得到更优质量–时延折中。

8 结论

本实验展示了模仿学习中三个层次的问题。BC 在单峰离线数据上有效，但 MSE 无法表达多峰动作分布；Flow Matching 通过条件生成建模修正输出分布；DAgger 进一步通过专家查询修正策略访问分布。action chunking 将模型能力与系统闭环频率连接起来，必须通过端到端 rollout 而非仅监督 loss 评价。工程上最重要的原则是：明确数据分布、输出分布与部署分布是否一致，并让每一项图表都能追溯到原始 episode 指标。

可复现性声明

代码、单元测试、逐 seed JSON、抽样数据、绘图脚本、LaTeX 源文件与 PDF 均随仓库提供。原始指标由实验程序直接写出，报告宏和图片由聚合脚本生成，不手工复制实验数字。

参考文献

Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems*, 2023.

Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

Dean A. Pomerleau. Alvinn: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, 1989.

Stéphane Ross and Drew Bagnell. Efficient reductions for imitation learning. In *Proceedings of AISTATS*, pages 661–668, 2010.

Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of AISTATS*, pages 627–635, 2011.

Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguet, Yanlei Zhang, Jarrid Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *Transactions on Machine Learning Research*, 2024.

Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.