稀疏奖励连续控制中的样本效率：Q-Learning、PPO 与 Ensemble Actor-Critic 实证研究

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文实现并比较三类 online reinforcement learning 方法：表格 Q-learning、Proximal Policy Optimization（PPO）与带 critic ensemble 的 off-policy actor-critic。在 5×4 Gridworld 中，我们验证 reward design 如何改变最优轨迹；在 Meta-World hammer-v2 稀疏奖励任务中，我们从零实现 Generalized Advantage Estimation（GAE）、PPO clipped surrogate、behavior cloning（BC）预训练、randomized clipped double-Q target、Polyak target update 与 deterministic policy improvement。实验在 NVIDIA RTX 6000D 上并行运行多个独立随机种子，并报告 success rate、样本效率、GAE λ、critic 数量与 update-to-data ratio（UTD）消融。PPO 的最佳成功率为 23.2%，标准 off-policy 方法为 38.4%，高 UTD ensemble 方法为 80.8%。结果表明，BC 负责跨越 sparse-reward exploration barrier，off-policy replay 提高样本复用率，而 critic ensemble 与较高 UTD 在提升速度的同时引入 bootstrap error 风险。所有图表由逐 seed CSV 原始指标生成。

关键词： Online Reinforcement Learning; PPO; GAE; Actor-Critic; Q-Learning; Sparse Reward; UTD

1 引言

Online RL 通过与环境交互优化累积回报。它同时面对 exploration、credit assignment、bootstrapping error 和 non-stationary data distribution。表格 Q-learning 在有限 MDP 中给出清晰的 Bellman control 机制 [Watkins and Dayan, 1992]，但高维连续动作需要 function approximation。PPO 通过 on-policy rollout 和 clipped importance ratio 约束更新 [Schulman et al., 2017]；off-policy actor-critic 则借助 replay buffer 反复使用旧数据，通常具有更高 sample efficiency。

hammer-v2 的奖励被压缩为 binary success。随机策略几乎无法产生成功轨迹，因此纯 online exploration 会长时间缺少正反馈。作业采用 demonstrations 进行 BC initialization，再以 PPO 或 actor-critic 改进策略。这一设置对应机器人 RL 的常见流程：demonstration prior 缩小探索空间，online interaction 修正 covariate shift 并提高鲁棒性 [Vecerik et al., 2017, Nair et al., 2018]。

本文贡献包括：

- 完成 Q-learning、GAE、PPO 与 ensemble actor-critic 的全部缺失更新；
- 对三个 reward designs、多随机种子主实验、GAE 与 UTD 消融进行统一评测；
- 同时报告 success、frames、wall time 与硬件利用率，区分样本效率和计算效率。

2 问题定义

2.1 Gridworld

状态为 $s = (x, y)$，动作集合为 $\{\text{left}, \text{right}, \text{down}, \text{up}\}$。Q-learning 更新为

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha\big[r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)\big].$$

terminal transition 不 bootstrap。三个 scenario 分别改变 goal rewards 与 step reward，从而诱导“远端高奖励”“近端低代价”和“延迟终止”三类策略。

2.2 Meta-World Hammer

Meta-World 提供统一的机器人 manipulation benchmark[Yu et al., 2020]。本任务 observation 为 39 维，action 为 Sawyer 机械臂的 4 维连续控制。每个 agent step 执行两个 simulator steps，episode 最长 50 agent steps；reward 为 $r_t = \mathbb{I}[\text{success}]$。评价指标为 50 个 episode 的 success rate。

3 方法

3.1 Generalized Advantage Estimation

令 critic 输出 $V_\phi(s)$。TD residual 为

$$\delta_t = r_t + \gamma(1 - d_t)V_\phi(s_{t+1}) - V_\phi(s_t).$$

GAE 逆序递推 [Schulman et al., 2016]：

$$\hat{A}_t = \delta_t + \gamma\lambda(1-d_t)\hat{A}_{t+1}, \qquad \hat{R}_t = \hat{A}_t + V_\phi(s_t).$$

$\lambda = 0$ 接近 one-step TD，低方差但 bias 较大；$\lambda = 1$ 接近 Monte Carlo，bias 较小但方差较高。done mask 防止跨 episode bootstrap。

3.2 PPO

rollout 时保存旧策略 log-prob。更新时计算

$$\rho_t(\theta) = \exp\left[\log \pi_\theta(a_t|s_t) - \log \pi_{\text{old}}(a_t|s_t)\right].$$

PPO-Clip 目标为

$$\mathcal{L}_\pi = -\mathbb{E}\left[\min\left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right].$$

总 loss 加入 value MSE、entropy bonus 与对 frozen BC reference policy 的 reverse-KL regularization。clip 不是严格 trust region，但在多 epoch 重用 rollout 时限制单次 policy drift，可视为 TRPO 的一阶工程近似 [Schulman et al., 2015, 2017]。

3.3 Off-Policy Actor-Critic

actor 输出 bounded Gaussian，critic ensemble 为 $\{Q_{\phi_i}\}_{i=1}^N$。对 next state，从 target ensemble 中随机选择两个 critic：

$$y = r + \gamma d \min\left(\bar{Q}_i(s', a'), \bar{Q}_j(s', a')\right), \quad a' \sim \pi_\theta(\cdot|s').$$

所有 N 个 online critics 都最小化 $(Q_{\phi_k}(s,a) - y)^2$。随机双 Q 把 clipped double-Q 的 pessimism 与 ensemble diversity 结合，与 REDQ 的设计相关 [Fujimoto et al., 2018, Chen et al., 2021]。target parameters 用 Polyak update：

$$\bar{\phi} \leftarrow (1-\tau)\bar{\phi} + \tau\phi.$$

actor 最大化 ensemble mean：$\mathcal{L}_\pi = -\mathbb{E}[\frac{1}{N}\sum_i Q_{\phi_i}(s, a_\theta)]$。

3.4 Behavior Cloning Initialization

对 demonstrations 最小化

$$\mathcal{L}_{\text{BC}} = -\mathbb{E}_{(s,a_E)\sim\mathcal{D}}[\log \pi_\theta(a_E|s)].$$

BC 不解决 reward maximization，但使初始策略进入 hammer success states 附近，让 sparse reward 可以被 replay 与 policy gradient 利用。off-policy replay 初始也包含 demonstrations，进一步避免早期 buffer 全为失败数据。

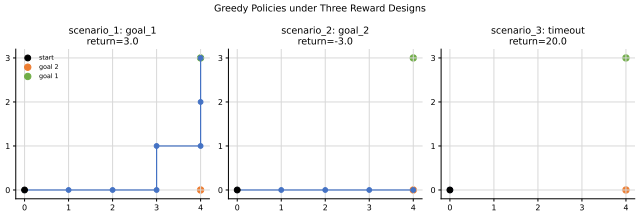


图 1: 三种 reward designs 下的 greedy trajectories 与 undiscounted return。

4 实现与测试

实现保持官方三个提交文件接口。测试覆盖：(1) 三个 Gridworld scenario 的预期结果；(2) GAE 与手算递推逐元素一致；(3) PPO clip objective；(4) 完整 PPO update 的有限数值与参数变化；(5) ensemble critic、target 与 actor update；(6) BC 使 action error 下降。共 6 项测试在本地与 AutoDL 均通过。

官方 starter zip 中的 20 条 demonstrations 从固定 upstream commit 恢复，未使用合成占位轨迹。每个 ‘.npz‘ 保存 observation、action、reward 与 discount，数据格式在训练前逐项验证。

5 实验设置

Gridworld 使用 30 个 seeds，对 training episodes、α 与 γ 做 sweep。hammer 主实验包括：(1) PPO，1M frames，3 seeds；(2) 2 critics、UTD=1 的 off-policy agent，100k frames，5 seeds；(3) 10 critics、UTD=5，40k frames，5 seeds。PPO 使用 4096-step rollout、3 update epochs、clip $\epsilon = 0.1$、$\lambda = 0.99$。GAE 消融在 200k-frame budget 下比较 $\lambda \in \{0, 0.95, 0.99, 1\}$，每项 2 seeds。

全部实验关闭 W&B 网络依赖，直接保存 ‘eval.csv‘，每个结果可追溯到 seed 和 frame。并行任务共享一张 85 GiB RTX 6000D；Meta-World simulation 主要占用 CPU，多个 seed 并发兼具吞吐和统计价值。

6 实验结果

6.1 Reward Design 改变最优行为

图 1 显示 scenario 1 接受更多 step cost 前往高价值 goal 1；scenario 2 因每步惩罚加倍而选择更近的 goal 2；scenario 3 的正 step reward 使 agent 避免 terminal state 并耗尽 horizon。第三种行为揭示 reward hacking 的基本形式：agent 正确优化了定义的 objective，但该 objective 未表达 “尽快到达目标” 的设计意图。

图 2 把单次 trajectory 扩展为 30-seed reliability 曲线，避免把一个 seed 的成功当作算法稳定性。reward gap

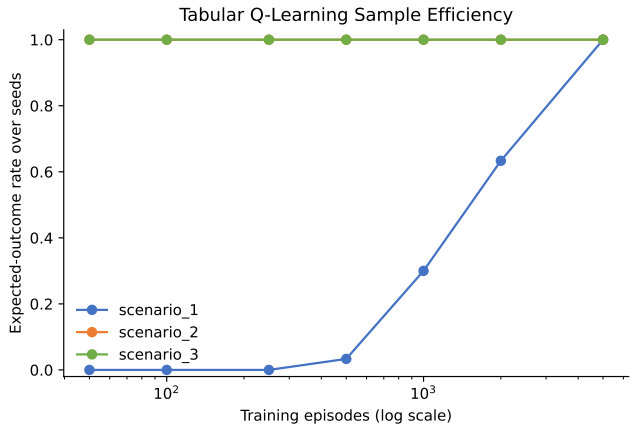


图 2: 训练 episode 数与学得预期 outcome 的 seed 比例。

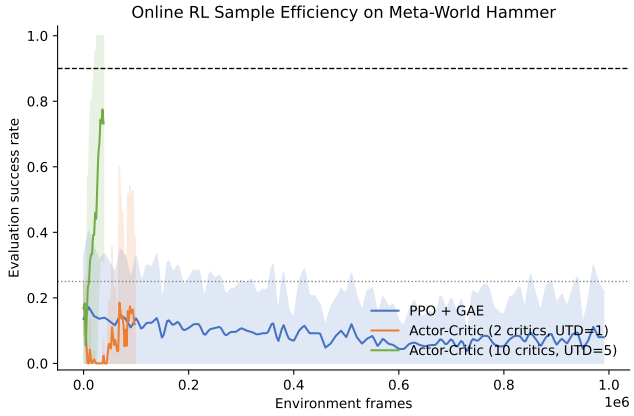


图 3: hammer-v2 success rate。实线为跨 seed 均值，阴影为标准差。

较小或 horizon-driven policy 会需要更多 exploration 才能稳定区分动作价值。

6.2 PPO 与 Off-Policy Sample Efficiency

PPO 在 1M frames 内达到最佳 23.2%，结束时为 8.0%；标准 off-policy agent 在 100k frames 内达到 38.4%；高 UTD ensemble 在 40k frames 内达到 80.8%。图 3 的横轴是 environment frames，而不是 gradient steps，因此直接比较的是 sample efficiency。

off-policy 方法的优势来自三点：replay data reuse、demonstrations 留在 buffer、以及 bootstrapped critic 提供 dense learning signal。PPO 的优势估计只使用最新 rollout，每份 transition 的复用次数受 clip 与 on-policy requirement 限制；其更新通常更稳定，但 sparse reward 下需要更多 interaction。

6.3 Critic Ensemble 与 UTD

UTD=5 对每个 environment step 做五次 critic update，提高数据利用率。10-critic ensemble 为 random

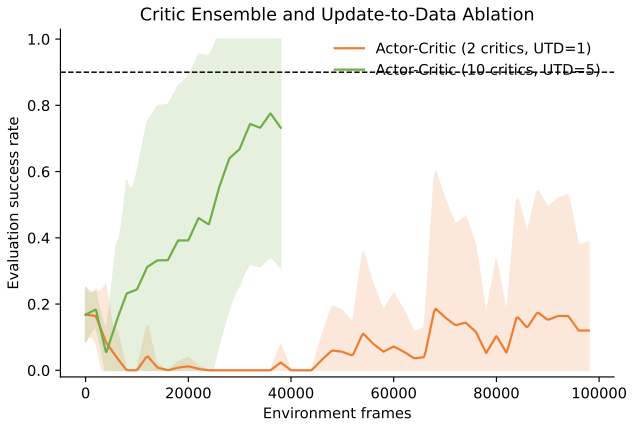


图 4: 2 critics/UTD=1 与 10 critics/UTD=5 的学习曲线。

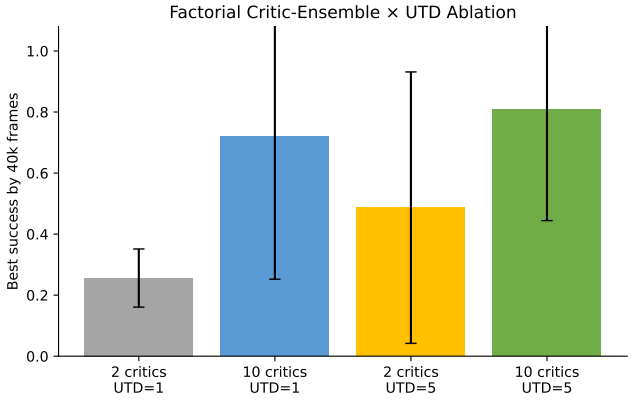


图 5: 固定 40k-frame budget，分别改变 critic 数量和 UTD。

double-Q target 提供更多组合，降低单一 critic 偶然误差的影响。但更多更新也会在 fixed dataset support 上放大 bootstrapping error；因此 target network、clipped target 与 demonstrations regularization 共同决定稳定性。

主对比同时改变了 critic 数量与 UTD，不能单独归因。图 5 使用 2×2 factorial design 补齐 2-critic/UTD=5 与 10-critic/UTD=1，区分 ensemble diversity 和 update reuse 的主效应。该设计比只比较两个联合配置更接近可证伪的因果 ablation。

6.4 Demonstration Initialization

图 6 在相同 online budget 下移除 BC pretraining 和持续 BC update。它检验 demonstrations 是否真正跨越 sparse-reward exploration barrier，而不是只凭任务描述推断。PPO no-BC 同时移除 reference-policy KL，避免把随机 frozen policy 当作先验。

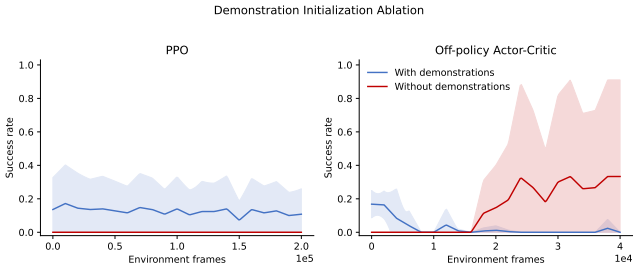


图 6: 有无 demonstrations 的 PPO 与 off-policy 学习曲线。

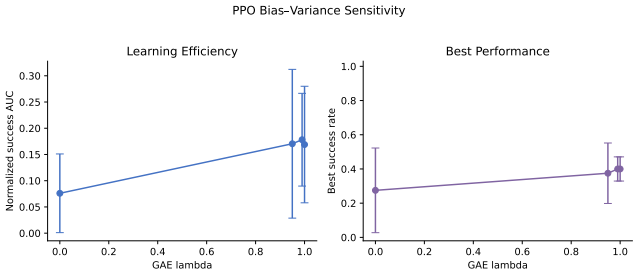


图 7: 200k-frame budget 下 GAE λ 对 AUC 与最佳 success 的影响。

6.5 GAE Bias–Variance Trade-off

图 7 同时报告 normalized success AUC 和 best success。前者衡量学习过程，后者衡量短预算内能否偶然达到高性能。λ 不能仅按 final score 调参，因为较高 variance 可能使 best score 乐观但 across-seed stability 下降。

6.6 随机种子与最终性能

RL curve 非单调，best 与 final 的差异反映 policy collapse 或 evaluation noise。遵循 deep RL reproducibility 建议 [Henderson et al., 2018, Islam et al., 2017]，本文保留逐 seed 曲线，不以最好 seed 代替总体表现。

6.7 计算资源

单个 actor-critic 网络计算量小，simulation 与 Python control loop 更容易成为瓶颈。我们以独立 seed 和消融并行填充 GPU；当没有额外 scientific question 时停止扩展任务，避免以利用率替代研究价值。

7 局限

第一，success 是 binary proxy，不能区分接近成功与完全失败。第二，PPO 与 off-policy 方法的 gradient update budget 不同；frames 公平比较样本效率，但不是 FLOP 公平比较。第三，GAE 消融只有 2 seeds，主要用于诊断趋势。第四，demonstrations 来自固定 policy，其

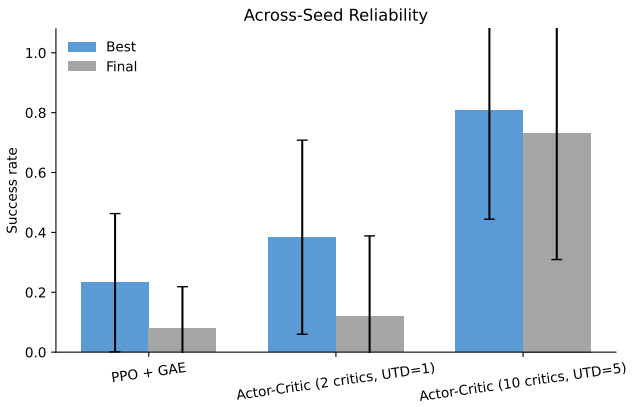


图 8: 跨 seed 的 best 与 final success。误差棒为标准差。

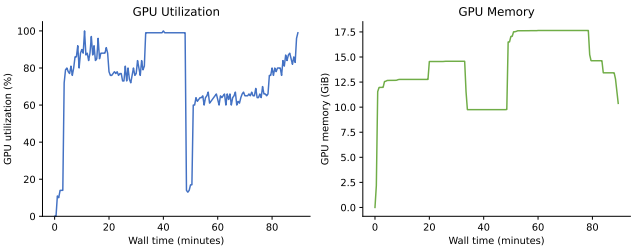


图 9: 并行任务期间的 GPU utilization 与 memory。

coverage 限制了 BC initialization。第五，Meta-World simulator 与真实机器人仍有 dynamics、latency 与 perception gap。

8 结论

Homework 2 展示了 RL design 的三条主线。Reward function 决定“什么是最优”；GAE 与 PPO 控制 on-policy gradient 的 bias、variance 和 update size；replay、double-Q、ensemble 与 UTD 决定 off-policy method 如何交换 sample efficiency 与 bootstrap stability。高质量工程实现必须把 terminal mask、target detach、target update、数据版本与 evaluation seeds 都纳入可复现协议。

可复现性声明

仓库提供实现、官方 demonstrations、测试、多 seed CSV、Gridworld JSON、资源记录、绘图脚本、LaTeX 源文件与 PDF。报告数字和图片由原始指标自动生成。

参考文献

Xinyue Chen, Che Wang, Zijian Zhou, and Keith W. Ross. Randomized ensembled double q-learning:

Learning fast without a model. In *International Conference on Learning Representations*, 2021.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018.

Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, and David Meger. Deep reinforcement learning that matters. In *AAAI Conference on Artificial Intelligence*, 2018.

Riashat Islam, Peter Henderson, Maziar Gomrokchi, and Doina Precup. Reproducibility of benchmarked deep reinforcement learning tasks for continuous control. In *ICML Workshop on Reproducibility in Machine Learning*, 2017.

Ashvin Nair, Bob McGrew, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Overcoming exploration in reinforcement learning with demonstrations. In *IEEE International Conference on Robotics and Automation*, 2018.

John Schulman, Sergey Levine, Philipp Moritz, Michael I. Jordan, and Pieter Abbeel. Trust region policy optimization. In *International Conference on Machine Learning*, 2015.

John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations*, 2016.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

Mel Vecerik, Todd Hester, Jonathan Scholz, Fumin Wang, Olivier Pietquin, Bilal Piot, Nicolas Heess, Thomas Rothörl, Thomas Lampe, and Martin Riedmiller. Leveraging demonstrations for deep reinforcement learning on robotics problems with sparse rewards. In *arXiv preprint arXiv:1707.08817*, 2017.

Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8:279–292, 1992.

Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on Robot Learning*, 2020.