Online Reinforcement Learning 工程与研究面试指南：从 Bellman Control 到 PPO、Double-Q 与高 UTD

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文构建面向算法工程、机器人学习与强化学习研究岗位的 online RL 知识体系。内容从 MDP、Bellman equation 和 tabular Q-learning 出发，推导 policy gradient、baseline、GAE、PPO clipped objective、actor-critic、target network、clipped double-Q、critic ensemble 与 UTD，并以 Meta-World hammer 稀疏奖励实验连接理论、PyTorch 实现、远端训练、统计评测和系统部署。本文不把面试准备等同于背诵公式，而要求能够解释 estimator 的 bias–variance、识别 bootstrap error、设计有证据力的 ablation，并在 simulator 吞吐、GPU utilization、replay storage 与安全约束之间做工程权衡。

关键词： 求职面试；Online RL；PPO；Actor-Critic；Q-Learning；Sample Efficiency；Robot Learning

1 一张地图理解 Online RL

强化学习的输入不是固定 label，而是 agent 通过 policy 改变后续数据分布。MDP 记为 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho_0)$。策略目标为

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{T}\gamma^t r(s_t, a_t)\right].$$

面试时可以用四个维度定位算法：

1. **value-based 或 policy-based：** 优化 Q 的 greedy policy，还是直接对 π_θ 求梯度；
2. **on-policy 或 off-policy：** 数据是否必须来自当前 policy；
3. **model-free 或 model-based：** 是否学习或使用 dynamics；
4. **Monte Carlo 或 bootstrapping：** target 来自完整 return 还是 learned value。

Q-learning 是 off-policy、value-based、model-free、bootstrapped；PPO 是 on-policy、policy-based，并用 critic bootstrap；本作业 actor-critic 是 off-policy、policy-based，同时学习 ensemble Q-functions。

2 Bellman Equation 与 Q-Learning

2.1 从固定策略到最优控制

固定策略的 action value 满足

$$Q^\pi(s,a) = \mathbb{E}[r + \gamma Q^\pi(s', a')].$$

最优 Bellman operator 为

$$(\mathcal{T}^\star Q)(s,a) = \mathbb{E}_{s'}[r + \gamma \max_{a'} Q(s', a')].$$

$\gamma < 1$ 时它在 sup norm 下是 contraction，因此 tabular iteration 收敛到唯一固定点 $Q^\star$[Watkins and Dayan, 1992, Sutton and Barto, 2018]。stochastic approximation 更新只需采样 transition，不需要知道 P。

2.2 为什么 Q-Learning 是 Off-Policy

behavior policy 可以用 ϵ-greedy 收集数据，target 却使用 $\max_{a'} Q(s', a')$，对应 greedy target policy。选择 action 的 policy 与学习的 policy 不同，因此是 off-policy。SARSA 使用实际采样的 a'，是 on-policy。

2.3 终止状态的实现

terminal transition 的 target 应为 $y = r$，不能读取 reset 后新 episode 的 value：

$$y = r + \gamma(1-d)\max_{a'} Q(s', a').$$

漏掉 done mask 会把两个 episode 拼接，产生系统性 target bias。这是最常见的 RL implementation interview bug。

2.4 Reward Design 不是附属工作

正 step reward 会鼓励 agent 延迟终止；过大的 negative step cost 会偏好近端低价值 goal。agent “钻漏洞”通常不是 optimizer 错误，而是 proxy objective 与真实意图不一致。面试回答 reward hacking 时应区分 specification、optimization 与 generalization 三类 failure。

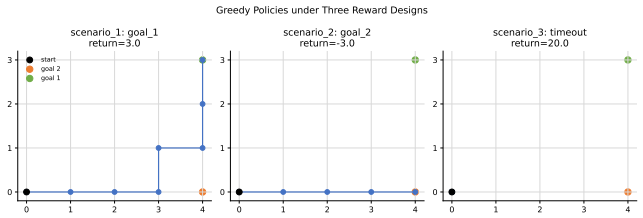


图 1: 相同 dynamics、不同 reward 产生完全不同的最优行为。

3 Policy Gradient：从 Log-Derivative 到 Baseline

trajectory probability 为 $p_\theta(\tau) = \rho_0(s_0)\prod_t \pi_\theta(a_t|s_t)P(s_{t+1}|s_t,a_t)$。环境 dynamics 不依赖 θ，因此

$$\nabla_\theta J = \mathbb{E}_\tau\left[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t) G_t\right].$$

只使用 reward-to-go 是 causality 的结果：过去 reward 不受当前 action 影响。加入只依赖 state 的 baseline $b(s_t)$ 不改变期望，因为 $\mathbb{E}_{a\sim\pi}[\nabla \log \pi(a|s)b(s)] = 0$。当 $b = V^\pi$ 时，权重成为 advantage。REINFORCE 无 bootstrap、近似无偏但方差高 [Williams, 1992]；actor-critic 用 learned value 降低方差，引入 approximation bias。

4 GAE 的 Bias–Variance 推导

GAE 是不同 horizon advantage estimators 的指数加权：

$$\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = \sum_{l=0}^{\infty}(\gamma\lambda)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t).$$

其递推形式只需逆序扫描：

$$\hat{A}_t = \delta_t + \gamma\lambda(1-d_t)\hat{A}_{t+1}.$$

$\lambda = 0$ 为 one-step TD；$\lambda = 1$ 在 episode 完整时接近 Monte Carlo return 减 baseline。γ 定义 task objective，λ 调节 estimator；二者数值同时出现，但概念不同。

高频追问：为什么 advantage 要 normalize？在 minibatch 内标准化不改变样本的相对顺序，能缓和 reward scale 对 learning rate 的影响；但它改变 gradient scale，且小 batch 的统计量可能噪声很大。应记录 raw advantage mean/std 以诊断 critic。

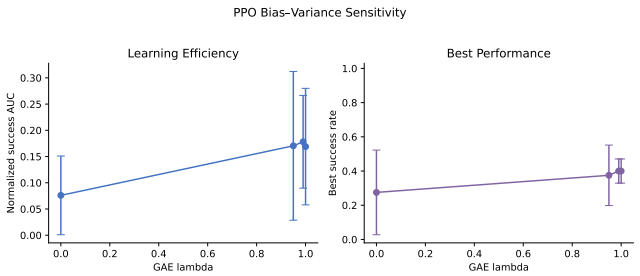


图 2: 短 budget 下 λ 对 learning AUC 与 best success 的影响。

5 PPO：Clip 能保证什么

5.1 Importance Ratio

数据来自 π_{old}，新策略 objective 用 ratio 修正：

$$\rho_t = \frac{\pi_\theta(a_t|s_t)}{\pi_{\mathrm{old}}(a_t|s_t)} = \exp(\log \pi_\theta - \log \pi_{\mathrm{old}}).$$

连续多维 action 的 log-prob 必须对 action dimensions 求和，再计算 ratio。

5.2 Clipped Surrogate

$$L^{\mathrm{clip}} = \mathbb{E}\left[\min(\rho_t A_t, \mathrm{clip}(\rho_t, 1-\epsilon, 1+\epsilon)A_t)\right].$$

对正 advantage，ratio 过大时收益被截断；对负 advantage，ratio 过小时惩罚被截断。必须先乘 advantage 再取 minimum，不能简单 clip loss。PPO clip 只约束 sampled actions 上的 surrogate improvement，不是严格 KL bound；因此仍需监控 approximate KL、clip fraction、entropy 与 value loss。

5.3 为什么能对同一 Rollout 做多 Epoch

第一轮后数据已 off-policy，但小 update、clip 和有限 epochs 把 distribution shift 控制在可接受范围。epochs 太少浪费数据，太多会 overfit advantage noise。TRPO 用显式 KL constraint 与 conjugate gradient，PPO 牺牲理论约束换取 first-order optimizer 的工程简洁 [Schulman et al., 2015, 2017]。

6 Off-Policy Actor-Critic

6.1 Replay 的价值与代价

replay buffer 打破 temporal correlation 并提高 transition reuse，显著改善 sample efficiency。代价是数据来自旧 policies，critic target 和 actor objective 可能在 out-of-distribution actions 上外推。continuous control

中通常通过 target network、double-Q、policy smoothing 和 entropy/BC regularization 稳定学习。

6.2 为什么需要 Target Network

若 target $r+\gamma Q_\phi(s',a')$ 与 prediction $Q_\phi(s,a)$ 同时快速变化，优化目标成为 moving target。Polyak average $\bar{\phi} \leftarrow (1-\tau)\bar{\phi}+\tau\phi$ 生成慢变量。τ 太大失去稳定效果，太小则 target lag 严重。

6.3 Overestimation 与 Double-Q

带噪估计满足 $\mathbb{E}[\max_a \hat{Q}(s,a)] \geq \max_a \mathbb{E}[\hat{Q}(s,a)]$。TD3 用两个 critics 取 minimum，降低 positive bias[Fujimoto et al., 2018]。minimum 可能产生 underestimation；REDQ 从 ensemble 随机抽两个取 min，再更新所有 critics，在 bias、variance 与计算间折中 [Chen et al., 2021]。

6.4 Actor Gradient

reparameterized action 可写为 $a_\theta = \tanh(\mu_\theta(s)+\sigma\epsilon)$。actor objective

$$L_\pi = -\mathbb{E}_s\left[\frac{1}{N}\sum_i Q_{\phi_i}(s,a_\theta)\right]$$

通过 Q 对 action 的梯度更新 actor。critic parameters 不由 actor optimizer step，但实现时可临时冻结 critic 以节省 gradient storage。

7 UTD：样本效率不等于计算效率

UTD 表示每个 environment transition 对应多少 gradient updates。增大 UTD：

- 优点：在真实机器人或 simulator interaction 昂贵时，提高 data reuse；
- 风险：对有限 replay support 过拟合，反复传播错误 target；
- 成本：GPU FLOPs 与 wall time 增加，即使 environment frames 减少；
- 配套：larger ensemble、target network、regularization 与 fresh data ratio。

面试陷阱：“UTD=5 比 UTD=1 快”必须说明 metric。它可能用更少 environment frames 达标，却需要更多 gradient steps 或更长 wall time。报告中至少分开 sample efficiency、compute efficiency 与 asymptotic performance。

若实验同时把 critics 从 2 改为 10、UTD 从 1 改为 5，就无法判断改进来自哪一项。factorial design 补齐两个交叉配置，是研究面试中“如何修复 confounded ablation”的直接例子。

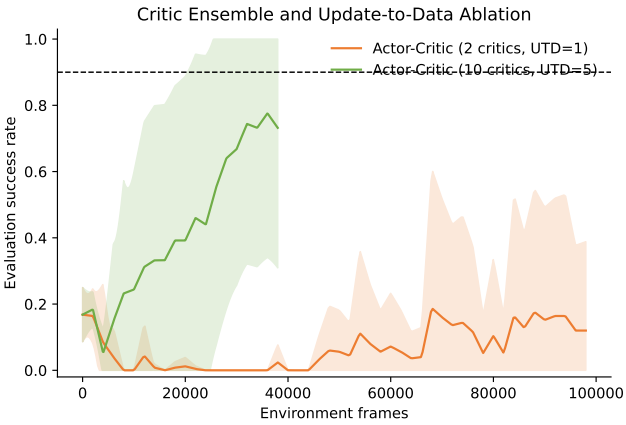


图 3: UTD 与 critic ensemble 对 sample efficiency 的联合影响。

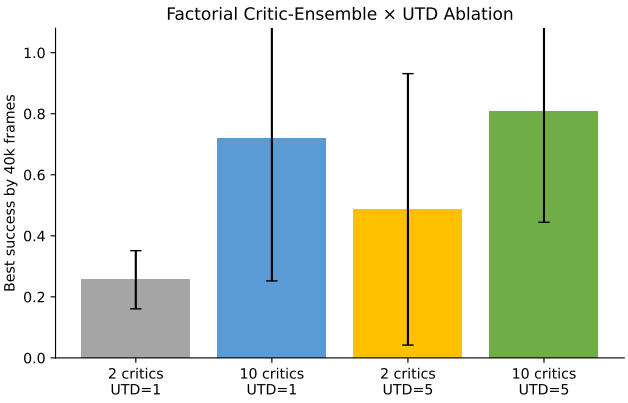


图 4: 2×2 factorial ablation 分离 critic count 与 UTD。

8 Demonstrations 如何跨越 Sparse Reward

随机 policy 在 hammer task 几乎看不到 success，policy gradient 的 reward-weighted signal 接近零。BC 把 policy 放到 expert occupancy 附近；off-policy agent 还把 demonstrations 放入 replay，使成功 transition 持续被采样。DDPGfD 与 demonstration augmented RL 采用类似思路 [Vecerik et al., 2017, Nair et al., 2018]。

但 BC prior 可能限制 improvement。常见策略是：(1) pretrain 后纯 RL；(2) RL 中以较低频率 interleave BC；(3) advantage-weighted BC；(4) KL to reference policy。regularizer 应随 online evidence 增加逐渐减弱，否则 agent 难以超越 suboptimal expert。

高质量 ablation 还需同步移除 PPO 对随机 reference policy 的 KL，否则“no BC”条件仍受一个无意义先验约束。off-policy 条件则同时设置 pretrain steps 和

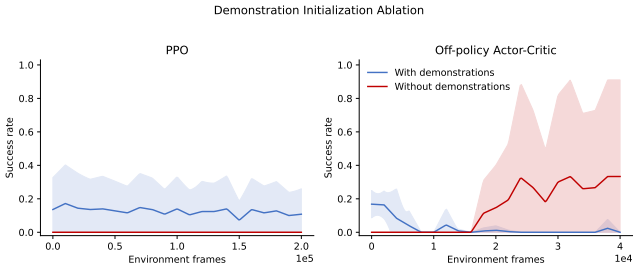


图 5: 移除 demonstrations 后的 exploration 对照。

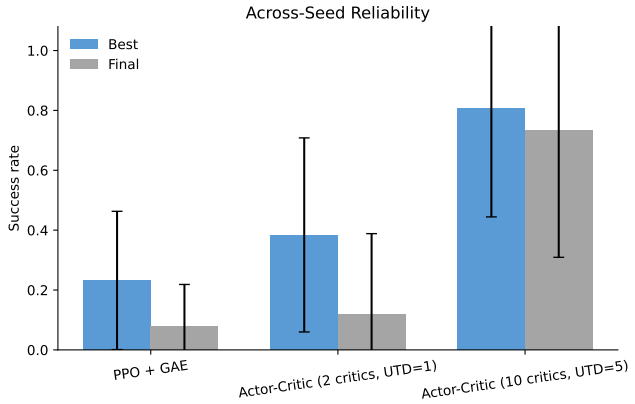


图 6: Best checkpoint 与 final checkpoint 的 across-seed 差异。

interleaved BC frequency 为零。

9 实验设计：如何让 RL 结论可信

9.1 独立统计单元

seed 而不是 timestep 是算法稳定性的主要独立重复。evaluation episode 用于估计同一 checkpoint 的 success variance，但不能替代训练 seed。应报告 mean、SD、median、best/final、seed count 和 evaluation episode count [Henderson et al., 2018, Islam et al., 2017]。

9.2 Best 与 Final

选择 best checkpoint 需要独立 validation tasks/seeds；若在 test curve 上挑最高点，会产生 multiple-comparison bias。课程验收关心“是否在 budget 内达到阈值”，可报告 first crossing frame；部署稳定性则更关心 final 与 rolling mean。

9.3 公平比较的三个 Budget

1. environment frames：衡量真实交互成本；
2. gradient updates/FLOPs：衡量训练计算；
3. wall time：包含 simulator、data loader、evaluation 和日志。

on-policy 与 off-policy 算法只按 frames 比较是不完整但有意义的。论文应明确主要 claim 是 sample efficiency 还是 total compute。

10 调试顺序：从手算到长任务

1. **Tabular sanity check：**小 MDP 手算一个 update，确认 terminal mask；
2. **Tensor tests：**检查 shape、finite、detach、gradient 和 parameter change；
3. **Overfit demonstration：**BC loss 与 action MSE 应下降；
4. **Short smoke：**数千 frames 验证 env、replay、eval.csv 和 checkpoint；
5. **Single-seed curve：**确认 success 非零，再启动 multi-seed；
6. **Ablation：**一次只改 λ、UTD 或 critic count 等可解释变量。

critic loss 下降但 return 不升。可能是 replay 只含失败、Q scale 错误、extrapolation error 或 actor 没有获得有效 gradient。**PPO ratio 爆炸**。检查 old log-prob 是否在 rollout 时保存，action dimensions 是否 sum，是否在 update 前改变 actor。**success 突然归零**。检查 actor std、Q overestimation、target lag、BC regularization 和 evaluation action 是否使用 mean。

11 系统设计题：机器人 Online RL 平台

回答可分五层。**数据层：**replay 按 episode 分片，记录 policy version、task、success、sensor calibration 与 intervention；demonstrations 单独 version。**训练层：**actor 与 learner 解耦，prioritized sampling 要记录 correction，checkpoint 包含 optimizer、target networks、normalizer 与 replay cursor。**评价层：**固定 scenario bank，simulation 与 real-robot 分级，使用 confidence interval 和 safety violations。**部署层：**动作 bounds、watchdog、latency budget、fallback controller 和 human override。**监控层：**state/action drift、critic disagreement、episode success、constraint cost 与 intervention rate。

真实机器人不应直接部署随机 exploration。可先在 simulation pretrain，以 demonstrations 初始化，再用 conservative action noise、safety shield 或 residual policy 逐步上线。sim-to-real 的核心不是只随机化视觉，而是覆盖 dynamics、delay、contact、calibration 与 observation noise。

12 高频面试问答

Q1：Q-learning 为什么会 overestimate？max 选择与评估使用同一组带噪估计，selection bias 使最大值偏高。Double-Q 解耦选择与评估，clipped double-Q 用 minimum 换取 conservative bias。

Q2：PPO 是严格 on-policy 吗？rollout 来自 frozen old policy；同一 rollout 多 epoch 后当前 policy 已变化，因此严格说产生轻微 off-policy。importance ratio 与 clip 控制偏离，但 replay buffer 长期复用不适合 PPO。

Q3：GAE λ 与 discount γ 有何不同？γ 定义优化目标的时间偏好；λ 组合多步 estimators，主要调 bias–variance。实现中二者乘在一起，语义不能混淆。

Q4：为什么 actor 不直接用 replay action？actor improvement 需要评估当前 policy action 的 $Q(s, \pi(s))$。replay action 用于 critic supervised target 或 BC；若直接最大化 replay action likelihood，就退化为 behavior cloning。

Q5：ensemble 和 double-Q 各解决什么？double-Q 的 min 主要抑制 overestimation；ensemble 提供多个 error realizations、uncertainty proxy 和随机 subset。只有两个 critics 也可 double-Q，但不能充分估计 disagreement。

Q6：何时提高 UTD？interaction 贵、replay 足够多样、critic 稳定时。若 buffer 很小、policy 快速变化或 Q divergence，先降低 UTD、learning rate，增加 target lag 或 regularization。

Q7：为什么 sparse reward 需要 demonstrations？不是数学上必需，而是随机 exploration 的 hitting probability 太低。demonstrations 提供成功 state-action support，让 critic 和 policy gradient 在有限 budget 内获得正信号。

13 如何把本作业讲成项目经历

使用“问题–证据–决策–结果”而非只说“实现 PPO”：

- 问题：hammer binary reward 下 PPO 与 off-policy sample efficiency 差异；
- 证据：多 seed learning curves、first-crossing frames、GAE/UTD ablations；
- 决策：恢复官方 demonstrations，写 terminal/gradient tests，并行独立 jobs；
- 结果：PPO best 23.2%，off-policy best 38.4%，高 UTD best 80.8%；
- 反思：frames、updates 和 wall time 是不同成本，best seed 不能代表可靠性。

这一表达同时展示理论推导、PyTorch、MuJoCo 环境、GPU 调度、统计方法和技术写作。

14 面试前自检清单

- 能从 Bellman optimality 写出 terminal-aware Q update；
- 能从 log-derivative 推导 policy gradient 与 baseline 无偏性；
- 能手算 GAE recursion，并解释 λ 两端；
- 能针对正负 advantage 分别解释 PPO clip；
- 能画出 actor、critic、target、replay 的 data flow；
- 能解释 double-Q、ensemble、target network 与 UTD 的不同作用；
- 能设计 multi-seed、frame/compute/wall-time 三预算实验；
- 能诊断 Q divergence、policy collapse 和 sparse reward；
- 能给机器人 online exploration 加入 safety boundary。

15 结语

Online RL 的难点不在单个 loss，而在多个近似同时耦合：policy 改变 data distribution，critic bootstrap 自己生成 target，replay 引入 policy lag，有限 evaluation 又带来选择 bias。高质量候选人应能把每个稳定化组件对应到具体 failure mode，并用可复现 ablation 而不是单条最好曲线支持结论。

参考文献

Xinyue Chen, Che Wang, Zijian Zhou, and Keith W. Ross. Randomized ensembled double q-learning: Learning fast without a model. In *International Conference on Learning Representations*, 2021.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018.

Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, and David Meger. Deep reinforcement learning that matters. In *AAAI Conference on Artificial Intelligence*, 2018.

Riashat Islam, Peter Henderson, Maziar Gomrokchi, and Doina Precup. Reproducibility of benchmarked

deep reinforcement learning tasks for continuous control. In *ICML Workshop on Reproducibility in Machine Learning*, 2017.

Ashvin Nair, Bob McGrew, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Overcoming exploration in reinforcement learning with demonstrations. In *IEEE International Conference on Robotics and Automation*, 2018.

John Schulman, Sergey Levine, Philipp Moritz, Michael I. Jordan, and Pieter Abbeel. Trust region policy optimization. In *International Conference on Machine Learning*, 2015.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.

Mel Vecerik, Todd Hester, Jonathan Scholz, Fumin Wang, Olivier Pietquin, Bilal Piot, Nicolas Heess, Thomas Rothörl, Thomas Lampe, and Martin Riedmiller. Leveraging demonstrations for deep reinforcement learning on robotics problems with sparse rewards. In *arXiv preprint arXiv:1707.08817*, 2017.

Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8:279–292, 1992.

Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8:229–256, 1992.