离线数据上的策略改进：AWAC、IQL 与轨迹拼接

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文在固定数据集上实现并比较 Advantage-Weighted Actor-Critic（AWAC）与 Implicit Q-Learning（IQL）。AntMaze 使用 D4RL 的 u-maze 与 medium-diverse 任务，PointMass 使用最大回报为 -46 的子优拼接数据集。两种算法都用 advantage-weighted regression 抽取策略；差别在价值备份是否查询当前策略在下一状态上的动作。AWAC 用 clipped double-Q，目标动作从 $\pi(\cdot \mid s')$ 采样。IQL 用 expectile 回归拟合 $V(s)$，Q 的目标只依赖数据集中的 (s, a, s')。三组随机种子的最终评估回报为：AWAC 在 u-maze 上 -329.9 ± 93.0，在 medium-diverse 上 -625.6 ± 40.0；IQL 在 u-maze 上更优的 $\zeta = 0.9$ 时分别为 -189.9 ± 29.6 与 -484.8 ± 12.2。拼接实验中该 ζ 的 IQL 平均回报为 -30.8，Filtered BC 为 -59.4。全部曲线由逐 seed 的 `metrics.csv` 生成。

关键词： Offline Reinforcement Learning；AWAC；IQL；Expectile；Stitching；D4RL

1 问题

Offline RL 只在事先收集的转移 $\mathcal{D}$ 上更新策略，训练期间不再与环境交互 [Lange et al., 2012, Levine et al., 2020]。这避免了在线探索的代价，也带来 distribution shift：若把标准 Q-learning 的 $\max_{a'}$ 或当前策略的 $a' \sim \pi$ 用到数据集很少覆盖的动作上，函数近似会给出过高的价值，备份又把这个误差传回已见过的状态 [Fujimoto et al., 2019, Kumar et al., 2019]。

行为克隆只最大化 $\log \pi(a \mid s)$，$(s, a) \sim \mathcal{D}$。它不会查询数据集外的动作，因此不外推，但也不能把多条次优轨迹拼成一条更短的路径 [Pomerleau, 1991]。AntMaze 的奖励在到达目标时为 0、其余步为 -1，回报越接近 0 越好。数据集里往往没有从起点直达终点的完整成功轨迹，能改进策略的算法必须做 stitching：在价值上承认“这段轨迹的后半段和另一段的前半段可以接上” [Fu et al., 2020, Kostrikov et al., 2022]。

本文完成作业中的三组问题：AWAC 在两张迷宫上的三种子评测，IQL 的 expectile 选择及其与 AWAC 的对比，以及 PointMass 上 IQL 与 Filtered BC 的拼接对照。

2 方法

2.1 AWAC

策略损失是 advantage 加权的负对数似然 [Peng et al., 2019, Nair et al., 2020]：

$$L_\pi(\psi) = -\mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[\log \pi_\psi(a \mid s)\, \exp\big(A(s,a)/\lambda\big)\Big]. \quad (1)$$

权重在反向传播前 detach，并截断到 50。λ 默认 0.1。优势用单样本估计 $A(s,a) = Q(s,a) - Q(s,a_\pi), a_\pi \sim \pi(\cdot \mid s)$。连续动作再截断到 $[-1, 1]$，与环境动作范围一致。

Critic 维护两套 Q 网络及对应的目标网络。目标为

$$y = r + \gamma(1-d) \min_{i\in\{1,2\}} Q_{\bar{\phi}_i}(s', a'), \quad a' \sim \pi(\cdot \mid s'), \quad (2)$$

d 为终止标记。两个在线网络对同一个 y 做均方误差，目标网络按 $\tau = 0.005$ 做 EMA[Fujimoto et al., 2018, Lillicrap et al., 2016]。取 min 是为了压低单网络的过估计；它不能从根上消除 a' 落到数据支撑外的问题。

2.2 IQL

IQL 不在备份里采样 a'。它另学一个状态价值 V_ϕ，用 expectile 回归去贴目标 Q 的上尾 [Newey and Powell, 1987, Kostrikov et al., 2022]：

$$L_2^\zeta(\mu) = |\zeta - \mathbf{1}\{\mu < 0\}|\, \mu^2, \quad (3)$$

$$L_V(\phi) = \mathbb{E}_{(s,a)\sim\mathcal{D}}\big[L_2^\zeta(Q_{\bar{\theta}}(s,a) - V_\phi(s))\big]. \quad (4)$$

$\zeta > 0.5$ 时，正残差（$Q > V$，即 V 偏低）权重大。$\zeta = 0.5$ 退化为均值回归。Q 的目标只用这个 V，并且 stop-gradient：

$$L_Q(\theta) = \mathbb{E}\big[(r + \gamma(1-d)V_\phi(s') - Q_\theta(s,a))^2\big]. \quad (5)$$

Q 只在数据集动作上回归，因此备份不查询未见动作。策略仍用与 AWAC 相同的指数加权回归，优势改为 $A(s,a) = Q(s,a) - V(s)$。温度 λ 对应论文中的 $1/\beta$。

表 1: 最终评估回报（三种子）。越高越好。

	u-maze	medium-diverse
AWAC ($\lambda = 0.1$)	-329.9 ± 93.0	-625.6 ± 40.0
IQL ($\zeta = 0.2$)	-531.3 ± 25.2	-700.0 ± 0.0
IQL ($\zeta = 0.9$)	-189.9 ± 29.6	-484.8 ± 12.2

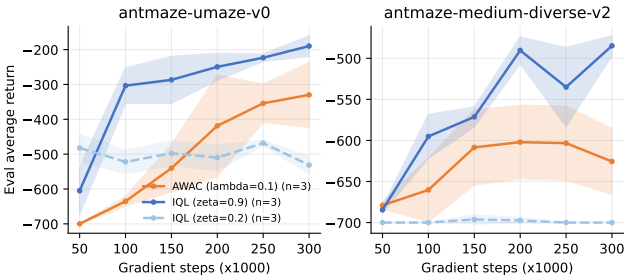


图 1: AntMaze 评估回报。阴影为种子间标准差。

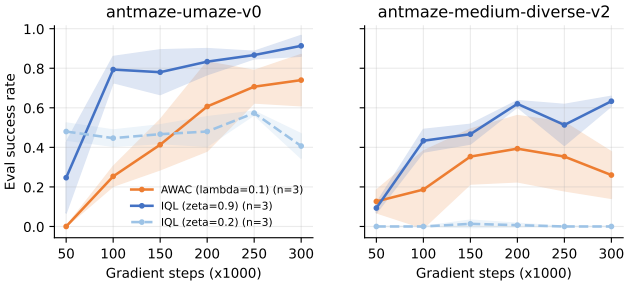


图 2: 评估成功率：轨迹中出现目标奖励的比例。

2.3 实现与核对

连续策略是对角高斯，均值经过 tanh，对数标准差限制在 $[-5, 2]$。离散 PointMass 使用 Categorical。单元测试核对了四件事：expectile 权重的方向及其闭式一阶条件、终止步的 TD 目标退化为 r、IQL 的 V 更新不改 Q 参数、正优势动作在 AWR 之后占据 Categorical 的最大概率。测试在 CPU 上 21 项全部通过。

3 实验设置

AntMaze 来自 D4RL[Fu et al., 2020]。u-maze 使用 `antmaze-umaze-v0`。公开镜像上的 `antmaze-medium-diverse-v0` HDF5 被截断：文件头记录的长度是 231 095 454 字节，实际只有 100 917 248 字节，h5py 拒绝打开。Berkeley 上的原文件可访问但单连接约 8 KB/s。medium 任务因此改用 D4RL 发布的修复版 `antmaze-medium-diverse-v2`，共 10^6 条转移。训练前把迷宫奖励减 1，使目标步为 0、其余步为 -1，与题面约定一致。评估回报按同样的平移计算。

网络与优化沿用 starter code：AntMaze 的 Q/V 为两层宽度 256，策略为四层宽度 512，Adam 学习率 3×10^{-4}，batch 256，折扣 0.99，各 3×10^5 次梯度步，每 5×10^4 步用 50 条确定性轨迹评估。PointMass 为两层宽度 64 的离散 Q/V，策略学习率 10^{-4}，5×10^4 步，20 条评估轨迹。作业要求的 AWAC、IQL 与 Filtered BC 各用三个种子 $\{1, 2, 3\}$。expectile 与温度扫描中，$\zeta \in \{0.5, 0.7, 0.95\}$ 和 $\lambda \in \{0.03, 0.3\}$ 各有两个种子，$\lambda = 1.0$ 有一个种子。表中的均值和标准差按这些种子的最终 `Eval_AverageReturn` 计算，不是单次评估内部的轨迹标准差。

拼接数据集有 79 条轨迹、8184 步，回报均值约 -104，最大 -46。Filtered BC 只保留回报最高的 10% 轨迹。IQL 使用在 u-maze 上更优的 ζ。额外消融包括 $\zeta \in \{0.5, 0.7, 0.95\}$、$\lambda \in \{0.03, 0.3, 1.0\}$，以及过滤比例 $1\%, 25\%, 50\%, 100\%$。硬件是一台 NVIDIA RTX PRO 6000，cgroup CPU 配额为 22 核。

4 AntMaze

u-maze 上 $\zeta = 0.2$ 的最终回报是 -531.3，$\zeta = 0.9$ 是 -189.9。两者中更高的是 $\zeta = 0.9$，medium 与拼接实验使用这个值。$\zeta > 0.5$ 把 V 推向同一状态上较高的 in-support 动作；$\zeta < 0.5$ 把权重点放在低于当前 V 的目标上，学到的更接近较差结果 [Kostrikov et al., 2022]。哪一侧回报更高，取决于数据里高价值动作是否足够密，以及过大的 expectile 是否在拟合偶然的高回报。

medium 迷宫更长，数据里成功轨迹更稀。AWAC 的最终回报是 -625.6，成功率 0.26；$\zeta = 0.9$ 的 IQL 是 -484.8，成功率 0.63。$\zeta = 0.2$ 的三条种子都停在 -700.0，成功率为 0。两种算法的差别在备份动作从哪里来。AWAC 的 Bellman 目标要采样 $a' \sim \pi(\cdot \mid s')$。训练早期 π 接近随机，a' 经常离开数据集动作的邻域，Q 在那里没有约束，clipped double-Q 只能减轻过估计 [Fujimoto et al., 2019, Kumar et al., 2020]。IQL 的 Q 目标是 $V(s')$，V 又只在数据集动作的 expectile 上回归，备份链停留在数据支撑内。$\zeta = 0.2$ 把这个 expectile 压到下尾，medium 上就没有留下可到达目标的策略。

λ 控制策略离开行为分布的程度。λ 很小时候选动作的权重大幅拉开，少数高优势动作主导梯度，方差上升。λ 大时权重接近常数，更新接近行为克隆。图 4 给出 $\lambda \in \{0.03, 0.1, 0.3, 1.0\}$ 的最终回报。$\lambda = 0.1$ 的三种子均值是 -329.9，种子间标准差 93.0。$\lambda = 1.0$ 的单种子回报更高，但只有一个种子，不能单独当成温度的最优点。

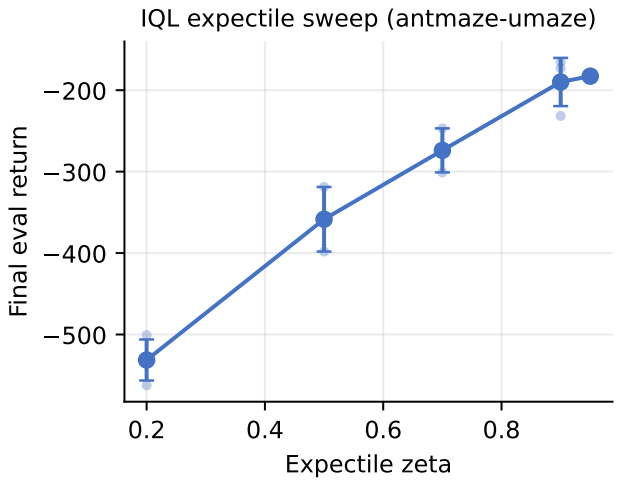


图 3: u-maze 上的 expectile 扫描。误差条为种子间标准差。

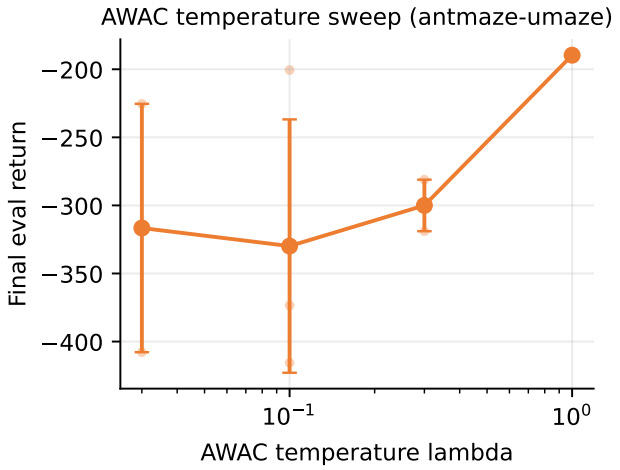


图 4: u-maze 上的 AWAC 温度 λ。横轴为对数刻度。

5 拼接

数据集没有任何一条轨迹优于 -46。PointMass 的 `step` 会把离散动作变成位移后再加上标准差 0.5 的高斯噪声，同一次评估的 20 条轨迹因此不会重合。平均回报描述典型轨迹，最大回报只说明这 20 条里最好的一条。回合上限是 150 步，从未到达目标时回报为 -150。

Filtered BC 在最高回报的 10% 轨迹上做极大似然，策略支撑限制在这些轨迹已经走过的动作上。IQL 的 V 可以在一个状态上采纳来自另一条轨迹的高价值后继，从而走出任何单条轨迹都没有完整走过的路径。同一数据集上的 AWAC 也列入图 6，用来对照：这个迷宫只有 5 个离散动作，行为数据对相关动作的覆盖比 AntMaze 密。

IQL（$\zeta = 0.9$）的平均回报 -30.8 高于 -46，最大回报 -18.0 同样高于 -46。平均意义下，评估轨迹已经短于数据集里最好的一条。Filtered BC（10%）的平均回报 -59.4 低于 -46，最大回报 -28.0 可以高于 -46：动作噪声让少数轨迹走得更短，典型轨迹仍然长于数据中的最好轨迹。图 7 里两种方法都能到达目标格，差别在路径长度。IQL 的轨迹更集中在从起点向上再进入目标的走廊；Filtered BC 在下半区来回更多。

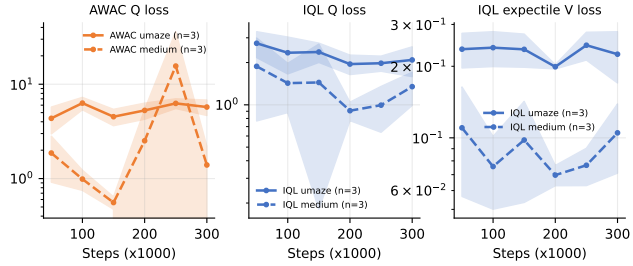


图 5: Critic 损失。IQL 的 Q 损失与 expectile V 损失分开记录。

表 2: PointMass 拼接数据集上的三种子最终回报。

	平均回报	最大回报
IQL ($\zeta = 0.9$)	-30.8 ± 3.0	-18.0 ± 0.8
AWAC ($\lambda = 0.1$)	-23.1 ± 0.7	-16.7 ± 1.2
Filtered BC (10%)	-59.4 ± 0.9	-28.0 ± 3.6
数据集	均值 -104，最大 -46	

过滤比例不是单调的。1% 时三个种子的回报都是 -150.0，成功率 0.00，策略没有到达目标。10% 到 50% 的平均回报分别是 -59.4、-55.8 和 -53.3，都到达了目标。使用全部数据时平均回报降到 -118.5，更接近数据集本身的均值。AWAC 在这个任务上的平均回报是 -23.1，也高于 -46。离散小迷宫上，策略采样的备份没有阻止拼接；AntMaze 上的差距方向相反，IQL 的最终回报高于 $\lambda = 0.1$ 的 AWAC。

6 结论

AWAC 用优势加权回归改进行为策略，价值备份仍依赖 $a' \sim \pi$。IQL 把这一查询换成 in-sample expectile，Q 只在数据动作上更新。u-maze 上 $\zeta = 0.9$ 的最终回报 -189.9 高于 $\zeta = 0.2$ 的 -531.3，medium 沿用 $\zeta = 0.9$。该设置下 IQL 在两张迷宫上的最终回报都高于 $\lambda = 0.1$ 的 AWAC；$\zeta = 0.2$ 在 medium 上三个种子都没有到达目标。PointMass 上，IQL 的平均回报 -30.8 高于数据集上限 -46，Filtered BC 的 -59.4 低于 -46。前者的典型轨迹短于数据中最好的一条，后者只在动作噪声下的少数轨迹上超过这条界限。

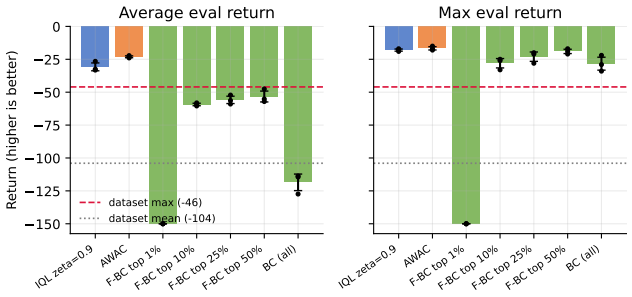


图 6: 不同算法与过滤比例的最终回报。虚线为数据集最大回报 −46。

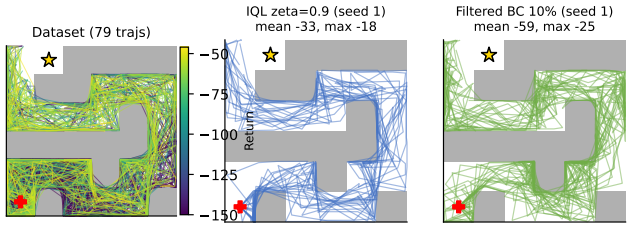


图 7: 左：数据集轨迹按回报着色。中、右：种子 1 的最终评估轨迹。星号为目标。

参考文献

Justin Fu, Aviral Kumar, Ofir Nachum, George Tucker, and Sergey Levine. D4RL: Datasets for deep data-driven reinforcement learning. In *arXiv preprint arXiv:2004.07219*, 2020.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018.

Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, 2019.

Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.

Aviral Kumar, Justin Fu, Matthew Soh, George Tucker, and Sergey Levine. Stabilizing off-policy Q-learning via bootstrapping error reduction. In *Advances in Neural Information Processing Systems*, 2019.

Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Sascha Lange, Thomas Gabel, and Martin Riedmiller. Batch reinforcement learning. *Reinforcement Learning: State-of-the-Art*, pages 45–73, 2012.

Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.

Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. In *International Conference on Learning Representations*, 2016.

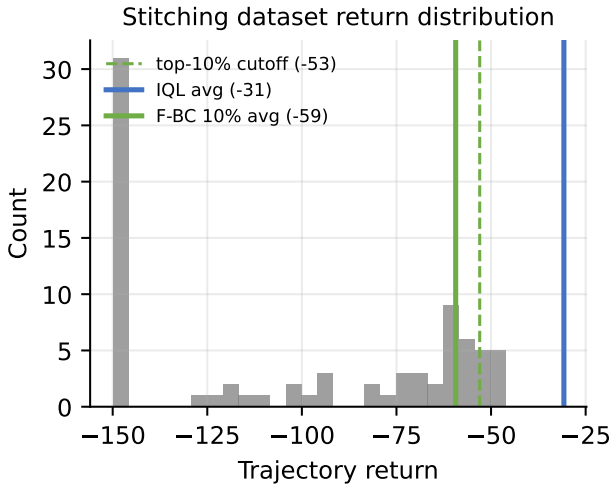


图 8: 拼接数据集的轨迹回报分布，以及两种方法的平均评估回报。

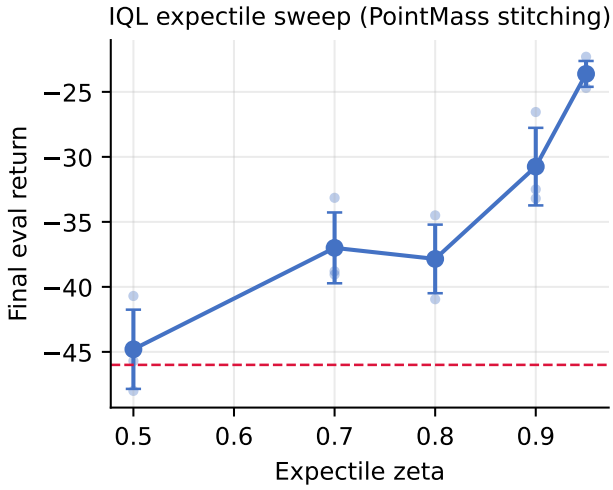


图 9: 拼接任务上的 expectile。平均回报随 ζ 升高，并在较高的 ζ 上超过 −46。

Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. AWAC: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.

Whitney K. Newey and James L. Powell. Asymmetric least squares estimation and testing. volume 55, pages 819–847, 1987.

Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. In *arXiv preprint arXiv:1910.00177*, 2019.

Dean A. Pomerleau. Efficient training of artificial neural networks for autonomous navigation. In *Neural Computation*, 1991.