Offline Reinforcement Learning 工程与研究面试指南：从分布偏移到 AWAC、IQL 与拼接

ShaneLiu04

https://github.com/ShaneLiu04

摘要

本文整理 offline RL 岗位面试里反复出现的一条主线：固定数据集上的 Bellman 备份为什么会外推，各类算法如何把策略改进限制在数据支撑内，以及这些选择在工程上对应哪些超参、日志和失败模式。内容覆盖 batch RL、行为克隆、BCQ、BEAR、CQL、AWR/AWAC、CRR、IQL、expectile、模型类离线方法和序列建模基线，并用 AntMaze 与 PointMass 上的实测数字说明每个机制改变的是哪一项误差。本文面向算法工程与研究岗位：既要能写出损失，也要能判断一份日志里的高 Q 值是学到了拼接还是过估计。

关键词： Offline RL；Distribution Shift；AWAC；IQL；CQL；Stitching；Expectile

1 固定数据集改变了什么

Online RL 的策略改进依赖新的交互：价值估高的动作会被执行，环境返回真实的后继，错误的外推会被样本纠正 [Sutton and Barto, 2018]。Offline RL 去掉了这一回路。数据集 $\mathcal{D}$ 在训练开始前就固定，算法只能在这些 (s, a, r, s') 上更新 [Lange et al., 2012, Levine et al., 2020]。工业场景里这是常态：日志来自人工、脚本或旧策略，在线试错的代价过高，例如机器人损坏、推荐系统的用户流失、自动驾驶的安全约束。

行为克隆把问题收成监督学习，$\max_\psi \mathbb{E}_{\mathcal{D}}[\log \pi_\psi(a \mid s)]$ [Pomerleau, 1991]。它没有外推，也没有改进。部署时状态分布一旦偏离采集分布，误差会沿时间复合，这就是 covariate shift[Ross et al., 2011]。Offline RL 想在不采集新数据的前提下，得到比行为策略更高的回报。它必须利用动态规划把不同轨迹的片段接起来，同时避免在没有数据的动作上相信自己的 Q 值。

2 外推误差

标准 Q-learning 的目标含有 $\max_{a'} Q(s', a')$ 或 $\mathbb{E}_{a' \sim \pi}[Q(s', a')]$。函数近似在数据稀疏的区域没有约束，最大化或策略采样会主动挑选这些高估点。下一次备份把高估写回有数据的状态，误差沿轨迹反向传播。Fujimoto 等人把这种现象称为 extrapolation error，并指出 off-policy deep RL 在完全没有探索时会发散 [Fujimoto et al., 2019]。Kumar 等人进一步把备份误差写成 bootstrapping error：不可见动作的价值误差被 γ 折扣后送回可见状态，策略若增加这些动作的概率，误差会被放大 [Kumar et al., 2019]。

因此 offline 算法都在回答同一个设计问题：策略改进的提议分布，和价值备份的查询分布，哪一个允许离开 $\mathcal{D}$。只约束其中一个通常不够。TD3 的 clipped double-Q 减轻在线设置里的过估计 [Fujimoto et al., 2018, van Hasselt et al., 2016]，但两个网络可以在同一个未见动作上一起高估，所以它不是 offline 约束。

3 约束与悲观

第一类方法显式限制策略接近行为分布。BCQ 用一个条件 VAE 拟合行为策略，动作提案只在 VAE 样本的小扰动内做最大化 [Fujimoto et al., 2019]。BEAR 用 MMD 把学习策略撑在行为策略的支撑上，而不是逐动作匹配密度，从而允许多模态数据 [Kumar et al., 2019]。BRAC 直接在策略目标里加行为策略的散度惩罚 [Wu et al., 2019]。TD3+BC 把这个思想收成一项极简正则：在 TD3 的策略损失上加 $\lambda_{\text{BC}} \|a - \pi(s)\|^2$，并用 Q 的尺度做归一，避免正则权重随奖励尺度漂移 [Fujimoto and Gu, 2021]。面试里要能说明：支撑约束保留拼接所需的多模态，密度匹配会把策略拉向次优模态的平均。

第二类方法不改提案分布，而把未见动作的价值压低。CQL 在 Q 损失里加入 $\mathbb{E}_{a \sim \mu}[Q(s, a)] - \mathbb{E}_{a \sim \mathcal{D}}[Q(s, a)]$ 一类的正则，使任意策略下的 Q 值下界尽量不超过数据动作上的 Q[Kumar et al., 2020]。它的工程代价是需要对 μ 采样，正则系数对任务敏感。模型类方法把不确定区域的奖励改小：MOPO 用动力学集成的方差惩罚奖励 [Yu et al., 2020]，MOReL 把不确定转移送进吸收的低价值状态 [Kidambi et al., 2020]，COMBO 把 CQL 式保守和模型 rollout 合在一起 [Yu et al., 2021]。模型误差本身会变成新的外推源，所以惩罚必须和集成分歧校准，而不是手写一个常数 [Ghasemipour et al., 2022]。

4 加权回归：AWR、AWAC 与 CRR

Advantage-weighted regression 把策略改进写成带权的极大似然 [Peng et al., 2019]。从 KL 约束的策略改进出发，最优解满足

$$\pi_{k+1}(a \mid s) \propto \pi_\beta(a \mid s) \exp\big(A^{\pi_k}(s,a)/\lambda\big). \tag{1}$$

当行为数据就是 π_β 的样本时，投影回参数族等价于最小化

$$-\mathbb{E}_{(s,a)\sim\mathcal{D}}\big[\log \pi_\psi(a \mid s) \exp(A/\lambda)\big]. \tag{2}$$

λ 是温度，也是离开行为分布的步长。它小，则少数高优势样本主导梯度；它大，则退化为行为克隆。权重必须 detach，否则优势会为了减小损失而被网络改写。实现里还要把 $\exp(A/\lambda)$ 截断，避免单个离群优势把梯度打爆。

AWAC 用同一项损失，并在离线数据上先训练，再在线微调 [Nair et al., 2020]。价值备份仍是 $a' \sim \pi(\cdot \mid s')$ 的 expected SARSA，配合双 Q 与目标网络。因此 AWAC 的策略步是保守的，价值步并不保守。这解释了它在短迷宫上可以工作、在长时域稀疏奖励上容易被早期随机 a' 带偏的现象。CRR 做了更明确的过滤：权重可以是 $\exp(A/\beta)$，也可以是只保留正优势的指示函数 [Wang et al., 2020]。面试时把这三项放在一起：AWR 给出闭式动机，AWAC 给出离线到在线的训练日程，CRR 给出“是否丢弃负优势样本”的消融维度。

本文的 AWAC 在 u-maze 上最终回报为 -329.9，在 medium-diverse 上为 -625.6。温度扫描用来检查默认 $\lambda = 0.1$ 是否落在模仿和改进之间。

5 IQL：不查询未见动作

IQL 的目标是让价值备份完全 in-sample[Kostrikov et al., 2022]。它引入 $V(s)$，用 expectile 回归拟合目标 Q 的上尾，而不是均值 [Newey and Powell, 1987]。损失 $L_2^\zeta(\mu) = |\zeta - \mathbf{1}\{\mu < 0\}|\mu^2$ 在 $\zeta > 0.5$ 时给正残差更大的权重。一阶条件是

$$\zeta\,\mathbb{E}[(Q-V)_+] = (1-\zeta)\,\mathbb{E}[(V-Q)_+]. \tag{3}$$

$\zeta = 0.5$ 时 V 是条件均值；$\zeta \to 1$ 时 V 逼近数据中该状态上的最大 Q。Q 的目标改成 $r + \gamma V(s')$，并且 V 不通过这条损失接收 Q 的梯度。于是 Q 网络从未在策略采样的 a' 上被训练。策略抽取再使用上面的指数加权回归，优势为 $Q - V$，温度的倒数就是论文里的 β。

这和 CQL 的差别值得在面试里讲清楚。CQL 主动压低未见动作的 Q，需要额外采样。IQL 根本不给未见动作定义备份，逼近的是数据集条件分布的上 expectile。因此 IQL 能拼接的是“数据里真实出现过的高价值后继”，不能发现数据支撑之外的捷径。ζ 太低会学到差轨迹的均值，太高会把偶然的高回报噪声当成价值。本文 u-maze 上 $\zeta = 0.2$ 的回报是 -531.3，$\zeta = 0.9$ 是 -189.9。medium 上选用 $\zeta = 0.9$，回报 -484.8。

后续工作把这一思想再参数化。XQL 用极值理论连接 max-entropy 与 expectile，给出 Gumbel 误差下的损失 [Garg et al., 2023]。IDQL 保留 IQL 的价值学习，把高斯策略换成 diffusion，以覆盖行为分布的多模态 [Hansen-Estruch et al., 2023]。Fisher-BRC 则从散度正则的角度约束 critic，而不是换备份算子 [Kostrikov et al., 2021]。DR3 指出深度价值网络即使在 in-sample 回归下也会因为隐式正则把 Q 推向共同的低秩方向，需要显式惩罚特征内积 [Kumar et al., 2022]。这些论文回答的是“IQL 已经不查询 OOD 动作之后，还剩什么误差”。

6 拼接与监督学习基线

Stitching 指数据集中不存在最优轨迹，但最优轨迹的每一段都出现在某条次优轨迹里。动态规划能把这些段接上，因为 $V(s)$ 总结的是后继的价值，而不是“必须沿同一条轨迹走下去”。行为克隆和 Filtered BC 没有这个总结，它们只提高所见动作的似然。只保留最高回报的 10% 轨迹可以去掉明显的失败样本，但保留下来的轨迹本身仍是次优的，策略无法走出它们的凸组合之外。

Return-conditioned supervised learning 用目标回报当条件，直接拟合 $p(a \mid s, R)$[Emmons et al., 2022, Ghosh et al., 2021]。Decision Transformer 把整段轨迹当成序列，用自回归模型按目标 return-to-go 生成动作 [Chen et al., 2021]；Trajectory Transformer 在同一框架里离散化状态和动作 [Janner et al., 2021]。这类方法实现简单，在有完整成功轨迹的数据上很强。它们弱在拼接：模型看到的训练序列并没有把 A 轨迹的前半和 B 轨迹的后半接在同一个 context 里，除非数据里已经有这样的拼接样本。AntMaze 因此成为区分动态规划和序列克隆的常用探针 [Fu et al., 2020]。

本文的 PointMass 数据集最大回报为 -46、平均约 -104。选用 ζ 的 IQL 平均评估回报为 -30.8，Filtered BC 为 -59.4。比较对象应当是 -46，而不是 0：超过数据集最大值才说明出现了数据中不存在的更好轨迹。

7 工程清单

面试里的实现题通常不考新损失，而考下面这些容易写错的接口。

- 奖励约定要和评估一致。D4RL AntMaze 原始目标奖励常为 1，训练代码把它减 1 后目标步为 0。评估若忘记同一平移，曲线会整体偏移一个回合长度。
- 终止标记只在真正结束时截断 bootstrap。超时（time limit）不应当成 $d=1$，否则长回合的价值被系统性压低。v0 与 v2 迷宫数据的一个已知差别就是早期终止的处理 [Fu et al., 2020]。
- 目标网络用 EMA，备份进 no_grad。IQL 里 $V(s')$ 也要断开，否则 Q 和 V 会互相追逐。
- 指数权重先 detach 再截断。优势的标准化可以再降方差，但会改变 λ 的语义，报告里必须写明有没有做。
- 连续动作在送进 Q 之前截断到环境范围。高斯尾部的样本会让 Q 在 $|a|>1$ 的区域接收梯度。
- 三种子的均值不要和单次评估的轨迹标准差混用。跨种子统计才对应算法稳定性 [Agarwal et al., 2021]。
- 数据集文件要校验 HDF5 超块里的 `stored_eof`。镜像上的 medium-diverse v0 文件声明长度为 231 095 454 字节，实体只有 100 917 248 字节。这种文件能通过下载大小检查，但不能被 h5py 打开。

日志上至少保留评估回报、成功率、Q 损失、V 损失和优势权重的分位数。Q 损失下降而成功率不升，通常是价值在拟合一个不会到达目标的行为分布。优势权重的最大值长期顶在截断上限，说明 λ 过小或优势尺度没有控制。

从离线到在线的微调是另一类常见岗位问题。AWAC 的原始动机就是用离线数据初始化，再用少量在线样本改进 [Nair et al., 2020]。Cal-QL 在离线 CQL 预训练和在线微调之间校准 Q 的尺度，避免上线后价值崩溃 [Nakamoto et al., 2023]。RLPD 则把离线数据和高 UTD 的在线更新放进同一个 buffer，强调对称采样而不是复杂的悲观正则 [Ball et al., 2023]。讲这条线时要区分：离线阶段防的是外推，上线阶段防的是分布突然变了之后旧 Q 的尺度不再匹配。

8 怎么读一份实验

D4RL 把不同任务的回报映射到归一化分数，AntMaze 的参考上界对应成功率 [Fu et al., 2020]。RL Unplugged 使用另一套数据划分，数字不能直接和 D4RL 对比 [Gulcehre et al., 2020]。CORL 提供了研究向的统一实现，适合作为复现时的对照代码，而不是作为黑盒替换自己的备份算子 [Tarasov et al., 2022]。

读本文的 AntMaze 曲线时，先看最终三种子均值，再看成功率是否和回报同向。回报上升但成功率不变，可能只是失败轨迹稍短。读 PointMass 时，先把结果和数据集最大值 -46 放在一起，再看轨迹图里评估路径是否穿过了单条数据轨迹没有完整覆盖的走廊。expectile 和 λ 的扫描应呈现单峰或平台：两端变差说明旋钮有效，单调则说明搜索范围没有覆盖到退化和过拟合的两侧。

综述可以用来组织阅读顺序，而不能代替原始损失的推导 [Prudencio et al., 2023]。一个够用的阅读顺序是：extrapolation error[Fujimoto et al., 2019]，支撑约束 [Kumar et al., 2019]，保守 Q[Kumar et al., 2020]，加权回归 [Peng et al., 2019, Nair et al., 2020, Wang et al., 2020]，in-sample expectile [Kostrikov et al., 2022]，然后才是 diffusion 策略、序列模型和在线微调。

9 岗位问题上的回答方式

“为什么不能直接把 DQN 或 SAC 套到日志上?” 因为最大化或熵正则策略会查询 $\mathcal{D}$ 没有覆盖的动作，函数近似在那里没有惩罚 [Mnih et al., 2015, Haarnoja et al., 2018, Fujimoto et al., 2019]。

“AWAC 和 IQL 的策略损失一样，为什么结果不同?” 因为差异在 critic。AWAC 的 y 含 $a'\sim\pi$，IQL 的 y 只含 $V(s')$。长时域上这个差别会被 γ^T 放大。

“ζ 和 λ 分别调什么?” ζ 选择价值去贴数据上尾的程度，λ 选择策略偏离行为样本的程度。两个都变大并不等价：高 ζ 加低 λ 会在一个很尖的上尾上做很大的策略步，方差最大。

“如何证明出现了拼接?” 需要一个已知最优轨迹不在数据集中的环境，报告数据最大回报和评估回报，并给出轨迹可视化。只有平均回报提高、没有和数据上限比较，不能区分“模仿了最好的那几条”和“拼出了更好的一条”。

参考文献

Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems*, 2021.

Philip J. Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. In *International Conference on Machine Learning*, 2023.

Lili Chen, Kevin Lu, Aravind Rajeswaran, Kimin Lee, Aditya Grover, Michael Laskin, Pieter Abbeel, Aravind Srinivas, and Igor Mordatch. Decision transformer: Reinforcement learning via sequence modeling. In *Advances in Neural Information Processing Systems*, 2021.

Scott Emmons, Benjamin Eysenbach, Ilya Kostrikov, and Sergey Levine. Rvs: What is essential for offline RL via supervised learning? In *International Conference on Learning Representations*, 2022.

Justin Fu, Aviral Kumar, Ofir Nachum, George Tucker, and Sergey Levine. D4RL: Datasets for deep data-driven reinforcement learning. In *arXiv preprint arXiv:2004.07219*, 2020.

Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2021.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018.

Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, 2019.

Divyansh Garg, Joey Hejna, Matthieu Geist, and Stefano Ermon. Extreme Q-learning: Maxent RL without entropy. In *International Conference on Learning Representations*, 2023.

Seyed Kamyar Seyed Ghasemipour, Shixiang Shane Gu, and Ofir Nachum. Why so pessimistic? estimating uncertainties for offline RL through ensembles, and why their independence matters. In *Advances in Neural Information Processing Systems*, 2022.

Dibya Ghosh, Abhishek Gupta, Ashwin Reddy, Justin Fu, Coline Devin, Benjamin Eysenbach, and Sergey Levine. Learning to reach goals via iterated supervised learning. In *International Conference on Learning Representations*, 2021.

Caglar Gulcehre, Ziyu Wang, Alexander Novikov, Thomas Paine, Sergio Gomez, Konrad Zolna, Rishabh Agarwal, Josh Merel, Daniel Mankowitz, Cosmin Paduraru, et al. RL unplugged: A suite of benchmarks for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International Conference on Machine Learning*, 2018.

Philippe Hansen-Estruch, Ilya Kostrikov, Michael Janner, Jakub Grudzien Kuba, and Sergey Levine. IDQL: Implicit Q-learning as an actor-critic method with diffusion policies. In *arXiv preprint arXiv:2304.10573*, 2023.

Michael Janner, Qiyang Li, and Sergey Levine. Offline reinforcement learning as one big sequence modeling problem. In *Advances in Neural Information Processing Systems*, 2021.

Rahul Kidambi, Aravind Rajeswaran, Praneeth Netrapalli, and Thorsten Joachims. MOReL: Model-based offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Ilya Kostrikov, Rob Fergus, Jonathan Tompson, and Ofir Nachum. Offline reinforcement learning with fisher divergence critic regularization. In *International Conference on Machine Learning*, 2021.

Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.

Aviral Kumar, Justin Fu, Matthew Soh, George Tucker, and Sergey Levine. Stabilizing off-policy Q-learning via bootstrapping error reduction. In *Advances in Neural Information Processing Systems*, 2019.

Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.

Aviral Kumar, Rishabh Agarwal, Tengyu Ma, Aaron Courville, George Tucker, and Sergey Levine. DR3: Value-based deep reinforcement learning requires explicit regularization. In *International Conference on Learning Representations*, 2022.

Sascha Lange, Thomas Gabel, and Martin Riedmiller. Batch reinforcement learning. *Reinforcement Learning: State-of-the-Art*, pages 45–73, 2012.

Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. In *Nature*, 2015.

Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. AWAC: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.

Mitsuhiko Nakamoto, Simon Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-QL: Calibrated offline RL pre-training for efficient online fine-tuning. In *Advances in Neural Information Processing Systems*, 2023.

Whitney K. Newey and James L. Powell. Asymmetric least squares estimation and testing. volume 55, pages 819–847, 1987.

Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. In *arXiv preprint arXiv:1910.00177*, 2019.

Dean A. Pomerleau. Efficient training of artificial neural networks for autonomous navigation. In *Neural Computation*, 1991.

Rafael Figueiredo Prudencio, Marcos R. O. A. Maximo, and Esther Luna Colombini. A survey on offline reinforcement learning: Taxonomy, review, and open problems. *IEEE Transactions on Neural Networks and Learning Systems*, 2023.

Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *International Conference on Artificial Intelligence and Statistics*, 2011.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.

Denis Tarasov, Alexander Nikulin, Dmitry Akimov, Vladislav Kurenkov, and Sergey Kolesnikov. CORL: Research-oriented deep offline reinforcement learning library. In *Advances in Neural Information Processing Systems, Datasets and Benchmarks*, 2022.

Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. 2016.

Ziyu Wang, Alexander Novikov, Konrad Zolna, Josh Merel, Jost Tobias Springenberg, Scott Reed, Bobak Shahriari, Noah Siegel, Caglar Gulcehre, Nicolas Heess, and Nando de Freitas. Critic regularized regression. In *Advances in Neural Information Processing Systems*, 2020.

Yifan Wu, George Tucker, and Ofir Nachum. Behavior regularized offline reinforcement learning. In *arXiv preprint arXiv:1911.11361*, 2019.

Tianhe Yu, Garrett Thomas, Lantao Yu, Stefano Ermon, James Zou, Sergey Levine, Chelsea Finn, and Tengyu Ma. MOPO: Model-based offline policy optimization. In *Advances in Neural Information Processing Systems*, 2020.

Tianhe Yu, Aviral Kumar, Rafael Rafailov, Aravind Rajeswaran, Sergey Levine, and Chelsea Finn. COMBO: Conservative offline model-based policy optimization. In *Advances in Neural Information Processing Systems*, 2021.